



UNIVERSITY FOR BUSINESS AND TECHNOLOGY
AMERICAN EUROPEAN UNIVERSITY

Programi për Shkenca Kompjuterike dhe Inxhinierisë

**Bazimi determinist dhe verifikimi i automatizuar i shpjegimeve
mjekësore të gjeneruara nga modelet e mëdha gjuhësore**

Shkalla Bachelor

Kledion Berisha

Tetor / 2026

Prishtinë



UNIVERSITY FOR BUSINESS AND TECHNOLOGY
AMERICAN EUROPEAN UNIVERSITY

Programi për Shkenca Kompjuterike dhe Inxhinierisë

Punim Diplome

Viti akademik [XXXX] – [YYYY]

Kledion Berisha

**Bazimi determinist dhe verifikimi i automatizuar i shpjegimeve
mjekësore të gjeneruara nga modelet e mëdha gjuhësore**

Mentori: [Titulli. Emri dhe Mbiemri]

Tetor / 2026

*Ky punim është përpiluar dhe dorëzuar në përmbushjen e kërkesave të pjesshme për Shkallën
Bachelor*

ABSTRAKT

Rezultatet e analizave laboratorike u dorëzohen pacientëve në një formë të hartuar për profesionistin shëndetësor. Modelet e mëdha gjuhësore mund t'i riformulojnë ato në gjuhë të thjeshtë, por prodhojnë me rrjedhshmëri edhe pohime që nuk mbështeten nga dokumenti (halucinacion), çka në kontekst mjekësor është rrezik i drejtpërdrejtë për pacientin.

Ky punim propozon, implementon dhe vlerëson ANALYTE, një sistem i ndërtuar mbi parimin se modeli gjuhësor nuk duhet të ketë autoritet mbi faktet. Informacioni nxirret nga dokumenti dhe interpretohet nga një shtresë deterministe; modeli merr vetëm këtë përfaqësim të strukturuar dhe merret ekskluzivisht me formulimin; një shtresë e automatizuar verifikimi kontrollon daljen kundrejt burimit përpara se ajo t'i shfaqet përdoruesit, dhe kur verifikimi dështon pas rigjenerimit, shfaqet një tekst rezervë determinist. Arkitektura zbatohet mbi vlera laboratorike të strukturuar dhe mbi tekstin e lirë të mjekut.

Vlerësimi u krye mbi një korpus sintetik prej 500 dokumentesh laboratorike shqip (332 dixhitale, 168 të skanuara) me të vërtetë bazë të plotë, mbi një korpus të korrumpuar për matjen e detektorëve, dhe mbi 105 fjali natyrale, 25 shpjegime dhe 60 fjali narrative të dorëzuara nga autori. Gjeneruesi është një model i vogël me plan falas (Mistral Ministral 14B); gjykatësi i detektimit është një model Claude. Punimi nuk validohet mbi dokumente reale dhe nuk përfshin studim me përdorues.

Mbi dokumentet dixhitale nxjerrja dhe klasifikimi i statusit dalin 1.000; mbi skanimet e simuluar F1 i nxjerrjes është 0.670 dhe saktësia e statusit 0.881; 125 nga 2 370 vlera lexohen gabim dhe pranohen. Në eksperimentin kryesor, norma e shkeljeve që arrijnë te përdoruesi është 54.4 për 100 fjali pa bazim, 9.5 me bazim dhe 0.000 (kufiri i sipërm 95%: 0.034) me bazim dhe verifikim me rregulla, me çmimin që 25% e dokumenteve përfundojnë te teksti rezervë. Ky zero numëron vetëm shkeljet që rregullat shohin: një audit i pavarur i 90 teksteve që kaluan verifikimin gjeti problem të llojeve që rregullat synojnë te 36% e tyre (26–46%). Detektori me rregulla arrin macro F1 0.993 mbi korpusin e korrumpuar dhe 0.795 mbi fjalitë natyrale; klasifikuesi XLM-RoBERTa 0.015–0.177, sepse mëson shabllonet e gjeneruesit; gjykatësi Claude Sonnet 1.000 dhe Claude Haiku 0.514–0.625. Hipoteza e parë konfirmohet në formën e matur, por jo si garanci; e dyta nuk konfirmohet. Punimi dokumenton gjithashtu pasojat arkitekturore të mungesës së çdo modeli klinik të paratrajnuar për shqipen.

Fjalë kyçe: halucinacion, bazim, verifikim i automatizuar, përpunim i gjuhës natyrore në mjekësi, modele të mëdha gjuhësore, rezultate laboratorike, gjuhë me burime të pakta

MIRËNJOHJE/FAENDERIME

Falënderoj mentorin tim për udhëzimet, vërejtjet dhe durimin gjatë gjithë punës në këtë punim, si dhe stafin akademik të Programit për Shkenca Kompjuterike dhe Inxhinierisë të UBT-së për njohuritë e marra gjatë studimeve.

Falënderoj familjen time për mbështetjen e pakushtëzuar.

Falënderoj gjithashtu komunitetin e programeve me burim të hapur, mbi të cilat është ndërtuar ky sistem.

PËRMBAJTJA

LISTA E FIGURAVE.....	VIII
LISTA E TABELAVE.....	VIII
FJALORI I TERMAVE.....	XI
1 HYRJE.....	1
2 SHQYRTIMI I LITERATURËS (HISTORIKU).....	4
2.1 Diagnostika laboratorike dhe interpretimi i rezultateve.....	4
2.1.1 Natyra e intervalit referent.....	4
2.1.2 Standardizimi terminologjik dhe LOINC.....	5
2.1.3 Komunikimi i rezultateve me pacientin.....	5
2.2 Përpunimi i gjuhës natyrore në kontekst mjekësor.....	6
2.2.1 Nxjerrja e informacionit klinik.....	6
2.2.2 Zbulimi i mohimit.....	7
2.2.3 Thjeshtimi i teksteve mjekësore.....	7
2.2.4 Gjuhët me burime të pakta.....	9
2.3 Modelet e mëdha gjuhësore dhe halucinacionet.....	9
2.3.1 Përkufizimi dhe tipologjia.....	9
2.3.2 Shkaqet.....	10
2.3.3 Bazimi.....	11
2.4 Verifikimi i daljes së modeleve gjuhësore.....	11
2.4.1 Natural Language Inference si bazë verifikimi.....	11
2.4.2 Metoda të tjera detektimi.....	12
2.4.3 Pozicionimi i këtij punimi.....	13
2.5 Modelet shumëgjuhësh.....	13
2.6 Teknologjitë e përdorura.....	14
2.7 Aspektet rregullatore dhe etike.....	14

2.7.1 Kualifikimi si pajisje mjekësore.....	14
2.7.2 Akti Evropian për Inteligjencën Artificiale.....	15
2.7.3 Mbrojtja e të dhënave.....	15
3 DEKLARIMI I PROBLEMIT.....	17
3.1 Pyetjet kërkimore.....	18
3.2 Hipotezat.....	19
3.3 Shtrirja dhe kufizimet.....	19
4 METODOLOGJIA.....	21
4.1 Qasja e zhvillimit të sistemit.....	21
4.2 Arkitektura e sistemit.....	22
4.2.1 Kontrata e të dhënave.....	24
4.3 Dega e rezultateve laboratorike.....	26
4.3.1 Rugëzimi i dokumentit.....	26
4.3.2 Rindërtimi i rreshtave.....	27
4.3.3 Normalizimi.....	27
4.3.4 Zgjidhja e intervalit referent.....	28
4.3.5 Klasifikimi dhe refuzimi i interpretimit.....	28
4.3.6 Rreshtat e hedhur.....	29
4.3.7 Gjendja e zbatimit dhe matja.....	29
4.3.8 Kombinimet ndërmjet analiteve.....	30
4.4 Dega e raportit mjekësor.....	31
4.4.1 Gjetja e tekstit dhe ndarja në fjali.....	31
4.4.2 Njohja e termave.....	31
4.4.3 Mohimi dhe pasiguria.....	32
4.4.4 Pohimet dhe krahasimi i kryqëzuar.....	33
4.4.5 Matja.....	33

4.5 Shtresa e verifikimit.....	34
4.6 Trajtimi i dështimit.....	36
4.7 Komponenti i mësimit makinerik.....	37
4.8 Strategjia e të dhënave.....	39
4.8.1 Korpusi sintetik.....	39
4.8.2 Të dhënat reale.....	42
4.9 Organizimi i komponentëve të aplikacionit.....	43
4.10 Struktura e databazës.....	45
4.11 Metodologjia e vlerësimit.....	47
4.11.1 Kontrolli i rrjedhjes së të dhënave.....	48
4.11.2 Infrastruktura e vlerësimit.....	49
4.12 Politika e sigurisë.....	51
5 REZULTATET.....	55
5.1 Rezultatet e implementimit të sistemit.....	57
5.2 Saktësia e nxjerrjes së të dhënave laboratorike.....	62
5.3 Saktësia e klasifikimit kundrejt intervaleve referente.....	63
5.3.1 Kontrolli i besueshmërisë për vlerat e lexuara nga OCR-ja.....	64
5.4 Besnikëria e thjeshtimit të tekstit mjekësor.....	65
5.5 Saktësia e krahasimit të kryqëzuar.....	66
5.5.1 Dega B mbi fjali të dorëzuara nga autori (grupi C).....	67
5.6 Efekti i shtresës së verifikimit.....	69
5.6.1 Auditi i pavarur i tekstit të dorëzuar.....	71
5.6.2 Të njëjtat kushte me r1.4 dhe kontrollin e OCR-së.....	73
5.7 Saktësia e vetë shtresës së verifikimit.....	74
5.7.1 Prejardhja e grupeve B dhe A.....	80
5.7.2 Gjykatësi LLM: si u krye dhe çfarë nuk dihet.....	81

5.7.3 Katalogu r1.4: çfarë ndryshon dhe me çfarë çmimi.....	82
5.8 Validimi mbi të dhëna reale.....	83
5.9 Rezultatet e studimit me përdorues.....	83
5.10 Analiza e gabimeve.....	84
6 DISKUTIME DHE PËRFUNDIME.....	87
6.1 Diskutimi i rezultateve.....	87
6.2 Asimetria e bazimit ndërmjet të dhënave të strukturuar dhe tekstit të lirë.....	88
6.3 Rregullat, klasifikuesi dhe gjykatësi LLM në verifikim.....	89
6.4 Përpunimi i gjuhës natyrore mjekësore për shqipen.....	90
6.5 Konsideratat e sigurisë dhe rregullatore.....	90
6.6 Kufizimet e punimit.....	91
6.7 Mundësitë për zhvillime të mëtejshme.....	94
6.8 Përfundimet.....	95
7 REFERENCAT.....	97
8 APPENDIXES.....	105
Shtojca A — Tabela e plotë terminologjike shqip.....	105
Shtojca B — Paneli i plotë i analiteve.....	107
Shtojca C — Katalogu i plotë i rregullave të verifikimit.....	110
Shtojca D — Kërkesat për modelin gjuhësor.....	111
D.2. Udhëzimet e gjeneruesit (kushtet B, C dhe D).....	111
D.3. Një kërkesë e vërtetë për një dokument të korpusit.....	112
D.4. Blloku i rigjenerimit.....	114
D.5. Kërkesa naive e kushtit A (E6).....	114
D.6. Gjykatësi i E12.....	114
Shtojca E — Udhëzimet e anotimit për dokumentet reale.....	115
Shtojca F — Instrumenti i studimit me përdorues.....	115

Shtojca G — Skema SQL e bazës së të dhënave.....	115
Shtojca H — Konfigurimet e eksperimenteve dhe farat fillestare.....	121
Shtojca I — Shembuj dokumentesh nga korpusi sintetik.....	122
Dokument dixhital (doc_00001.pdf).....	123
Dokument i skanuar (doc_00000.pdf).....	125

LISTA E FIGURAVE

Figura 1. Fazat kryesore të zhvillimit të sistemit ANALYTE.....	21
Figura 2. Arkitektura e përgjithshme e sistemit.....	23
Figura 3. Tubacioni i përpunimit të rezultateve laboratorike.....	26
Figura 4. Tubacioni i përpunimit të raportit mjekësor.....	31
Figura 5. Arkitektura e shtresës së verifikimit.....	34
Figura 6. Makina e gjendjeve e përpunimit të dokumentit.....	36
Figura 7. Ndërtimi i korpusit të korruptuar për trajnimin e klasifikuesit.....	38
Figura 8. Procesi i gjenerimit të korpusit sintetik.....	39
Figura 9. Struktura modulare e aplikacionit.....	43
Figura 10. Entity Relationship Diagram (ERD) i databazës.....	45
Figura 11. Tubacioni i vlerësimit dhe gjurmueshmëria e eksperimenteve.....	47
Figura 12. Faqja e autentikimit të sistemit.....	58
Figura 13. Hapat e përpunimit të dokumentit të ngarkuar, ndërsa ndodhin.....	59
Figura 14. Gjetjet laboratorike të strukturuar.....	60
Figura 15. Shpjegimi në gjuhë të thjeshtë me treguesin e verifikimit, dhe fjalët e mjekut të vendosura veçmas, fjalë për fjalë.....	61
Figura 16. Krahasimi i raportit mjekësor me rezultatet laboratorike.....	62
Figura 17. Matrica e konfuzionit për klasifikimin e statusit (E3, tërë korpusi, me OCR).....	64
Figura 18. Rezultatet e ablacionit të shtresës së verifikimit (Tabela 17).....	71
Figura 19. Matricat e konfuzionit për tre qasjet e detektimit.....	79
Figura 20. Llojet e shkeljeve: çfarë prodhon modeli dhe sa mirë zbulohen.....	80
Figura I.1. Faqja e parë e një dokumenti dixhital të korpusit sintetik.....	123
Figura I.2. Faqja e parë e një dokumenti të skanuar të korpusit sintetik.....	125

LISTA E TABELAVE

Tabela 1. Teknologjitë kryesore të përdorura në sistem.....	24
---	----

Tabela 2. Faktorët e konvertimit të njësive.....	27
Tabela 3. Paneli i analiteve dhe hartëzimi me kodet LOINC (ekstrakt).....	28
Tabela 4. Saktësia e nxjerrjes mbi kanalin e skanuar, sipas fushës (E2).....	29
Tabela 5. Ekstrakt nga tabela terminologjike shqip.....	32
Tabela 6. Katalogu i rregullave të verifikimit.....	35
Tabela 7. Matrica e eksperimenteve.....	48
Tabela 8. Përbërësit e sistemit dhe gjendja e tyre e matur.....	57
Tabela 9. Saktësia e nxjerrjes së të dhënave laboratorike (E1 dhe E2).....	62
Tabela 10. Saktësia e klasifikimit të statusit (E3, tërë korpusi, me OCR).....	63
Tabela 11. Matrica e konfuzionit të E3.....	63
Tabela 12. Saktësia e statusit sipas burimit të intervalit (E3).....	64
Tabela 13. Efekti i kontrollit të besueshmërisë së OCR-së mbi 168 dokumentet e skanuara...65	65
Tabela 14. Besnikëria e thjeshtimit (E4).....	65
Tabela 15. Saktësia e krahasimit të kryqëzuar (E5).....	66
Tabela 16. Dega B mbi fjalitë e grupit C.....	68
Tabela 17. Rezultatet e ablacionit të verifikimit (modeli gjuhësor.....	69
Tabela 18. Shkeljet e prodhuara nga modeli, sipas llojit (të gjitha përpjekjet.....	70
Tabela 19. Auditi i pavarur i 90 teksteve të gjeneruara që kaluan verifikimin e E8.....	72
Tabela 20. Problemet e gjetura nga auditi, sipas llojit.....	72
Tabela 21. Kushtet e ablacionit me r1.3 dhe me r1.4 bashkë me kontrollin e OCR-së.....	73
Tabela 22. Krahasimi i qasjeve të detektimit.....	75
Tabela 23. F1 sipas llojit të defektit, korpusi i korruptuar (192 mostra).....	76
Tabela 24. F1 sipas llojit të defektit, grupi B (105 mostra).....	76
Tabela 25. Detektimi sipas degës (A: laboratorike; B: narrative).....	77
Tabela 26. Katalogu r1.3 kundrejt r1.4 mbi të njëjtat mostra.....	82
Tabela 27. Taksonomia e gabimeve të vërejtura.....	84

Tabela A.1. Termat, shpjegimet, kategoritë dhe sinonimet.....	105
Tabela B.1. Paneli i analiteve dhe hartëzimi LOINC.....	107
Tabela B.2. Faktorët e konvertimit të njësive.....	109
Tabela B.3. Rregullat e kombinimit ndërmjet analiteve.....	109
Tabela C.1. Katalogu i rregullave të verifikimit.....	110
Tabela C.2. Një shembull i vërtetë për çdo rregull që korruptuesit e prodhojnë, me provën që jep rregulli.....	110
Tabela D.1. Parametrat e ekzekutimit.....	111
Tabela H.1. Korpusi sintetik.....	121
Tabela H.2. Versionet dhe parametrat fiks të sistemit.....	121
Tabela H.3. Rezultatet që ekzistojnë dhe prejardhja e tyre.....	121
Tabela H.4. Klasifikuesi XLM-RoBERTa (trajnuar në Colab) dhe pragjet e zgjedhura mbi validimin.....	122

FJALORI I TERMAVE

ALT – Alanine Aminotransferase

API – Application Programming Interface

AST – Aspartate Aminotransferase

CDSS – Clinical Decision Support System

ERD – Entity Relationship Diagram

F1-Score – Mesatarja harmonike e precision-it dhe recall-it

GDPR – General Data Protection Regulation

Grounding – Bazimi i daljes së gjeneruar në një burim të verifikueshëm

HbA1c – Hemoglobina e glikuar

Hallucination – Përmbajtje e gjeneruar që nuk mbështetet nga burimi

Hedging – Shprehje gjuhësore e pasigurisë klinike

JWT – JSON Web Token

LLM – Large Language Model

LOINC – Logical Observation Identifiers Names and Codes

MDR – Medical Device Regulation

NER – Named Entity Recognition

NLI – Natural Language Inference

NLP – Natural Language Processing

OCR – Optical Character Recognition

PK1–PK7 – Pyetjet kërkimore të këtij punimi

REST – Representational State Transfer

XLM-RoBERTa – Model enkoder shumëgjuhësh i paratrajnuar

1 HYRJE

Zhvillimi i shërbimeve elektronike shëndetësore ka ndryshuar rrënjësisht mënyrën se si pacientët kanë qasje në informacionin e tyre mjekësor. Rezultatet e analizave laboratorike, që dikur komunikoheshin ekskluzivisht përmes mjekut, sot i dorëzohen pacientit drejtpërdrejt në formë elektronike, shpesh brenda pak orësh nga kryerja e analizës dhe përpara se ai të ketë mundësi të flasë me një profesionist shëndetësor. Kjo qasje e drejtpërdrejtë konsiderohet përgjithësisht si përparim, sepse e vendos pacientin në qendër të procesit dhe e pajis atë me informacionin që i përket [11], [12].

Megjithatë, qasja në informacion nuk është e njëjta gjë me qasjen në kuptim. Një raport laboratorik është dokument teknik i hartuar për profesionistin shëndetësor. Ai përmban shkurtesa latine ose angleze, njësi matëse që ndryshojnë nga një laborator në tjetrin, dhe intervale referente të shtypura në mënyrë të tillë që marrëdhëniet e tyre me vlerën e matur nuk është gjithmonë e qartë për një lexues jo profesionist. Për pacientin, rezultati praktik është një dokument që e zotëron por nuk e kupton [8], [10].

Pasojat e kësaj situate nuk janë neutrale. Pacienti që nuk e kupton dokumentin e vet ose pret takimin e radhës me mjekun, duke shtyrë kuptimin për javë të tëra, ose kërkon shpjegim në burime të painformuara në internet, ku informacioni nuk është i përshtatur për rastin e tij konkret dhe shpesh është i pasaktë. Të dyja rrugët janë të dobëta: e para vonon informimin, e dyta e zëvendëson atë me përmbajtje të paverifikuar që mund të shkaktojë ankth të panevojshëm ose, në drejtimin e kundërt, qetësi të pajustificuar që e shtyn pacientin të mos kërkojë ndihmë kur duhet.

Zhvillimi i shpejtë i modeleve të mëdha gjuhësore gjatë viteve të fundit e ka bërë teknikisht të mundur zgjidhjen e këtij problemi. Këto modele janë jashtëzakonisht të afta në riformulimin e tekstit teknik në gjuhë të thjeshtë dhe në përshtatjen e nivelit të shpjegimit sipas lexuesit. Në parim, një sistem që merr një raport laboratorik dhe prodhon një shpjegim të kuptueshëm për pacientin është një aplikim i drejtpërdrejtë i teknologjisë ekzistuese.

Problemi qëndron në një veti të këtyre modeleve që në kontekstin mjekësor bëhet vendimtare. Modelet gjuhësore gjenerojnë tekst të rrjedhshëm edhe kur përmbajtja e tij nuk mbështetet nga burimi. Kjo dukuri, e njohur në literaturë si halucionacion, është përshkruar në mënyrë sistematike nga Ji et al. [3], të cilët dallojnë ndërmjet halucionacionit intrinsik, ku përmbajtja e gjeneruar kundërshton burimin, dhe halucionacionit ekstrinsik, ku përmbajtja nuk mund të

verifikohet nga burimi. Në shumicën e aplikimeve, një halucinacion përbën shqetësim për cilësinë e produktit. Në kontekstin e shpjegimit të një rezultati mjekësor, ai përbën rrezik.

Skenarët konkretë janë të thjeshtë për t'u imagjinuar dhe të rëndë për nga pasojat. Një sistem mund t'i thotë pacientit se një vlerë është brenda normës kur në fakt nuk është. Mund të përmendë një analizë që nuk është kryer fare, duke krijuar përshtypjen se një aspekt i shëndetit është kontrolluar kur nuk është. Mund ta kthejë një mohim të shprehur nga mjeku në pohim, duke e shndërruar një gjetje të përjashtuar në një gjetje të konfirmuar. Secili prej këtyre rasteve mund të ndikojë drejtpërdrejt në vendimin e pacientit për të kërkuar ose për të mos kërkuar ndihmë mjekësore.

Qasja më e zakonshme ndaj këtij problemi në praktikë është udhëzimi i modelit që të mos shpikë informacion. Ky punim nis nga premisa se një udhëzim i tillë nuk përbën mekanizëm sigurie. Ai mund ta ulë frekuencën e problemit, por nuk e eliminon dhe, më e rëndësishmja, nuk ofron asnjë mënyrë për të matur nëse është zbatuar. Nëse siguria e një sistemi mjekësor varet nga bindja e një modeli statistikor, ajo nuk është siguri por shpresë.

Punimi propozon një zgjidhje arkitekturore. Modeli gjuhësor nuk e sheh kurrë dokumentin e papërpunuar. Informacioni nxirret dhe interpretohet nga një shtresë deterministe që punon me rregulla të verifikueshme dhe jo me modele probabilistike. Modeli gjuhësor merr vetëm përfaqësimin e strukturuar që rezulton nga kjo shtresë dhe ngarkohet ekskluzivisht me formulimin gjuhësor. Pas gjenerimit, një shtresë e automatizuar verifikimi kontrollon në mënyrë mekanike nëse çdo pohim i tekstit të gjeneruar mbështetet nga përfaqësimi i strukturuar. Vetëm teksti që kalon këtë kontroll i shfaqet përdoruesit.

Parimi organizues i të gjithë sistemit mund të përmbliidhet në një fjali: modeli gjuhësor formulon gjuhën, por nuk përcakton faktet.

Kontributi kryesor i punimit nuk është ndërtimi i një aplikacioni web mjekësor, sepse sisteme të tilla ekzistojnë në numër të konsiderueshëm. Kontributi është shtresa e verifikimit dhe vlerësimi i saj sasior. Punimi mat sa shpesh modeli prodhon përmbajtje të pambështetur, sa e ul këtë verifikimi, dhe sa saktë e zbulon vetë verifikimi përmbajtjen problematike.

Një element i dytë, po aq i rëndësishëm, është krahasimi i drejtpërdrejtë i dy niveleve të bazimit. Arkitektura zbatohet njëkohësisht mbi të dhëna numerike të strukturuar, ku verifikimi mund të jetë i saktë, dhe mbi tekst klinik të lirë, ku ai mund të jetë vetëm semantik dhe rrjedhimisht i pasigurt. Ky ndryshim nuk fshihet por matet dhe raportohet, sepse ai përcakton se çfarë lloji garancie mund të japë realisht një sistem i tillë.

Së fundi, punimi zhvillohet për gjuhën shqipe. Për shqipen nuk ekziston asnjë model klinik i paratrajnuar i përpunimit të gjuhës natyrore i krahasueshëm me modelet e disponueshme për anglishten. Kjo mungesë nuk është detaj teknik por kufizim që përcakton arkitekturën e sistemit, dhe dokumentimi i pasojave të saj përbën kontribut më vete në një fushë ku literatura ekzistuese është pothuajse inekzistente.

Punimi organizohet si vijon. Kapitulli 2 shqyrton literaturën përkatëse mbi diagnostikën laboratorike, përpunimin e gjuhës natyrore në mjekësi, halucinacionet e modeleve gjuhësore dhe metodat e verifikimit. Kapitulli 3 formulon problemin dhe paraqet pyetjet kërkimore. Kapitulli 4 përshkruan metodologjinë, arkitekturën, implementimin dhe planin e vlerësimit. Kapitulli 5 paraqet rezultatet e matura. Kapitulli 6 i diskuton ato dhe nxjerr përfundimet e punimit.

2 SHQYRTIMI I LITERATURËS (HISTORIKU)

Ky kapitull vendos punimin në literaturën ekzistuese. Ai ndahet në shtatë pjesë: interpretimi i rezultateve laboratorike dhe komunikimi i tyre me pacientin (2.1), përpunimi i gjuhës natyrore në kontekst mjekësor (2.2), halucinacionet e modeleve të mëdha gjuhësore dhe bazimi (2.3), verifikimi i daljes së tyre (2.4), modelet shumëgjuhësh (2.5), teknologjitë e përdorura (2.6) dhe kuadri rregullator (2.7). Çdo burim i cituar është lexuar; aty ku literatura nuk ofron asgjë për shqipen, kjo thuhet si rezultat i një kërkimi të dokumentuar dhe jo si supozim.

2.1 Diagnostika laboratorike dhe interpretimi i rezultateve

2.1.1 Natyra e intervalit referent

Interpretimi i një vlere laboratorike nuk është veti e vetë vlerës por e marrëdhënies së saj me një interval referent. Ky interval përcaktohet nga secili laborator mbi bazën e metodës analitike që përdor dhe të popullatës referente që ka matur, dhe varet gjithashtu nga mosha dhe gjinia e personit. Udhëzuesi EP28-A3c i Institutit për Standardet Klinike dhe Laboratorike (CLSI) përshkruan procedurën me të cilën një laborator përcakton, vendos ose verifikon intervalet e veta referente, duke kërkuar së paku 120 individë referentë për një interval të ri dhe verifikim lokal për një interval të marrë nga prodhuesi [6]. Ozarda [5] përmbledh gjendjen e fushës dhe thekson se intervalet e besueshme janë themeli i interpretimit të rezultateve, se ato varen nga popullata dhe nga laboratori, dhe se studimet shumëqendrore janë mënyra e vetme për të marrë vlera referente të krahasueshme ndërmjet laboratorëve. Rrjedhimisht, i njëjti rezultat numerik mund të klasifikohet si normal në një laborator dhe si jashtë normës në një tjetër, pa asnjë gabim nga ana e asnjërit.

Kjo veti ka pasoja të drejtpërdrejta për dizajnin e çdo sistemi që synon të interpretojë automatikisht rezultate laboratorike. Një tabelë e ngurtë intervalesh të shkruar në kod prodhon në mënyrë të pashmangshme klasifikime të gabuara për dokumente që vijnë nga laboratorë me metoda të ndryshme. Zgjidhja e vetme e qëndrueshme është nxjerrja e intervalit nga vetë dokumenti sa herë që ai është i shtypur atje, dhe përdorimi i një tabele rezervë vetëm si zgjidhje e fundit, me regjistrim të qartë se cili burim është përdorur për secilën vlerë. Kjo është pikërisht rruga që ndjek seksioni 4.3.4.

2.1.2 Standardizimi terminologjik dhe LOINC

Një pengesë e dytë në përpunimin automatik të dokumenteve laboratorike është mungesa e uniformitetit në emërtimin e testeve. I njëjti analit mund të shfaqet si shkurtësë latine, si emërtim i plotë anglisht, si emërtim shqip, ose në një variant lokal specifik për laboratorin.

LOINC (Logical Observation Identifiers Names and Codes) është përgjigjja standarde ndaj kësaj situate. McDonald et al. [7] e përshkruajnë si një sistem kodesh të disponueshëm falas që i cakton çdo observimi laboratorik një kod dhe një emër formal, me qëllim që rezultatet të shkëmbehen dhe të arkivohen automatikisht ndërmjet institucioneve, dhe rekomandojnë që kodet LOINC të transmetohen bashkë me rezultatet në mesazhet HL7. Për sistemet automatike, LOINC funksionon si shtresë normalizimi që e zëvendëson një fjalor sinonimesh të improvizuar me një standard të dokumentuar dhe të citueshëm. Paneli i këtij punimi (Tabela 3, Shtojca B) hartëzohet në një nënbashkësi LOINC.

2.1.3 Komunikimi i rezultateve me pacientin

Rritja e qasjes së drejtpërdrejtë të pacientëve në rezultatet e tyre përmes portaleve elektronike ka krijuar një fushë të re problemesh që lidhen me kuptueshmërinë. Literatura mjekësore ka dokumentuar se disponueshmëria e informacionit nuk përkthehet automatikisht në kuptim.

Giardina et al. [8] intervistuan 95 përdorues të portaleve të pacientëve dhe gjetën se gati dy të tretat nuk kishin marrë asnjë shpjegim bashkë me rezultatet, se 46 përqind kërkuan në internet për t'i interpretuar, dhe se pacientët me rezultate jonormale raportuan më shumë emocione negative dhe më shumë kontakte me mjekun; autorët përfundojnë se qasja në portal nuk mjafton pa mbështetje për interpretimin. Zikmund-Fisher et al. [9], në një eksperiment në internet me 1 620 të rritur, treguan se me paraqitjen e zakonshme tabelare shumica e pjesëmarrësve e vlerësuan njësoj të ngutshme një vlerë lehtësisht jonormale dhe një vlerë rëndë jonormale të ALT, dhe se vetëm paraqitja grafike e vlerës mbi intervalin e përmirësoi dallimin. Fraccaro et al. [10], me një studim të gjurmimit të syve mbi tri faqesje portali, gjetën se 65 përqind e pjesëmarrësve e nënvlerësuan së paku një herë nevojën për veprim dhe se saktësia e interpretimit mbeti ndërmjet 0.45 dhe 0.55 pavarësisht nga dizajni. Steitz et al. [11], në një anketë me 8 139 pacientë pas zbatimit të ligjit amerikan që kërkon dorëzimin e menjëhershëm të rezultateve, gjetën se 95.7 përqind preferonin t'i merrnin rezultatet menjëherë, por 16.5 përqind e atyre me rezultat jonormal raportuan shqetësim të shtuar nga leximi i rezultatit përpara kontaktit me mjekun. Pillemer et al. [12] vërejtën të njëjtën dyzim: pacientët e vlerësonin shumë dorëzimin e drejtpërdrejtë, por rezultatet jonormale ose të

vështira për t'u interpretuar shoqëroheshin me ankth dhe me rritje të vizitave dhe telefonatave, rritje që ishte më e vogël kur mjeku e dorëzonte rezultatin bashkë me një interpretim.

Këto studime mbështesin dy premisa të këtij punimi. Së pari, hendeku ndërmjet qasjes dhe kuptimit është i matur dhe jo i supozuar. Së dyti, ajo që ndihmon nuk është vetëm riformulimi gjuhësor por vendosja e vlerës në raport me intervalin dhe dallimi i devijimit të lehtë nga ai i rëndë, pikërisht ajo që shtresa deterministe e këtij punimi llogarit përpara se të përfshihet modeli gjuhësor (seksioni 4.3.5).

2.2 Përpunimi i gjuhës natyrore në kontekst mjekësor

2.2.1 Nxjerrja e informacionit klinik

Nxjerrja e informacionit të strukturuar nga tekstet klinike është një nga drejtimet më të vjetra të përpunimit të gjuhës natyrore në mjekësi. Sistemet e hershme bazoheshin tërësisht në fjalorë terminologjike dhe rregulla të shkruara manualisht: MedLEE i Friedman et al. [13] analizonte raportet radiologjike me një gramatikë semantike të ndërtuar me dorë dhe i hartëzonte frazat në një fjalor të kontrolluar, duke arritur 70 përqind mbulim dhe 87 përqind saktësi mbi 230 raporte. cTAKES i Savova et al. [14] e vazhdoi këtë traditë si tubacion modular me burim të hapur, ku njohja e entiteteve bëhet me kërkim në fjalor kundrejt UMLS. Wang et al. [15] shqyrtuan 263 artikuj të nxjerrjes së informacionit klinik ndërmjet viteve 2009 dhe 2016 dhe katalogojnë mjetet, metodat dhe aplikimet e fushës. Fu et al. [16], në një shqyrtim metodologjik të 219 studimeve të nxjerrjes së koncepteve klinike ndërmjet viteve 2009 dhe 2019, gjetën se sistemet me rregulla mbeteshin qasja më e përdorur (46 përqind), përpara atyre hibride (23 përqind), të mësimit makinerik klasik (22 përqind) dhe të mësimit të thellë (8 përqind), dhe se në mjediset klinike jashtë detyrave të përbashkëta pjesa e tyre arrinte 51 përqind.

Rëndësia e kësaj literature për punimin aktual qëndron në një vërejtje metodologjike: sistemet e bazuara në rregulla mbeten konkurruese kur fusha e problemit është e ngushtë dhe e përcaktuar mirë, dhe kanë përparësinë vendimtare se janë plotësisht të shpjgueshme dhe të auditueshme. Modelet neuronale të paratrajnuara mbi korpuset klinike, si BioBERT [17] dhe ClinicalBERT [18], i tejkalojnë ato në detyra të gjera, por ekzistojnë vetëm për anglishten (seksioni 2.2.4).

2.2.2 Zbulimi i mohimit

Mohimi përbën një problem qendror në përpunimin e teksteve klinike, sepse një gjetje e pohuar dhe një gjetje e mohuar kanë kuptime krejtësisht të kundërta ndërsa ndajnë pothuajse të njëjtat fjalë përmbajtësore. Një sistem që injoron mohimin nuk prodhon një gabim të vogël por një gabim të përmbysur.

Chapman et al. [1] propozuan algoritmin NegEx, i cili identifikon frazat mohuese përmes shprehjeve të rregullta, filtron rastet ku një frazë duket mohuese pa qenë e tillë, dhe kufizon fushëveprimin e mohimit brenda një distance të caktuar nga fraza. Në një test me 1235 gjetje dhe sëmundje të shpërndara në 1000 fjali nga epikrizat, algoritmi arriti specificitet prej 94.5 përqind dhe vlerë parashikuese pozitive prej 84.5 përqind, duke ruajtur një ndjeshmëri prej 77.8 përqind [1].

Harkema et al. [2] e zgjeruan këtë qasje me algoritmin ConText, i cili përcakton jo vetëm nëse një gjetje është e mohuar, por edhe kush është përjetuesi i saj dhe cili është statusi i saj kohor.

Rëndësia e këtyre dy punimeve për ANALYTE është e dyfishtë. Së pari, ato tregojnë se një qasje e bazuar në rregulla, relativisht e thjeshtë dhe e vlerësuar mirë, është e mjaftueshme për zbulimin e mohimit në tekste klinike. Së dyti, dhe më rëndësishëm për kontekstin e këtij punimi, kjo qasje nuk varet nga ekzistenca e një modeli neuronal të paratrajnuar për gjuhën konkrete, gjë që e bën atë të zbatueshme për shqipen.

2.2.3 Thjeshtimi i teksteve mjekësore

Thjeshtimi i tekstit mjekësor për lexues jo profesionistë është fushë e veçantë kërkimore me metrika dhe sfida të vetat. Ondov et al. [19] shqyrtojnë 45 punime mbi thjeshtimin automatik të teksteve biomjekësore në shtatë gjuhë dhe gjejnë se metodat procedurale ende i tejkalojnë në numër ato neuronale, sepse të dhënat paralele janë të pakta. Devaraj et al. [21] ndërtuan një korpus paralel përmbledhjesh teknike dhe në gjuhë të thjeshtë nga Cochrane dhe propozuan modele thjeshtimi në nivel paragrafi; Trienes et al. [22] bënë të njëjtën gjë për raportet patologjike gjermane, duke theksuar mungesën e burimeve si pengesën kryesore të fushës.

Problemi qendror i fushës është se thjeshtimi dhe besnikëria janë në tension. Devaraj et al. [20] propozuan një taksonomi të gabimeve faktike në thjeshtim, me tri klasa: futje (informacion që nuk gjendet në tekstin e ndërlikuar shtohet ose halucinohet në atë të thjeshtuar), heqje (informacion i tekstit burimor humbet) dhe zëvendësim (informacioni ndryshohet ashtu që ndryshon kuptimi). Ata treguan se gabime të tilla ndodhin si në

thjeshtimet referente ashtu edhe në daljet e modeleve, se metrikat ekzistuese nuk i zbulojnë, dhe paralajmëruan se një tekst më i lexueshëm por i pasaktë mund të jetë në shumë raste më i keq se mungesa e plotë e qasjes. Tri klasat e tyre korrespondojnë drejtpërdrejt me llojet e shkeljeve që ky punim mat te dega narrative: gjetja e shpikur është futje, rekomandimi i humbur është heqje, dhe kthimi i mohimit ose heqja e rezervës është zëvendësim (seksioni 4.5).

Me modelet e mëdha gjuhësore tensioni është matur drejtpërdrejt mbi tekst mjekësor. Jeblick et al. [23] ua dhanë 15 radiologëve 45 raporte radiologjike të thjeshtuara nga ChatGPT: megjithëse shumica i gjetën përgjithësisht të sakta, ata shënuan pasazhe të gabuara në 23 nga 45 raporte, informacion të munguar në 10 dhe përfundime potencialisht të dëmshme në 16, përfshirë halucinacione si «asnjë shenjë kanceri». Amin et al. [24] krahasuan ChatGPT, Bard dhe Bing mbi 150 raporte dhe gjetën se recensuesit pajtoheshin fort që dalja nuk përmbante informacion të pasaktë vetëm në 75 deri 86 përqind të rasteve. Zaretsky et al. [25] transformuan 50 epikriza me GPT-4 në gjuhë të përshtatshme për pacientin: lexueshmëria u përmirësua ndjeshëm, por mjekët i vlerësuan si plotësisht të plota vetëm 56 nga 100 recensione dhe shënuan shqetësime sigurie për mungesa dhe pasaktësi në 18 prej tyre. Dy punime janë veçanërisht të afërta me këtë punim. Cadamuro et al. [26], në emër të grupit të punës për inteligjencën artificiale të Federatës Evropiane të Kimisë Klinike dhe Mjekësisë Laboratorike, i dhanë ChatGPT dhjetë raporte laboratorike të simuluar: modeli i njohu të gjitha testet dhe i shënoi devijimet nga intervali referent, por interpretimet ishin sipërfaqësore, jo gjithmonë të sakta dhe i jepnin pak peshë madhësisë së devijimit. He et al. [27] vlerësuan përgjigjet e GPT-4 dhe të modeleve të tjera ndaj 53 pyetjesh reale pacientësh mbi rezultate laboratorike dhe gjetën se GPT-4 i tejkalonte si modelet e tjera ashtu edhe përgjigjet e përdoruesve të tjerë, por jepte ende interpretime të pasakta ose të përgjithësuara, pa individualizim dhe pa referenca.

Dy mësimet dalin për këtë punim. Së pari, gabimi tipik i modelit mbi tekst mjekësor nuk është pakuptueshmëria por pasaktësia e rrjedhshme, dhe ai zbulohet vetëm nga një rishikim i kujdesshëm i përmbajtjes kundrejt burimit. Së dyti, asnjë nga këto studime nuk e vendos modelin pas një shtrese që i heq atij autoritetin mbi faktet; të gjitha i japin modelit dokumentin e papërpunuar. Pikërisht kjo është ndarja që ky punim e bën dhe e mat.

2.2.4 Gjuhët me burime të pakta

Modelet klinike të paratrajnuara ekzistojnë praktikisht vetëm për anglishten. Névéol et al. [28] dokumentojnë se anglishtja është me shumë larg gjuha më e pasur me burime për përpunimin e gjuhës natyrore klinike: UMLS i vitit 2016 përmbante 9.1 milion terma anglisht kundrejt 1.3 milion spanjisht dhe më pak se 5 përqind të numrit anglisht për të gjitha gjuhët e tjera, dhe për asnjë gjuhë tjetër nuk ekzistonte një korpus klinik i ndashëm i krahasueshëm me i2b2. BioBERT [17] dhe ClinicalBERT [18] janë paratrajnuar përkatësisht mbi literaturën biomjekësore dhe mbi shënimet klinike MIMIC-III, të dyja në anglisht.

Për shqipen situata është më e theksuar. Një kërkim i kryer më 6 tetor 2026 në bazat bibliografike dhe në motorët e kërkimit, me pyetjet «Albanian clinical NLP», «Albanian biomedical corpus», «Albanian medical text processing» dhe «gjuha shqipe përpunimi i gjuhës natyrore tekste mjekësore», nuk gjeti asnjë punim të recensuar mbi përpunimin e teksteve klinike shqip dhe asnjë korpus klinik ose biomjekësor shqip. Shqyrtimi i gjendjes së përpunimit të gjuhës natyrore për shqipen nga Kastrati dhe Biba [29] gjen se kërkimi për shqipen është ende i kufizuar dhe nuk përmend asnjë punim klinik ose biomjekësor. Burimet e përgjithshme ekzistojnë: Kote et al. [30] publikuan korpusin më të madh deri tani për njohjen e entiteteve të emëruara në shqip, me rreth një milion shenja nga lajmet dhe dhjetë lloje entitetesh. E vetmja punë në fushën mjekësore është një sistem sinteze të të folurit shqip për përkthyesin mjekësor BabelDr [31], që nuk përpunon tekst klinik. Mungesa e një modeli klinik shqip nuk është pra supozim por rezultat i dokumentuar i kërkimit.

Kjo mungesë ka pasojë të drejtpërdrejtë arkitekturore. Komponentët që në një sistem anglisht do të realizoheshin me një model klinik të specializuar duhet të realizohen ndryshe: me fjalorë dhe rregulla aty ku problemi është i vendosshëm, dhe me enkoderë shumëgjuhësh të përgjithshëm aty ku nuk është. Ky punim e trajton këtë kufizim jo si mangësi që duhet fshehur, por si kusht i projektimit që duhet dokumentuar.

2.3 Modelet e mëdha gjuhësore dhe halucionet

2.3.1 Përkufizimi dhe tipologjia

Ji et al. [3] ofrojnë një shqyrtim gjithëpërfshirës të problemit të halucionit në gjenerimin e gjuhës natyrore, duke mbuluar përkufizimin, kategorizimin, shkaktarët, metrikat e matjes dhe metodat e zbutjes. Dallimi që ata vendosin ndërmjet halucionit intrinsik dhe atij ekstrinsik, i përdorur më parë nga Maynez et al. [32] për përmbledhjen abstraktive, hartëzohet

drejtpërdrejt në kategoritë e shkeljeve që ky punim përcakton dhe mat. Një pohim që kundërshton statusin e strukturuar të një analiti është halucinacion intrinsik; përmendja e një analiti që nuk është matur fare është halucinacion ekstrinsik. Maynez et al. [32] treguan me vlerësim njerëzor se të gjitha sistemet neuronale të përmbledhjes që testuan prodhonin sasi të konsiderueshme përmbajtjeje të pambështetur nga burimi, dhe se masat e bazuara në implikimin tekstual korrelojnë më mirë me besnikërinë sesa metrikat standarde; ky është një nga motivimet e hershme për verifikimin me NLI të seksionit 2.4.1.

Për modelet e mëdha gjuhësore të brezit të fundit, Huang et al. [33] propozojnë një taksonomi të halucinacioneve, i ndajnë shkaqet në ato të lidhura me të dhënat, me trajnimin dhe me inferencën, dhe shqyrtojnë metodat e zbulimit dhe të zbutjes, përfshirë kufijtë e gjenerimit të shtuar me kërkim. Në fushën mjekësore, Singhal et al. [34] gjetën se një model i madh i përgjithshëm arrinte 67.6 përqind në pyetjet e provimit mjekësor amerikan, por se vetëm 61.9 përqind e përgjigjeve të tij pajtoheshin me konsensusin shkencor kundrejt 92.9 përqind për klinikistët, dhe se 29.7 përqind u gjykuan potencialisht të dëmshme. Thirunavukarasu et al. [35] rendisin halucinacionin, kufirin e njohurive, njëanshmërinë dhe mungesën e validimit si pengesat kryesore për përdorimin klinik. Tang et al. [36] vlerësuan përmbledhjet e evidencës mjekësore nga GPT-3.5 dhe ChatGPT në gjashtë fusha klinike dhe gjetën mospërputhje faktike dhe siguri mashtruese, me tri lloje gabimesh: keqinterpretim, fabrikim dhe gabim atributi.

2.3.2 Shkaqet

Literatura identifikon disa burime të dallueshme të halucinacionit, që shtrihen nga cilësia e të dhënave të trajnimit deri te vetë procesi i dekodimit gjatë gjenerimit [3], [33]. Për qëllimet e këtij punimi, vërejtja thelbësore është se asnjë nga këto shkaqe nuk eliminohet përmes udhëzimit në prompt. Halucinacioni është veti strukturore e mënyrës si funksionojnë këto modele dhe jo dështim i rastësishëm që mund të korrigjohet me formulim më të mirë të kërkesës. Studimet e seksionit 2.2.3 e ilustronjë këtë: modelet që u udhëzuan të thjeshtojnë raporte mjekësore prodhuan megjithatë pohime të gabuara ose të dëmshme në një pjesë të konsiderueshme të rasteve [23], [24], [25].

Ky konstatim është arsyeja pse punimi trajton verifikimin si mekanizëm të veçantë dhe të pavarur nga gjenerimi, dhe jo si përmirësim të tij.

2.3.3 Bazimi

Bazimi është praktika e kufizimit të gjenerimit në një burim të verifikueshëm. Format e tij janë të ndryshme, nga futja e dokumentit burimor në kontekst deri te arkitekturat që kombinojnë kërkimin me gjenerimin. Lewis et al. [37] propozuan gjenerimin e shtuar me kërkim (RAG), ku një model gjenerues merr pasazhe të marra nga një indeks i jashtëm dhe prodhon gjuhë më specifike dhe më faktike se një model që mbështetet vetëm te parametrat e vet. Shuster et al. [38] treguan se kërkimi i integruar e ul ndjeshëm halucionin në dialogun e bazuar në njohuri; abstrakti i tyre flet për ulje, jo për eliminim, dhe Huang et al. [33] përmbledhin kufijtë e qasjes.

Më afër këtij punimi qëndron gjenerimi nga të dhëna të strukturuar. Parikh et al. [39] ndërtuan ToTTo, një bashkësi të dhënash prej 120 mijë shembujsh për gjenerimin e tekstit nga tabela me qeliza të theksuara, dhe gjetën se modelet ekzistuese shpesh halucinojnë fraza që tabela nuk i mbështet, edhe kur hyrja është plotësisht e strukturuar. Dušek dhe Kasner [40] e kthyen këtë vërejtje në metodë verifikimi: ata i kthejnë të dhënat e strukturuar në fjali me shabllone të thjeshta dhe përdorin një model NLI për të kontrolluar implikimin në të dy drejtimet ndërmjet hyrjes dhe daljes, duke zbuluar mungesat dhe halucionet me saktësi të lartë.

Ky punim zbaton një formë të rreptë të bazimit, ku modeli nuk merr fare dokumentin burimor por vetëm një objekt të strukturuar të prodhuar nga shtresa deterministe. Dallimi është thelbësor: në bazimin e zakonshëm, modeli mund të interpretojë gabim burimin; në bazimin e rreptë, interpretimi është kryer tashmë përpara se modeli të përfshihet. Rezultati i ToTTo [39] paralajmëron megjithatë se struktura e hyrjes nuk e eliminon halucionin, dhe kjo është arsyeja pse bazimi i rreptë shoqërohet këtu me verifikim.

2.4 Verifikimi i daljes së modeleve gjuhësore

2.4.1 Natural Language Inference si bazë verifikimi

Natural Language Inference (NLI), detyra e klasifikimit të marrëdhënies ndërmjet një premise dhe një hipoteze si implikim, kundërshti ose neutralitet [41], është korniza e natyrshme formale për pyetjen nëse një pohim mbështetet nga një burim.

Laban et al. [4] rishikojnë përdorimin e modeleve NLI për zbulimin e mospërputhjeve faktike dhe konstatojnë se punimet e mëparshme kishin dështuar për shkak të një mospërputhjeje granulariteti: dataset-et NLI janë ndërtuar në nivel fjalie, ndërsa zbulimi i mospërputhjeve

zbatohet në nivel dokumenti. Ata propozojnë metodën SummaCConv, e cila e zgjidh këtë duke segmentuar dokumentin në njësi fjali dhe duke agreguar rezultatet ndërmjet çifteve të fjalive [4]. Mbi benchmark-un SummaC, të përbërë nga gjashtë dataset-e zbulimi mospërputhjeje, metoda arrin saktësi të balancuar prej 74.4 përqind [4]. Honovich et al. [43] standardizuan njëmbëdhjetë bashkësi të dhënash të qëndrueshmërisë faktike në benchmark-un TRUE dhe gjetën se qasjet me NLI në shkallë të madhe dhe ato me gjenerim e përgjigje pyetjesh japin rezultatet më të forta dhe plotësuese. Kryscinski et al. [42] trajnuan një kontrollues qëndrueshmërie (FactCC) mbi të dhëna sintetike të prodhuara me transformime me rregulla të tekstit burimor; ideja e tyre, që defektet futen me rregulla të njohura dhe etiketa caktohet automatikisht, është e njëjta me ndërtimin e korpusit të korruptuar të seksionit 4.7.

Këto rezultate kanë rëndësi të dyfishtë për punimin aktual. Së pari, ato konfirmojnë se qasja e bazuar në NLI për verifikimin e mbështetjes është e vlefshme dhe e vlerësuar. Së dyti, dhe më rëndësishëm, shifra prej rreth 74 përqind saktësi të balancuar tregon se verifikimi semantik mbi tekst të lirë mbetet dukshëm larg përsosmërisë edhe në gjendjen aktuale të teknikës. Ky është pikërisht kufizimi që ky punim e mat drejtpërdrejt përmes krahasimit të dy degëve të sistemit.

2.4.2 Metoda të tjera detektimi

Literatura përmban gjithashtu qasje që nuk mbështeten në një burim të jashtëm por në qëndrueshmërinë e brendshme të gjenerimeve të shumta. Manakul et al. [44] propozuan SelfCheckGPT, që zbulon halucionet pa qasje te brendësia e modelit dhe pa burim të jashtëm, duke marrë disa përgjigje për të njëjtën kërkesë dhe duke matur sa pajtohen ato ndërmjet tyre, me premisën se faktet e njohura prodhojnë mostra të qëndrueshme ndërsa ato të shpikura divergojnë. Min et al. [45] propozuan FActScore, që e zbërthen një tekst të gjatë në fakte atomike dhe mat pjesën e tyre që mbështetet nga një burim i besueshëm; me vlerësim njerëzor ata gjetën se ChatGPT arrinte vetëm 58 përqind të biografisë. Li et al. [46] ndërtuan HaluEval, një benchmark me mostra halucionesh të gjeneruara dhe të anotuara nga njerëzit, dhe gjetën se ChatGPT halucionon në rreth 19.5 përqind të pyetjeve dhe se modelet ekzistuese e kanë të vështirë t'i njohin halucionet.

Një familje e tretë përdor vetë modelin e madh gjuhësor si gjykatës. Zheng et al. [47] treguan se gjykatës të fortë si GPT-4 arrijnë mbi 80 përqind pajtueshmëri me preferencat njerëzore, sa pajtueshmëria ndërmjet njerëzve, por vuajnë nga njëanshmëri të pozicionit, të gjatësisë dhe të vetëvlerësimit. Liu et al. [48] propozuan G-Eval, që përdor GPT-4 me zinxhir arsyetimi për të

vlerësuar tekste të gjeneruara, dhe vërejtën se vlerësuesi mund të anojë nga teksti i gjeneruar nga modele. Panickssery et al. [49] treguan se modelet mund t'i njohin daljet e veta dhe se kjo aftësi lidhet drejtpërdrejt me preferencën ndaj tyre kur veprojnë si vlerësues. Këto tri punime përcaktojnë kufijtë e eksperimentit E12 të këtij punimi, ku gjykatësi është një model që nuk është i pavarur nga ndërtuesi i sistemit (seksioni 5.7.2).

2.4.3 Pozicionimi i këtij punimi

Dallimi kryesor i ANALYTE nga literatura e mësipërme qëndron në natyrën e premisë. Në punimet e cituara, premisa është tekst dhe verifikimi është rrjedhimisht detyrë semantike me normë gabimi të pashmangshme. Në degën e rezultateve laboratorike të ANALYTE, premisa nuk është tekst por një objekt i strukturuar me vlera numerike të njohura dhe statuse të përcaktuara në mënyrë deterministe. Pyetja nëse një numër mbështetet nga burimi ka përgjigje të vendosshme, dhe verifikimi bëhet krahasim dhe jo gjykim. Dušek dhe Kasner [40] e kanë vendosur NLI-në edhe mbi hyrje të strukturuar; ky punim shkon një hap më tej dhe e zëvendëson gjykimin me krahasim kudo ku struktura e lejon.

Për degën e tekstit të lirë punimi trajnon një klasifikues të llojit të shkeljes mbi një enkoder shumëgjuhësh; formulimi NLI është motivimi dhe pika e krahasimit në literaturë, jo detyra e zbatuar (seksioni 4.7). Kjo ndarje e qëllimshme i dy regjimeve, dhe matja e ndryshimit ndërmjet tyre, është ajo që punimi e paraqet si kontribut.

2.5 Modelet shumëgjuhësh

Meqë modelet klinike të specializuara mbulojnë vetëm anglishten, komponenti neuronal i këtij sistemi duhet të mbështetet në një enkoder shumëgjuhësh të përgjithshëm. Arkitektura e enkoderëve të paratrajnuar me maskim, e vendosur nga BERT [50], mund të përshtatet me një shtresë të vetme shtesë për detyra klasifikimi. XLM-RoBERTa i Conneau et al. [51] është paratrajnuar mbi 100 gjuhë me më shumë se dy terabajt tekst të filtruar nga CommonCrawl (korpora CC-100), dhe i tejkalon dukshëm modelet shumëgjuhëshe të mëparshme në inferencën ndërgjuhësore, në përgjigjen e pyetjeve dhe në njohjen e entiteteve, veçanërisht për gjuhët me burime të pakta. Shqipja është ndër 100 gjuhët e korpusit të tij, me rreth 918 milion shenja [51]. Kjo është arsyeja pse ai zgjidhet si model bazë për klasifikuesin e verifikimit (seksioni 4.7); zgjedhja nuk krahasohet eksperimentalisht me enkoderë të tjerë.

2.6 Teknologjitë e përdorura

Sistemi është ndërtuar me teknologji të hapura të zakonshme, të zgjedhura që çdo hap të jetë i riprodhueshëm dhe i testueshëm; përdorimi i tyre përmbledhet te Tabela 1. Shërbimi është shkruar në Python me FastAPI. Modelet e domenit janë objekte të pandryshueshme Pydantic, dhe numrat dhjetorë ruhen si Decimal, që krahasimi i saktë i verifikimit të mos ndikohet nga rrumbullakimi binar. Të dhënat ruhen në PostgreSQL përmes SQLAlchemy me migrime Alembic, dhe punët e përpunimit ekzekutohen në sfond me arq mbi Redis. Teksti dhe koordinatat e fjalëve nga PDF-të lexohen me PyMuPDF, dhe dokumentet e skanuara kalojnë përmes Tesseract, motorit të njohjes optike me burim të hapur, arkitektura e të cilit (gjetja e rreshtave, klasifikuesi adaptiv, trajtimi i faqeve të pjerrëta) përshkruhet nga Smith [52]. Ndikimi i gabimeve të njohjes optike mbi përpunimin e mëpasshëm të gjuhës është i dokumentuar: van Strien et al. [53] treguan se cilësia e OCR-së i degradon vazhdimisht detyrat që ndërtohen mbi tekstin e njohur, nga segmentimi i fjalive deri te njohja e entiteteve, dhe seksioni 5.2 e mat të njëjtin efekt mbi nxjerrjen e vlerave laboratorike. Komponenti neuronal është XLM-RoBERTa [51], i trajnuar me PyTorch dhe Transformers në Google Colab. Ndërfaqja është aplikacion Next.js me React dhe TypeScript, me tipe të gjeneruara nga skema OpenAPI e shërbimit. Hyrja përdor Argon2id për fjalëkalimet dhe tokenë JWT me seanca të revokueshme, dhe llogaria aktivizohet me një lidhje të dërguar me SMTP (në zhvillim, kutia e provës e Mailtrap). Nuk përdoret spaCy: njohja e termave, e mohimit dhe e pasigurisë bëhet me fjalorë dhe rregulla leksikore të shkruara për këtë punim (seksioni 4.4). Figurat strukturore të punimit gjenerohen nga kodi me matplotlib.

2.7 Aspektet rregullatore dhe etike

2.7.1 Kualifikimi si pajisje mjekësore

Sipas Rregullores (BE) 2017/745 për pajisjet mjekësore [54], softueri i destinuar të japë informacion që përdoret për vendime me qëllim diagnostik ose terapeutik klasifikohet sipas Rregullit 11 të Aneksit VIII së paku në klasën IIa, dhe në klasën IIb ose III kur vendimet e gabuara mund të shkaktojnë përkeqësim të rëndë ose të pakthyeshëm të shëndetit; çdo softuer tjetër hyn në klasën I. Dokumenti udhëzues MDCG 2019-11 i Grupit Koordinues për Pajisjet Mjekësore [55], i rishikuar në qershor 2025, trajton në detaje se kur një softuer kualifikohet si pajisje mjekësore dhe si zbatohet Rregulli 11.

ANALYTE pozicionohet qëllimisht jashtë kësaj kategorie. Sistemi shpjegon në gjuhë të thjeshtë rezultatet e vetë pacientit dhe refuzon në mënyrë sistematike çdo pohim diagnostik,

terapeutik ose prognostik. Ky punim megjithatë nuk pretendon se ky pozicionim e vendos sistemin përfundimisht jashtë fushës së rregullores, sepse kufiri ndërmjet informacionit shpjegues dhe informacionit që përdoret për vendimmarrje klinike nuk është i mprehtë dhe varet nga përdorimi real.

2.7.2 Akti Evropian për Inteligjencën Artificiale

Rregullorja (BE) 2024/1689, Akti për Inteligjencën Artificiale [56], hyri në fuqi më 1 gusht 2024 dhe zbatohet në përgjithësi nga 2 gushti 2026. Neni 50 i saj përmban detyrimet e transparencës: sistemet që ndërveprojnë drejtpërdrejt me persona fizikë duhet të projektohen ashtu që personat të informohen se po ndërveprojnë me një sistem të inteligjencës artificiale, dhe përmbajtja e gjeneruar artificialisht duhet të shpaloset si e tillë.

Kuadri ka pësuar ndryshime së fundmi. Rregullorja (BE) 2026/1744, e njohur si «Digital Omnibus on AI» [57], u publikua në Gazetën Zyrtare më 24 korrik 2026 dhe hyri në fuqi më 27 korrik 2026. Ajo ndryshon Nenin 113 të Aktit dhe e shtyn zbatimin e detyrimeve për sistemet me rrezik të lartë të pavarura sipas Aneksit III deri më 2 dhjetor 2027, ndërsa për sistemet e integruara në produkte të rregulluara sipas Aneksit I afati shtyhet deri më 2 gusht 2028. Detyrimet e transparencës sipas Nenit 50 nuk u shtynë dhe zbatohen që nga 2 gushti 2026, me një periudhë kalimtare katërmujore vetëm për shënimin e lexueshëm nga makina të përmbajtjes së gjeneruar nga sisteme të vendosura në treg para asaj date.

Pasoja praktike për një sistem si ANALYTE është se detyrimet e transparencës, përfshirë shpalosjen se përmbajtja është gjeneruar nga inteligjenca artificiale, janë tashmë të zbatueshme, ndërsa regjimi më i rëndë për sistemet me rrezik të lartë hyn në fuqi më vonë. Sistemi e zbaton detyrimin e transparencës me shënimin e përhershëm se teksti është gjeneruar nga një model dhe se sistemi nuk zëvendëson vlerësimin e profesionistit shëndetësor (seksioni 4.12).

2.7.3 Mbrojtja e të dhënave

Të dhënat shëndetësore klasifikohen si kategori e veçantë e të dhënave personale sipas Nenit 9 të Rregullores së Përgjithshme për Mbrojtjen e të Dhënave [58], përpunimi i të cilave është i ndaluar si rregull dhe lejohet vetëm me bazë ligjore specifike dhe masa mbrojtëse shtesë. Ligji i Kosovës Nr. 06/L-082 për Mbrojtjen e të Dhënave Personale [59] e pasqyron këtë kuadër: Neni 8 i tij i trajton të dhënat në lidhje me shëndetin si kategori të veçantë me të njëjtin

ndalim si rregull, dhe Neni 3 i përkufizon ato si të dhëna personale që lidhen me shëndetin fizik ose mendor të personit, përfshirë ofrimin e shërbimeve shëndetësore.

Për një sistem që dërgon përmbajtjen e dokumenteve mjekësore te një ofrues i jashtëm i modeleve gjuhësore, ky ofrues merr statusin e përpunuesit dhe transferimi mund të përbëjë transferim ndërkombëtar të të dhënave shëndetësore. Një alternativë që e shmang plotësisht këtë problem është vendosja lokale e një modeli me peshë të hapur, e cila mbetet e pamatur në kuadër të këtij punimi (seksioni 6.7). Kontrollat teknike që sistemi zbaton për këtë rrezik përshkruhen te seksioni 4.12; baza ligjore dhe miratimi etik mbeten vendime jashtë sistemit.

3 DEKLARIMI I PROBLEMIT

Në kujdesin shëndetësor bashkëkohor, pacienti ka gjithnjë e më shumë qasje të drejtpërdrejtë në dokumentet e veta mjekësore, por kjo qasje nuk shoqërohet me mjete që e bëjnë informacionin të kuptueshëm. Një raport laboratorik i dorëzuar elektronikisht përmban të dhëna të sakta dhe të plota, të hartuara sipas konventave profesionale, por i drejtohet një lexuesi me formim mjekësor. Pacienti që e merr këtë dokument ndodhet në pozitën e pazakontë të zotërimit të informacionit pa mundësinë e përdorimit të tij.

Problemi nuk zgjidhet me rritjen e mëtejshme të transparencës apo me qasje më të gjerë në të dhëna, sepse pengesa nuk është disponueshmëria por interpretueshmëria. Zgjidhja kërkon një shtresë ndërmjetëse që e përkthen informacionin teknik në gjuhë të kuptueshme pa e ndryshuar përmbajtjen e tij.

Modelet e mëdha gjuhësore e ofrojnë këtë aftësi përkthimi në një nivel që deri para pak vitesh nuk ishte i mundur. Megjithatë, përdorimi i tyre në këtë rol krijon një problem të dytë, i cili në kontekstin mjekësor është më i rëndë se problemi fillestar. Këto modele prodhojnë tekst të rrjedhshëm dhe bindës edhe kur përmbajtja e tij nuk mbështetet nga dokumenti burimor. Rrjedhshmëria e daljes nuk lidhet me saktësinë e saj, dhe pikërisht kjo mospërputhje e bën problemin të rrezikshëm: një pohim i gabuar nuk duket i gabuar.

Mënyrat kritike të dështimit ndryshojnë në varësi të llojit të burimit, dhe ky dallim është themelor për strukturën e punimit.

Kur burimi është një tabelë vlerash laboratorike, dështimet kryesore janë shpikja e një vlere që nuk gjendet në dokument, përmendja e një analiti që nuk është matur, kthimi i drejtimit të një gjetjeje, dhe humbja e heshtur e një vlere kritike nga shpjegimi përfundimtar. I fundit është më i rrezikshmi dhe njëkohësisht më pak i vërejturi, sepse nuk prodhon asnjë gabim të dukshëm në tekst por thjesht një mungesë.

Kur burimi është tekst narrativ i shkruar nga mjeku, dështimet janë të një natyre tjetër. Mohimi mund të kthehet, duke e shndërruar një gjetje të përjashtuar në një gjetje të konfirmuar. Shprehjet e pasigurisë mund të hiqen, duke e paraqitur një hipotezë si fakt. Mund të shtohen gjetje që mjeku nuk i ka shkruar. Mund të humbasin rekomandime konkrete si kontrolli i përsëritur pas një periudhe të caktuar. Dhe mund të shpiket një përkufizim për një term që sistemi nuk e njeh.

Ndër këto, kthimi i mohimit është shkelja më e rëndë e mundshme, sepse ndryshon kuptimin klinik në të kundërtën e tij duke ruajtur plotësisht rrjedhshmërinë gjuhësore, dhe rrjedhimisht nuk sinjalizohet në asnjë mënyrë te lexuesi.

Zgjidhjet ekzistuese ndaj këtyre problemeve janë të pamjaftueshme për tri arsye.

Së pari, udhëzimi i modelit që të mos shpikë informacion trajtohet gjerësisht si masë mbrojtëse, por nuk është e tillë. Ai mund ta zvogëlojë frekuencën e problemit, por nuk ofron asnjë garanci dhe, çka është më e rëndësishme për një punim shkencor, nuk ofron asnjë mënyrë matjeje. Një sistem, siguria e të cilit nuk mund të matet, nuk mund të vlerësohet.

Së dyti, metodat ekzistuese të verifikimit semantik nuk e shfrytëzojnë strukturën kur ajo është e pranishme. Kur burimi është një objekt i strukturuar me vlera numerike të njohura, trajtimi i verifikimit si detyrë probabilistike e humb pa nevojë saktësinë që struktura e bën të mundur.

Së treti, literatura nuk ofron një krahasim të drejtpërdrejtë të së njëjtës arkitekturë verifikimi të zbatuar njëkohësisht mbi burim të strukturuar dhe mbi tekst të lirë. Pa këtë krahasim, nuk dihet sa ndryshon siguria e garancisë ndërmjet dy rasteve, dhe rrjedhimisht nuk dihet çfarë lloj premtimi mund t'i bëhet ndershmërisht përdoruesit.

Një problem i katërt, specifik për kontekstin e këtij punimi, është mungesa e plotë e infrastrukturës gjuhësore për shqipen. Modelet klinike të paratrajnuara, korpuset e anotuara dhe fjalorët terminologjikë për pacientë ekzistojnë për anglishten dhe mungojnë për shqipen. Kjo do të thotë se zgjidhjet e gatshme nuk mund të transferohen drejtpërdrejt, dhe se çdo komponent gjuhësor duhet ose të ndërtohet nga fillimi ose të zëvendësohet me një qasje që nuk varet nga burime specifike për gjuhën.

Problemi kryesor që trajton ky punim është, pra, mungesa e një arkitekture ku modeli gjuhësor mund të përdoret për të shpjeguar informacion mjekësor pa i dhënë atij autoritet mbi faktet, dhe ku efektiviteti i këtij kufizimi mund të matet në mënyrë sasiore, si për të dhëna të strukturuar ashtu edhe për tekst klinik të lirë, në një gjuhë për të cilën mjetet e specializuara nuk ekzistojnë.

3.1 Pyetjet kërkimore

Pyetja kryesore kërkimore e punimit formulohet si vijon:

Deri në ç'masë mund të gjenerojë një sistem i automatizuar shpjegime të kuptueshme për pacientin nga rezultate laboratorike dhe raporte mjekësore, pa futur përmbajtje të

pambështetur nga burimi, dhe si ndryshon siguria e kësaj garancie ndërmjet të dhënave të strukturuar dhe tekstit të lirë?

Kjo pyetje zbërthehet në shtatë nënpyetje, secila e lidhur me një metrikë të përcaktuar.

Për degën e rezultateve laboratorike, **PK1** pyet sa saktë nxirren emri i testit, vlera, njësia dhe intervali referent nga dokumentet, e matur me precision, recall dhe F1-Score, me raportim të ndarë për dokumentet digjitale dhe ato të skanuara. **PK2** pyet sa saktë klasifikohen vlerat kundrejt intervaleve referente, e matur me saktësi dhe matricë konfuzioni, e kushtëzuar nga nxjerrja e suksesshme që gabimet e fazës së mëparshme të mos e ndotin rezultatin.

Për degën e raportit mjekësor, **PK3** pyet sa besueshëm mund të thjeshtohet terminologjia mjekësore pa ndryshuar kuptimin klinik, e matur me normën e ruajtjes së mohimit, normën e ruajtjes së shprehjeve të pasigurisë, normën e gjetjeve të shpikura dhe rishikim ekspertësh mbi një mostër. **PK4** pyet sa besueshëm përputhen pohimet e raportit narrativ me vlerat laboratorike, e matur përmes një klasifikimi katërshe kundrejt anotimit manual.

Për të dyja degët bashkë, **PK5** pyet sa shpesh gjeneron modeli përmbajtje të pambështetur dhe sa e ul këtë shtresa e verifikimit; ky është eksperimenti kryesor i punimit. **PK6** pyet sa saktë e zbulon vetë shtresa e verifikimit përmbajtjen e pambështetur, duke krahasuar rregullat deterministe, klasifikuesin e finetunuar dhe modelin gjuhësor të përdorur si gjykatës. **PK7** pyet nëse përdoruesit joprofesionistë i kuptojnë më mirë rezultatet e tyre me ndihmën e sistemit.

3.2 Hipotezat

Punimi formulon dy hipoteza. Hipoteza e parë parashikon se shtimi i verifikimit të automatizuar e ul ndjeshëm normën e pohimeve të pambështetura që arrijnë te përdoruesi, krahasuar me bazimin pa verifikim. Hipoteza e dytë parashikon se precision-i dhe recall-i i detektorit janë më të lartë për degën e të dhënave laboratorike sesa për degën e tekstit narrativ, si pasojë e drejtpërdrejtë e asimetrisë së bazimit.

3.3 Shtrirja dhe kufizimet

Brenda shtrirjes së punimit hyjnë dokumentet laboratorike në gjuhën shqipe, në formë digjitale dhe të skanuara, seksionet narrative të raporteve mjekësore, një panel prej tridhjetë deri në dyzet analitesh me hartëzim LOINC, dhe një tabelë terminologjike me tetëdhjetë deri në njëqind e pesëdhjetë terma.

Jashtë shtrirjes mbeten qëllimisht diagnoza, rekomandimi i trajtimit dhe prognoza, të cilat janë të përjashtuara me politikë të shkruar dhe të testuar; modelet parashikuese të rrezikut; arkitekturat që kombinojnë kërkimin me gjenerimin mbi korpuse të jashtme mjekësore; nxjerrja e plotë e entiteteve klinike; rezultatet laboratorike jonumerike; dhe gjuhët e tjera përveç shqipes.

4 METODOLOGJIA

4.1 Qasja e zhvillimit të sistemit

Zhvillimi i sistemit ANALYTE është organizuar sipas një qasjeje iterative në të cilën infrastruktura e vlerësimit ndërtohet përpara komponentëve që ajo mat. Ky rend është i qëllimshëm dhe përbën vendim metodologjik: në një punim ku kontributi kryesor është një mekanizëm verifikimi, aftësia për të matur duhet të ekzistojë përpara asaj që matet.

Procesi është ndarë në faza me kritere të përcaktuara përfundimi. Asnjë komponent nuk konsiderohet i përfunduar derisa metrika përkatëse të jetë matur mbi një dataset të versionuar dhe rezultati të jetë i gjurmueshëm deri te konfigurimi që e ka prodhuar.




Figura 1. Fazat kryesore të zhvillimit të sistemit ANALYTE.

Diagrami paraqet rrjedhën e nëntë fazave kryesore: përcaktimi i shtrirjes dhe shqyrtimi i literaturës, ndërtimi i gjeneruesit të të dhënave sintetike, ndërtimi i infrastrukturës së vlerësimit, zhvillimi i degës laboratorike, zhvillimi i degës së raportit mjekësor, gjenerimi dhe

verifikimi me rregulla, trajnimi i klasifikuesit të verifikimit, eksperimentet dhe ablacioni, dhe së fundi zhvillimi i aplikacionit web. Shigjetat tregojnë varësitë ndërmjet fazave, ku fazat e dyta dhe të treta paraprijnë të gjitha fazat e mëpasme sepse prodhojnë përkatësisht të dhënat dhe mjetet matëse.

4.2 Arkitektura e sistemit

Arkitektura e ANALYTE ndjek një model të vetëm, i cili zbatohet në mënyrë identike në të dyja degët e sistemit. Burimi përpunohet nga një shtresë deterministe bazimi që prodhon një përfaqësim të strukturuar; ky përfaqësim i jepet modelit gjuhësor, i cili prodhon tekstin; teksti i prodhuar kalon përmes një shtrese verifikimi; dhe vetëm teksti i verifikuar i shfaqet përdoruesit.




Figura 2. Arkitektura e përgjithshme e sistemit.

Figura paraqet pesë shtresat e sistemit dhe rrjedhën e të dhënave ndërmjet tyre. Shtresa e prezantimit, e realizuar me Next.js dhe React, komunikon përmes një ndërfaqeje REST me shtresën e API-së të ndërtuar me FastAPI. Kjo e fundit delegon përpunimin e dokumenteve te shtresa e orkestrimit, e cila menaxhon punët asinkrone dhe makinën e gjendjeve. Shtresa e bazimit përmban dy degët e përpunimit, ndërsa shtresa e verifikimit vendoset ndërmjet gjenerimit dhe dorëzimit. Të gjitha të dhënat dhe gjurmët e auditimit ruhen në PostgreSQL.

Garancia qendrore e arkitekturës nuk zbatohet përmes udhëzimeve por përmes kontratës së të dhënave. Funkcioni që ndërton kërkesën për modelin gjuhësor pranon si hyrje vetëm objektin e kontekstit të strukturuar dhe, kur rigjenerohet, shkeljet e përpjekjes së mëparshme; asgjë

tjetër. Modeli nuk ka qasje programatike te dokumenti i papërpunuar, te teksti i nxjerrë prej tij, apo te ndonjë burim tjetër informacioni. Ky kufizim është i verifikueshëm nga vetë nënshkrimi i funksionit dhe testohet automatikisht.

Tabela 1. Teknologjitë kryesore të përdorura në sistem

Komponenti	Teknologjia	Roli
Ndërfaqja e përdoruesit	Next.js, React, TypeScript	Aplikacioni web dhe paraqitja e rezultateve
Shërbimi i aplikacionit	Python, FastAPI	API REST, validim, autentikim
Baza e të dhënave	PostgreSQL	Ruajtja e të dhënave dhe gjurmëve të auditimit
Autentikimi	Argon2id, JWT	Hyrja, seancat e revokueshme, dil kudo dhe kufizimi i provave
Posta	SMTP (kutia e provës e Mailtrap në zhvillim)	Lidhja e konfirmimit të email-it
Nxjerrja e tekstit	PyMuPDF	Leximi i PDF-ve me ruajtje të koordinatave
Njohja optike e karaktereve	Tesseract	Përpunimi i dokumenteve të skanuara
Terminologjia standarde	Nënbashkësi LOINC	Normalizimi i emrave të analiteve
Përpunimi gjuhësor	Fjalorë dhe rregulla leksikore	Segmentimi, zbulimi i termave, i mohimit dhe i pasigurisë
Klasifikuesi i verifikimit	XLM-RoBERTa	Zbulimi semantik i përmbajtjes së pambështetur
Gjenerimi i gjuhës	Shablloni determinist (parazgjedhja e aplikacionit); Mistral <code>ministral-14b-2512</code> përmes klientit të përgjithshëm, në eksperimente (me cache) dhe në aplikacion kur zgjidhet shprehimisht (<code>ANALYTE_SERVICE_GENERATOR=model</code> , pa cache; ADR 0017)	Formulimi i shpjegimeve
Përpunimi në sfond	arq, Redis	Punët asinkrone të përpunimit të dokumenteve
Paketimi	Docker, docker-compose	Mjedisi i riprodhueshëm i ekzekutimit
Testimi	pytest	Teste njësie, integrimi dhe golden-file

4.2.1 Kontrata e të dhënave

Garancia qendrore e arkitekturës nuk zbatohet përmes udhëzimeve në kërkesën drejtuar modelit gjuhësor por përmes kontratës së të dhënave. Kjo është arsyeja pse kontrata u shkrua e para, përpara çdo shtrese tjetër, dhe pse ajo nuk ndryshoi gjatë zbatimit të komponentëve që e përdorin.

Objekti i vetëm i kalimit

Shtresa e gjenerimit ka nënshkrimin:

```
def build_prompt(context: GroundingContext, feedback: tuple[Violation, ...]  
= ()) -> Prompt
```

Nuk ka parametër për dokumentin e papërpunuar, për tekstin e nxjerrë prej tij, apo për ndonjë burim tjetër. Modeli nuk mund të shohë asgjë që nuk ndodhet brenda kontekstit, sepse nuk ka nga ku ta marrë. Kufizimi është i verifikueshëm nga vetë nënshkrimi dhe nuk mbështetet te disiplina e zhvilluesit. Parametri `feedback` mban vetëm shkeljet e zbuluara në përpjekjen e mëparshme; ai nuk e sjell dokumentin.

`GroundingContext` përmban gjetjet e strukturuar, pohimet e nxjerra nga narrativa, gjendjet e krahasimit të kryqëzuar, zërat e fjalorit për termat e përmendur dhe listën e termave që sistemi nuk i shpjegon. Ai nuk përmban të dhëna të pacientit: emri, mosha dhe gjinia mbeten jashtë, dhe gjinia përdoret vetëm gjatë zgjidhjes së intervalit referent, përpara se konteksti të formohet (NFR5).

Tri vendime që e bëjnë kontratën të zbatueshme

Objektet janë të pandryshueshme. Një gjetje e nxjerrë nuk modifikohet nga shtresat e mëpasme; çdo transformim prodhon objekt të ri. Kjo e mban gjurmën e auditimit të plotë: dihet gjithmonë cila shtresë e prodhoi një vlerë (NFR2).

Vlerat numerike janë Decimal. Verifikimi krahason numrat për barazi të saktë, prandaj përfaqësimi me presje lëvizëse do të prodhonte shkelje fantazmë — një numër i mbështetur do të dukej i pambështetur për shkak të rrumbullakimit binar, dhe shkak do të ishte pothuajse i pazbulueshëm.

Gjendjet e pamundura nuk ndërtohen dot. Validimi i modelit refuzon një gjetje pa interval referent që mban status tjetër nga *e painterpretueshme*, një gjetje normale që mban masë ashpërsie, ose një shkelje të zbuluar nga një rregull që mban vlerë besueshmërie. Politika SP5 dhe natyra deterministe e rregullave nuk janë kështu kërkesa që kontrollohen diku më vonë; ato janë kushte ndërtimi.

Pastërtia e paketës së domenit

Paketa e modeleve nuk importon asgjë nga pjesa tjetër e sistemit. Kjo nuk mbetet konventë: një test lexon pemën sintaksore të çdo moduli të saj dhe dështon nëse ndonjë import del jashtë listës së lejuar.

Arsyeja është e thjeshtë. Kontrata mban formën e të dhënave për pesë shtresa dhe për gjeneruesin e korpusit njëkohësisht. Sapo ajo të fillojë të varet nga persistenca ose nga

gjenerimi, ndryshimi i atyre shtresave e prish atë në heshtje, dhe etiketat e korpusit ndalojnë së përputhuri me daljen e sistemit pa asnjë shenjë të dukshme.

4.3 Dega e rezultateve laboratorike




Figura 3. Tubacioni i përpunimit të rezultateve laboratorike.

4.3.1 Rrugëzimi i dokumentit

Faza e parë vendos nëse dokumenti ka shtresë teksti të përdorshme. Pragu nuk është zero dhe kjo është pjesë e vendimit: një faqe e skanuar mund të mbajë pak tekst — numër faqeje, vulë të shtypur dixhitalisht, mbetje nga një njohje optike e mëparshme — dhe po ta pranonim atë si shtresë të vlefshme, sistemi do të nxirrte disa rreshta dhe do ta quante dokumentin të lexuar. Prandaj kërkohen njëkohësisht një numër minimal karakteresh dhe një numër minimal rreshtash për faqe.

Dokumenti që nuk e kalon këtë provë kalon në gjendjen e dështimit të leximit dhe jo në atë të mungesës së gjetjeve. Dallimi mes “nuk u lexua dot” dhe “nuk kishte asgjë brenda” është gjendje e veçantë e makinës së gjendjeve, sepse të dyja prodhojnë dalje bosh dhe vetëm njëra prej tyre është gabim i sistemit.

4.3.2 Rindërtimi i rreshtave

Raportet laboratorike janë tabela, por PDF-ja nuk ruan tabela: ajo ruan vargje teksti të vendosura në koordinata. Biblioteka e leximit kthen një rresht për çdo varg të vizatuar veçmas, prandaj “rreshti i tabelës” nuk ekziston derisa të ndërtohet.

Sistemi i grupon fragmentet sipas vijës bazë me tolerancë të vogël dhe i rendit horizontalisht brenda grupit. Kjo e heq hamendjen nga segmentimi: vargu i vetëm “Hb 13,0 g/dL 13,5 - 17,5” kërkon të gjendet ku mbaron emri dhe ku fillon vlera, ndërsa tre fragmente me kolona të veta nuk kërkojnë asgjë.

Njohja e një rreshti si rresht të dhënash mbetet e ngushtë me qëllim: kërkohen të paktën dy fragmente, fragmenti i parë të mos jetë numër, dhe një nga fragmentet e mëpasme të fillojë me numër. Blloku i pacientit, titujt e paneleve dhe koka e kolonave bien jashtë kësaj prove.

4.3.3 Normalizimi

Emrat e analiteve hartëzohen te kodet LOINC me përputhje të saktë pas normalizimit; përputhja e afërt refuzohet. Arsyeja jepet në vendimin arkitekturor 0006: “Kaliumi” dhe “Kalciumi” ndryshojnë për një shkronjë dhe kanë intervale krejt të ndryshme, dhe ngatërrimi i tyre do të hynte i heshtur në një shpjegim për pacientin.

Numrat lexohen si me presje ashtu edhe me pikë dhjetore, por ndarësi i mijësheve refuzohet. Kjo është zgjedhje e vetëdijshme: refuzimi është gabim i dukshëm, ndërsa hamendja është gabim i heshtur me faktor një mijë.

Njësitë kthehen në njësinë kanonike të analitit. Faktori varet nga substanca kudo ku në të hyn masa molare, prandaj kthimi merr analitin dhe jo vetëm dy emra njësisish. Vlera në njësi që nuk njihet nuk kthehet dhe as nuk pranohet ashtu siç është: ajo nuk krahasohet dot me asnjë interval, prandaj gjetja mbetet e painterpretueshme.

Tabela 2. Faktorët e konvertimit të njësive

Nga	Në	Faktori	Analiti
g/L	g/dL	0.1	çdo analit
mmol/L	mg/dL	18.0182	2345-7
umol/L	mg/dL	0.0113122	2160-0
mmol/L	mg/dL	6.006	3094-0
umol/L	mg/dL	0.0584795	1975-2
mmol/L	mg/dL	38.67	2093-3
mmol/L	mg/dL	38.67	2085-9
mmol/L	mg/dL	38.67	13457-7
mmol/L	mg/dL	88.57	2571-8

4.3.4 Zgjidhja e intervalit referent

Përparësia është e përcaktuar. Intervali i shtypur në dokument fiton gjithmonë, sepse laboratorit e di me çfarë metode ka matur dhe tabela jonë jo. Kur ai mungon, merret intervali i tabelës së brendshme, i përputhur sipas analitit dhe gjinisë. Kur asnjëra nuk jep përgjigje, gjetja mbetet pa interval.

Gjinia lexohet nga blloku i kokës së dokumentit. Kur ajo nuk gjendet dhe analiti ka kufij të ndryshëm sipas saj, intervali mbetet i pazgjidhur: zgjedhja e njërit prej dy intervaleve do të ishte short i maskuar si mbulim.

Burimi i intervalit regjistrohet për çdo gjetje dhe raportohet veçmas në rezultate. Pa të, një gabim klasifikimi nuk mund t'i atribuohet as leximit të intervalit nga faqja, as zgjedhjes së tij nga tabela.

4.3.5 Klasifikimi dhe refuzimi i interpretimit

Klasifikimi është rregull determinist mbi vlerën e normalizuar dhe kufijtë e zgjidhur, me gjashtë statuse. Masa e ashpërsisë llogaritet si largësia nga kufiri i kaluar pjesëtuar me gjerësinë e intervalit. Për intervale njëanëshe, të zakonshme të lipidet, gjerësia nuk ekziston dhe shkalla bëhet vetë kufiri i kaluar; ky dallim është i dokumentuar te funksioni, sepse ashpërsitë e dy llojeve nuk janë të krahasueshme mes tyre.

Vlera pa interval mbahet dhe nuk hidhet. Pacienti e ka atë të shtypur në dokument dhe ka të drejtë ta shohë të renditur, me shënimin se nuk interpretohet. Heqja e saj do të fshihte një matje që laboratorit e bëri vërtet — mungesë e heshtur në vend të një refuzimi të shprehur.

Tabela 3. Paneli i analiteve dhe hartëzimi me kodet LOINC (ekstrakt)

Kodi LOINC	Analiti	Njësia	Paneli	Interval (M)	Interval (F)
718-7	Hemoglobinë në gjak	g/dL	hematologji	13.5 – 17.5	12.0 – 16.0
4544-3	Hematokrit	%	hematologji	40.0 – 52.0	36.0 – 48.0
789-8	Eritrocite	10 ¹² /L	hematologji	4.50 – 5.90	4.00 – 5.20
6690-2	Leukocyte	10 ⁹ /L	hematologji	4.0 – 10.0	—
777-3	Trombocyte	10 ⁹ /L	hematologji	150 – 400	—
787-2	Volumi mesatar eritrocitar	fL	hematologji	80.0 – 100.0	—
785-6	Hemoglobina mesatare eritrocitare	pg	hematologji	27.0 – 33.0	—
786-4	Përqendrimi mesatar i hemoglobinës	g/dL	hematologji	32.0 – 36.0	—
2345-7	Glukoze në serum	mg/dL	biokimi	70 – 99	—
4548-4	Hemoglobinë e glikuar	%	biokimi	4.0 – 5.6	—

Ekstrakt i 10 analiteve të para; paneli i plotë është te Shtojca B (Tabela B.1).

Tabela e brendshme përmban 38 analite me interval referent dhe njeh me emër edhe 8 të tjera për të cilat interval nuk ekziston. Këto të fundit nuk janë mangësi e tabelës por materiali me të cilin matet politika SP5.

4.3.6 Rreshtat e hedhur

Çdo rresht që njihet si të dhëna por nuk prodhon gjetje ruhet bashkë me arsyen: analiti i panjohur, vlerë e palexueshme, dublikatë. Kjo listë nuk hyn në kontekst — ajo është material auditimi dhe analize gabimesh.

Pa të, një saktësi e ulët e nxjerrjes nuk do të tregonte nëse faji është i segmentimit, i hartës së emrave apo i njësive, dhe analiza e gabimeve e Kapitullit 6 do të mbështetej te ndjesia.

4.3.7 Gjendja e zbatimit dhe matja

Kanali dixhital u mat mbi 332 dokumente dixhitale të korpusit sintetik (E1). Saktësia, mbulimi dhe F1 dolën 1.000 për të katër fushat — analiti, vlera, njësia dhe intervali. Saktësia e klasifikimit mbi të njëjtat dokumente është 1.000.

Ky rezultat nuk duhet lexuar si dëshmi se nxjerrja është e zgjidhur. Ai thotë se tubacioni është i lidhur saktë mbi një korpus që nuk dallon: gjeneruesi vizaton tekst të pastër në koordinata të njohura dhe nxjerrësi lexon koordinata. Mungojnë rreziqet e një dokumenti real — emrat e mbështjellë në dy rreshta, shenjat e fusnotave pranë vlerës, qelizat e bashkuara, kolonat e komenteve dhe analitet jashtë tabelës. Për më tepër, nxjerrësi dhe gjeneruesi ndajnë tabelën e kthimit të njësive, çka e bën fushën e intervalit pjesërisht tautologjike te rreshtat me njësi alternative.

Matja që do të kishte vlerë dalluese është ajo mbi kanalin e skanuar dhe mbi dokumente reale. E dyta pret miratimin etik; e para u bë me Tesseract 5 [52] (ADR 0012), me konfigurim të zgjedhur mbi një korpus të veçantë akordimi. Mbi 168 dokumentet e skanuara të korpusit të vlerësimit (gen-1.0/s42/n500/37d8b080), F1 doli 0.670:

Tabela 4. Saktësia e nxjerrjes mbi kanalin e skanuar, sipas fushës (E2)

Fusha	Saktësia	Mbulimi	F1
Analiti	0.996	0.697	0.820
Vlera	0.947	0.663	0.780
Njësia	0.781	0.547	0.643
Intervali	0.532	0.372	0.438

Numri që ka rëndësi nuk është F1 por saktësia e vlerës. Nga 2 370 vlera të nxjerra nga dokumentet e skanuara, 125 ishin të gabuara dhe u pranuan — më shpesh sepse OCR-ja

humbi ndarësin dhjetor dhe “15,7” u lexua “157”. Në matjen e parë ishin 271; gjysma tjetër — intervale të lexuara si vlerë me njësi numerike — refuzohen tani nga nxjerrësi (ADR 0012). Një vlerë e humbur nuk interpretohet; një vlerë e gabuar interpretohet me siguri, dhe asgjë më poshtë në rrjedhë nuk e vë re. Kontrolli i besueshmërisë që do ta ndalte kërkon kufij fiziologjikë me burim për çdo analit dhe mbetet vendim i hapur.

E3 me OCR mbi tërë korpusin: saktësia e statusit 0.881. Pjesa më e madhe e gabimeve janë të sigurta — vlerat u bënë “pa interval” sepse intervali nuk u lexua, dhe SP5 refuzoi interpretimin. Por 62 vlera morën një status të interpretuar dhe të gabuar, ndër to 11 të shënuara kritike të larta pa qenë të tilla (9 normale, 1 e lartë dhe 1 kritike e ulët). Këta janë rastet që kontrolli i besueshmërisë do t’i ndalte.

Vendimi për të mos e vështirësuar korpusin sintetik, dhe arsyeja e tij, jepen te seksioni 4.8.

4.3.8 Kombinimet ndërmjet analiteve

Rregullat e kombinimit janë të shkruara me dorë në një tabelë burimore (Tabela B.3, Shtojca B), një rresht për rregull: një listë kushtesh — analiti dhe drejtimi i statusit të tij — që duhet të plotësohen njëkohësisht, dhe burimi i rregullit. Njëmbëdhjetë rregulla mbulojnë kombinime të njohura gjerësisht, si hemoglobina e ulët me ferritinë të ulët apo hormoni stimulues i tiroides i lartë me tiroksinë të lirë të ulët.

Rregulli nuk emërton gjendjen. Emri i një kombinerimi është diagnozë, dhe SP1 e ndalon pavarësisht nga burimi; dalja thotë vetëm se këto vlera, bashkë, kërkojnë vlerësim nga profesionisti shëndetësor. Tri veti e kufizojnë rregullin më tej. Vlera kritike numërohet sipas drejtimit të saj, që rregulli të mos heshtë pikërisht te vlerat më të rënda. Vlera pa interval referent nuk merr pjesë, sepse përndryshe rregulli do ta interpretonte tërthorazi atë që SP5 ndalon të interpretohet. Dhe një analit që shfaqet dy herë në dokument nuk zgjidhet me hamendje: rregulli që e kërkon nuk ndizet.

Kombinimet hyjnë në `GroundingContext` si vëzhgime që tregojnë gjetjet që i formuan, prandaj edhe modeli gjuhësor i sheh vetëm si pjesë të kontekstit. Ashtu si klasifikimi, ato janë rregull i dhënë (ADR 0003): e vërteta bazë e korpusit i llogarit me të njëjtin funksion.

Korpusi prodhon vlera të pavarura për çdo analit, prandaj kombinimet aty janë të rralla — 19 nga 500 dokumente. Rregullat testohen mbi gjetje të ndërtuara me dorë, jo mbi korpusin, dhe asnjë PK nuk mat saktësinë e tyre klinike; ajo varet nga burimi i secilit rregull dhe nga shqyrtimi i mentorit.

4.4 Dega e raportit mjekësor




Figura 4. Tubacioni i përpunimit të raportit mjekësor.

Dega e dytë merret me tekstin e lirë të mjekut. Ndryshe nga vlerat laboratorike, ku e vërteta është numër dhe krahasimi është i saktë, këtu e vërteta është kuptimi i një fjalie — dhe pikërisht ai kuptim është ai që humbet më lehtë kur teksti thjeshtohet.

4.4.1 Gjetja e tekstit dhe ndarja në fjali

Narrativa gjendet në dokument nën titullin e vet dhe mbyllet te nënshkrimi i mjekut. Rreshtat e mbështjellë bashkohen sërish me një hapësirë të vetme — veprimi i kundërt i atij që i mbështolli — që teksti i rindërtuar të jetë varg për varg i njëjtë me atë që u shtyp. Kjo nuk është kozmetikë: pozicionet e pohimeve maten mbi këtë varg dhe duhet të mbeten të krahasueshme me anotimin manual.

Ndarja në fjali është e thjeshtë me qëllim. Narrativa e raporteve është prozë e shkurtër pa shkurtime me pikë, dhe një ndarës më i ndërlikuar do të fshihte se nga vjen secili pohim.

4.4.2 Njohja e termave

Kërkimi në tabelën terminologjike është rregull: termi gjendet ose nuk gjendet. Përputhja duron lakimin e shqipes me përputhje parashtese mbi çdo fjalë të termit, prandaj “anemisë”,

“anemia” dhe “anemi” janë i njëjti zë, dhe “intervalin referent” gjendet si “interval referent”. Toleranca vlen për çdo fjalë e jo vetëm për të fundit, sepse shqipja e lakon edhe kryefjalën e një termi dyfjalësh.

Termat që nuk gjenden në tabelë njihen me morfologji: prapashtesat mjekësore si -ozë, -emi, -peni dhe -uri. Kjo është heuristikë dhe jo rregull, dhe kjo ndarje ka pasojë metodologjike: heuristika nuk ndahet me gjeneruesin e korpusit. E vërteta bazë e termave të pashpjeguar vjen nga ajo që gjeneruesi vendosi të fusë; po ta nxirrnim me të njëjtën heuristikë, sistemi do të krahasohej me vetveten dhe SP6 do të dukej gjithmonë i plotësuar.

Heuristika ka çmimin e vet dhe ai u pa gjatë zbatimit: prapashtesa -itet kapte foljen “paraqitet” dhe prodhonte një term të pashpjeguar në pothuajse çdo dokument. Ajo u hoq, dhe fjalët e zakonshme që mbarojnë si terma mjekësorë mbahen në një listë të shkurtër përjashtimesh. Kur ajo listë të rritet përtej disa dhjetësh, kjo do të thotë se qasja morfologjike ka dalë nga fuqia e vet.

Tabela 5. Ekstrakt nga tabela terminologjike shqip

Termi	Shpjegimi	Kategoria
anemi	nivel i ulët i hemoglobinës në gjak	gjendje
eritropoezë	prodhimi i qelizave të kuqe të gjakut në palcën kockore	proces
leukocitozë	numër i rritur i qelizave të bardha të gjakut	gjendje
leukopeni	numër i ulët i qelizave të bardha të gjakut	gjendje
trombocitopeni	numër i ulët i pllakëzave të gjakut	gjendje
trombocitozë	numër i rritur i pllakëzave të gjakut	gjendje
hiperglicemi	nivel i rritur i sheqerit në gjak	gjendje
hipoglicemi	nivel i ulët i sheqerit në gjak	gjendje
hiperkalemi	nivel i rritur i kaliumit në gjak	gjendje
hipokalemi	nivel i ulët i kaliumit në gjak	gjendje

Ekstrakt i 10 zërave të parë; tabela e plotë është te Shtojca A (Tabela A.1).

Tabela përmban 82 zëra. Shpjegimet janë përkufizime pune të autorit dhe nuk janë referuar në një burim të verifikueshëm; pa referencë, tabela bëhet vetë burim informacioni të paverifikuar — pikërisht ajo që SP6 synon të pengojë. Kjo deklarohet si kufizim te seksioni 6.6.

4.4.3 Mohimi dhe pasiguria

Zbulimi i mohimit ndjek frymën e NegEx-it: një listë e shkurtër shenjash dhe një fushë veprimi që mbyllet te kundërvënia. Tri hollësi e bëjnë problemin real.

Pseudo-mohimi kontrollohet i pari. “Nuk përjashtohet sideropeni” përmban shenjën “nuk” dhe nuk mohon asgjë — ajo pohon me rezervë. Po ta lexonim si mohim, do të përmbysnim mjekun pikërisht ashtu si druhet rregull R5 se do ta bëjë modeli gjuhësor.

Polariteti dhe drejtimi mbahen të ndarë. “Nuk rezulton mbi intervalin referent” ka drejtim *i rritur* dhe polaritet *i mohuar*. Bashkimi i tyre në një fushë do ta bënte të pamundur dallimin mes “është i ulët” dhe “nuk është i lartë”, të cilat nuk janë e njëjta gjë: e dyta përputhet me çdo status që nuk është i rritur.

Gabimi i parazgjedhur është pohimi. Një mohim i humbur prodhon tekst më të fortë se burimi dhe kapet nga verifikimi; një mohim i shpikur prodhon tekst që kundërshton burimin pa lënë gjurmë se nga erdhi.

Pasiguria zbulohet njësoj, me shenja të ndara në katër grupe: foljet modale, ndajfoljet, foljet e dukjes dhe mohimi i përjashtimit. Ky i fundit është njëkohësisht pseudo-mohim, dhe të dy modulet e trajtojnë njësoj: pohim, por me rezervë.

Një kufizim mbetet i hapur dhe është fiksuar me test që ndryshimi i tij të jetë i vetëdijshëm: mohimi në gjymtyrën e dytë të fjalisë lexohet si pohim. Zgjidhja e duhur është ndarja e fjalisë në dy pohime, jo zbutja e fushës së veprimit.

4.4.4 Pohimet dhe krahasimi i kryqëzuar

Çdo fjali që pretendon diçka kthehet në një pohim me llojin e vet: gjetje, rekomandim ose përmendje termi. Fjalitë që nuk pretendojnë asgjë nuk prodhojnë pohim; një pohim i shpikur do të kërkonte më vonë mbështetje që nuk ekziston.

Fjalja me term të panjohur prodhon pohim njësoj si ajo me term të njohur. Kjo është ana e dytë e SP6: sistemi duhet ta vërejë fjalinë për ta shënuar termin si të pashpjeguar. Po ta linim pa pohim, “nuk e shpjegojmë” do të bëhej “nuk e pamë fare” — dy gjendje që duken njësoj në dalje dhe janë krejt të ndryshme në auditim.

Krahasimi i kryqëzuar prodhon një gjendje për analit. Rregulli i përputhjes është përkufizim dhe jo hamendje, prandaj i njëjti funksion përdoret nga gjeneruesi për të ndërtuar të vërtetën bazë; PK4 mat nxjerrjen e gjetjeve dhe të pohimeve, jo rregullin.

4.4.5 Matja

PK4 u mat mbi korpusin sintetik me dy vlera që duhen raportuar të dyja:

- **1.000** mbi dokumentet dixhitale, me mbulim të plotë për të katër gjendjet;
- **0.656** mbi tërë korpusin pa OCR, dhe **0.863** me OCR (gen-1.0/s42/n500/37d8b080, 500 dokumente, 168 të skanuar).

I gjithë ndryshimi është kanali i skanuar. Pa njohje optike ato dokumente nuk lexohen fare dhe çdo gjendje e tyre llogaritet si e munguar; me OCR lexohen pjesërisht. Një vlerë e mëparshme prej 0.563 u raportua në një draft më të hershëm pa u shënuar korpusi mbi të cilin u mat, prandaj nuk riprodhohet dhe nuk përdoret.

Mbi gjysmën dixhitale, të gjitha pohimet e burimit u rikthyen me polaritet, siguri dhe lloj të saktë, dhe termat e pashpjeguar u identifikuan saktësisht në çdo dokument.

Vlen i njëjti kufizim si te Dega A, dhe këtu ai peshon më shumë: narrativa sintetike ndërtohet nga fjali të shkruara me dorë, dhe detektorët u shkruan duke i pasur ato parasysh. Prandaj testet e mohimit dhe të pasigurisë përdorin fjali të tjera, të shkruara posaçërisht si provë — një provë mbi shabllonet e gjeneruesit do të tregonte vetëm se kodi kujton veten. Prova e vërtetë mbetet teksti i mjekëve realë.

4.5 Shtresa e verifikimit




Figura 5. Arkitektura e shtresës së verifikimit.

Shtresa e verifikimit është kontributi qendror i punimit. Ajo vepron mbi tekstin e gjeneruar nga modeli gjuhësor dhe mbi kontekstin e strukturuar që i është dhënë atij, dhe vendos nëse teksti mund t'i shfaqet përdoruesit.

Verifikimi funksionon në dy mënyra, që i përgjigjen dy degëve të sistemit.

Për të dhënat laboratorike, verifikimi është i saktë. Çdo numër që shfaqet në tekstin e gjeneruar duhet të përputhet me një vlerë, me një kufi intervali ose me një datë të pranishme në gjetjet e strukturuar, brenda një tolerance të përcaktuar rrumbullakimi; një numër i papërputhur përbën shkelje. Çdo analit i përmendur duhet të ekzistojë në gjetjet; përmendja e një analiti të pamatur përbën shkelje. Çdo pohim mbi drejtimin duhet të përputhet me statusin e strukturuar të analitit përkatës. Dhe çdo gjetje e klasifikuar si kritike duhet të shfaqet diku në tekstin përfundimtar.

Për tekstin narrativ, verifikimi është semantik. Polariteti i çdo pohimi burimor duhet të ruhet në dalje; kthimi i një mohimi përbën shkeljen më të rëndë të mundshme. Niveli i sigurisë i shprehur në burim duhet gjithashtu të ruhet. Asnjë gjetje e re nuk lejohet të shfaqet. Çdo rekomandim i pranishëm në burim duhet të mbijetojë në dalje. Dhe çdo term i shpjeguar duhet të gjendet në tabelën terminologjike.

Tabela 6. Katalogu i rregullave të verifikimit

Kodi	Dega	Kontrolli
R1	A	Përputhja numerike me tolerancë të përcaktuar
R2	A	Ekzistenca e analitit në gjetjet e strukturuar
R3	A	Përputhja e drejtimit me statusin
R4	A	Mbulimi i gjetjeve kritike
R5	B	Ruajtja e polaritetit
R6	B	Ruajtja e nivelit të sigurisë
R7	B	Mosshfaqja e gjetjeve të reja
R8	B	Mbijetesa e rekomandimeve
R9	B	Bazueshmëria e shpjegimeve terminologjike

Katalogu i zbatuar (versioni r1.3) përmban edhe një rregull politike, SP1–SP3, që refuzon pohimet diagnostike, të trajtimit dhe prognostike; versioni i katalogut regjistrohet te çdo rezultat verifikimi. Katalogu i plotë me një shembull për çdo rregull është te Shtojca C.

Renditja e ekzekutimit është e përcaktuar: rregullat deterministe ekzekutohen të parat dhe kanë përparësi kudo ku verifikimi është mekanikisht i vendosshëm, ndërsa klasifikuesi ekzekutohet i dyti dhe mbulon zhvendosjet semantike që rregullat nuk i kapin. Vendimi përfundimtar është bashkimi i flamujve nga të dyja qasjet.

4.6 Trajtimi i dështimit




Figura 6. Makina e gjendjeve e përpunimit të dokumentit.

Sjellja e sistemit në rast shkeljeje është e përcaktuar si makinë gjendjesh dhe çdo kalim regjistrohet në gjurmën e auditimit.

Kur verifikimi zbulon një ose më shumë shkelje, sistemi rigjeneron tekstin një herë, duke e përfshirë shprehimisht përshkrimin e shkeljes në kërkesën drejtuar modelit. Teksti i ri verifikohet përsëri. Nëse edhe ky dështon, sistemi nuk bën përpjekje të mëtejshme por kalon te një shpjegim i gjeneruar nga një shabllon determinist, i cili ndërtohet drejtpërdrejt nga gjetjet e strukturuara pa përfshirjen e modelit gjuhësor. Ky shpjegim është më i thatë gjuhësisht, por ndërtohet vetëm nga gjetjet e strukturuara dhe nuk shton asgjë që nuk është në to. Saktësia e tij është ajo e gjetjeve: një vlerë e lexuar gabim nga OCR-ja përsëritet si e tillë (§5.2).

Makina e gjendjeve përmban gjithashtu një gjendje të veçantë për dokumentet që përpunohen me sukses por nuk japin asnjë gjetje. Pa këtë gjendje, një dokument i palexueshëm do të prodhonte një dalje bosh pa asnjë shpjegim për përdoruesin, gjë që përbën dështim të heshtur.

Parimi që përshkon të gjithë këtë mekanizëm është se tekst që nuk ka kaluar verifikimin nuk i shfaqet asnjëherë përdoruesit, në asnjë rrethanë. Verifikimi kap vetëm atë që rregullat shohin (§5.6.1).

4.7 Komponenti i mësimit makinerik

Klasifikuesi i verifikimit semantik gjykon një fjali të vetme të tekstit të gjeneruar dhe i jep asaj një etiketë nga një bashkësi e mbyllur: `clean` (fjalë nuk ka shkelje) ose një nga tetë llojet e shkeljeve që mund të njihen nga një fjali e vetme (`ungrounded_number`, `ungrounded_analyte`, `direction_mismatch`, `polarity_flip`, `hedge_removed`, `fabricated_finding`, `ungrounded_term_explanation` dhe `prohibited_claim`). Dy prej tyre, `ungrounded_term_explanation` dhe `prohibited_claim`, nuk prodhohen nga korruptuesit e korpusit dhe nuk kanë mostra trajnimi; ato janë në bashkësi që koka e klasifikimit të mos ndryshojë kur grupi B i sjell. Rekomandimi i fshirë dhe vlera kritike që mungon nuk lënë fjali për të gjykuar, prandaj nuk janë detyrë e klasifikuesit (ADR 0009). Klasifikuesi ka dy hyrje: fjalinë e vetme, dhe fjalinë bashkë me një përmbledhje të shkurtër të kontekstit.

Kjo nuk është detyra e natural language inference (premisë, hipotezë, tre klasa: entailment, kundërshti, neutralitet) që përshkruhet te §2.4.1. NLI është motivimi dhe terreni i literaturës [4]; ajo që u trajnuar dhe u mat (E11) parashikon llojin e shkeljes, jo marrëdhënien logjike. Pasoja është e dukshme te hyrja: klasifikuesi nuk merr një premisë të plotë, dhe krahasimi i tij me rregullat bëhet mbi hyrje të ndryshme (ADR 0009).

Modeli bazë i zgjedhur është XLM-RoBERTa. Zgjedhja diktohet nga konteksti gjuhësor: modelet klinike të paratrajnuara mbulojnë vetëm anglishten, ndërsa një enkoder shumëgjuhësh i përgjithshëm mbulon edhe shqipen. Zgjedhja nuk u krahasua eksperimentalisht me enkoderë të tjerë: u trajnuar vetëm xlm-roberta-base (§5.7).




Figura 7. Ndërtimi i korpusit të korruptuar për trajnimin e klasifikuesit.

Të dhënat e trajnimit prodhohen automatikisht. Duke nisur nga teksti i shabllonit, që kalon çdo rregull, futet saktësisht një defekt i kontrolluar nga shtatë lloje të mundshme: ndryshim i një numri, përmendje e një analiti që nuk është matur, kthim i drejtimit të një gjetjeje, kthim i mohimit, heqje e një shprehjeje pasigurie, shtim i një gjetjeje të shpikur, ose fshirje e një rekomandimi (llojet `ungrounded_number`, `ungrounded_analyte`, `direction_mismatch`, `polarity_flip`, `hedge_removed`, `fabricated_finding` dhe `omitted_recommendation`). Etiketa caktohet automatikisht nga vetë procesi i korruptimit, gjë që eliminon nevojën për anotim manual dhe garanton etiketim të përsosur. Baza është shablloni dhe jo modeli gjuhësor, prandaj defektet janë të injektuara dhe ngajnë me gabimet e modelit vetëm për aq sa i imitojnë mirë (ADR 0009, §4.11.1).

Krahasimi eksperimental përfshin tri qasje mbi të njëjtat mostra testuese, por jo mbi të njëjtën informacion: rregullat deterministe të përshkruara në nënkapitullin 4.5 shohin kontekstin e plotë të strukturuar; klasifikuesi i finetunuar sheh vetëm fjalinë (një variant i dytë merr edhe një përmbledhje të shkurtër të kontekstit); dhe një model i madh gjuhësor i përdorur si gjykatës merr kontekstin dhe një rubrikë vlerësimi të përcaktuar rreptësisht (E12). Prandaj dallimet mes tyre janë dallime të hyrjes po aq sa të metodës (ADR 0009). Klasifikuesi vlerësohet në dy pika pune, të dyja të zgjedhura mbi validimin dhe vetëm atje: ajo me macro F1 më të lartë mbi llojet e defektit, dhe ajo me macro F1 më të lartë ndër pragjet që bllokojnë jo më shumë se 5% të teksteve të pastra të validimit.

4.8 Strategjia e të dhënave

4.8.1 Korpusi sintetik




Figura 8. Procesi i gjenerimit të korpusit sintetik.

Korpusi sintetik është burimi parësor i vlerësimit. Ai prodhon njëkohësisht dy gjëra që mbahen rreptësisht të ndara: dokumentin PDF që sheh sistemi, dhe skedarin me të vërtetën bazë që sistemi nuk e sheh kurrë.

Rendi i veprimeve

Rendi me të cilin ndërtohet një dokument nuk është i rastësishëm. Zgjidhet i pari statusi i synuar, pastaj kampionohet një vlerë që e plotëson atë, pastaj vendoset mënyra e shtypjes — njësia, prania e intervalit, presja dhjetore — dhe vetëm në fund rillogaritet statusi i vërtetë mbi vlerën dhe intervalin ashtu si dalin të shtypura.

Nëse do të ruhej statusi i synuar, një dokument që shtyp interval paksa të ndryshëm nga tabela e brendshme do të mbante etiketë të rreme. Kjo është forma më e rrezikshme e gabimit në një korpus me etiketa: ai nuk dështon, ai mat diçka tjetër nga ajo që mendon se mat.

Variacioni i shtypjes

Ndryshimet mes laboratorëve janë pjesë e korpusit dhe jo zbulim: presje apo pikë dhjetore, interval i shtypur për të gjitha rreshtat, për disa ose për asnjë, flamur H/L, shigjetë apo yll, njësi tradicionale apo SI. Tri formate faqeje ndryshojnë gjerësinë e kolonave, vendosjen e njësisë në qelizë të veçantë ose ngjitur pas vlerës, dhe praninë e vijave ndarëse.

Intervali i shtypur ndryshon paksa nga tabela e brendshme në rreth një të dhjetën e rreshtave. Pa këtë, nxjerrja e intervalit nga dokumenti nuk do të mategj vërtet: sistemi do të dilte i saktë edhe po ta injoronte fare atë që shtypet.

Narrativa

Teksti i mjekut ndërtohet nga fjali të plota të shkruara me dorë dhe jo nga fragmente të bashkuara. Shqipja ka rasa dhe përshtatje numri; një shabllon i tipit “Vlerat e {emri} janë të rritura” prodhon trajtë të gabuar për gjysmën e analiteve. Prandaj çdo shabllon ekziston në njëjës dhe në shumës, dhe emri i analizit qëndron gjithmonë kryefjalë në emërore.

Fjalitë me terma mjekësorë janë të kushtëzuara nga matja: një narrativë që përmend leukocitozë kur leukocitet janë normale do të ishte korpus i pakujdesshëm, jo korpus i vështirë.

Numrat nuk hyjnë në narrativë — shkruhet “pas tre muajsh” dhe jo “pas 3 muajsh”. Një vlerë e shtypur në tekstin e mjekut do të zgjeronte heshtazi bashkësinë e numrave që teksti i gjeneruar mund t’i përmendë, dhe do ta zbuste rregullin R1 pikërisht aty ku ai duhet të jetë i ashpër.

Simulimi i skanimit

Rreth 35% e dokumenteve kthehen në fotografi letre: anim, turbullim, zhurmë, njolla dhe artefakte kompresimi, pa asnjë shtresë teksti.

Dokumenti i skanuar nuk vizatohet ndryshe. Ai vizatohet njësoj dhe pastaj prishet, prandaj përmbajtja e të dy kanaleve është identike dhe çdo ndryshim në rezultatet e PK1 dhe PK2 i atribuohet kanalit e jo tekstit. Kutitë kufizuese rrotullohen bashkë me faqen; përndryshe e vërteta bazë do të tregonte vende ku nuk ka më asgjë.

Përsëritshmëria

Dy ekzekutime me të njëjtën farë japin bajt për bajt të njëjtët skedarë, PDF-të e përfshira. Kjo kërkonte tri gjëra: asnjë identifikues nga burim i rastësishëm i sistemit, asnjë vulë kohore në dalje, dhe çrrënjosjen e vulës së kohës që biblioteka e vizatimit e shkruan në PDF si parazgjedhje.

Çdo dokument merr farën e vet të prejardhur nga fara e korpusit dhe indeksi i tij. Prandaj dokumenti i njëqindtë është i njëjti pavarësisht nëse u kërkuan njëqind e një apo pesëqind dokumente, dhe gjenerimi është i ndashëm në procese.

Manifesti ruan shumat kontrolluese të tabelave burimore. Dy korpuse me të njëjtën farë por me tabelë analitësh të ndryshme nuk kanë të njëjtin version dhe nuk ngatërrohen dot në asnjë tabelë rezultatesh.

Çfarë mat dhe çfarë nuk mat ky korpus

Korpusi mbulon me qëllim rastet që punimi pretendon se i trajton — vlera kritike, vlera pa interval referent, pohime të mohuara, pasiguri të shprehur, rekomandime, terma jashtë tabelës dhe të katër gjendjet e krahasimit të kryqëzuar — dhe ky mbulim kontrollohet me test.

Ai nuk mat vështirësinë e nxjerrjes nga dokumente reale. Kjo duhet thënë hapur dhe jo si formulë modestie: kanali dixhital sintetik nuk dallon, sepse gjeneruesi vizaton tekst të pastër në koordinata të njohura dhe nxjerrësi lexon koordinata. Vlefshmëria e jashtme varet nga eksperimenti E13 mbi dokumente reale, dhe nëse ai nuk realizohet, kufizimi mbetet i shprehur në përfundime.

Korpusi nuk u vështirësua për ta mbyllur këtë boshllëk. Emra të mbështjellë në dy rreshta, shenja fusnotash dhe kolona komentesh mund t'i shtoheshin gjeneruesit, por atëherë i njëjti autor do ta projektonte vështirësinë dhe zgjidhjen e saj, dhe një rezultat i lartë mbi të nuk do të

provonte asgjë përtej asaj që autori priste. Kanali i skanuar është përjashtimi: zhurma e skanimit prodhohet nga një proces i rastësishëm dhe jo nga një listë rreziqesh, prandaj E2 është matja e vetme brenda korpusit që e sfidon nxjerrësin.

Shkalla e jonormalitetit është rreth 20% për analit, më e lartë se te një depistim rutinë. Pasurimi është i qëllimshëm — një korpus ku pothuajse çdo vlerë është normale nuk ka mbi çfarë të matë as klasifikimin, as përshkallëzimin kritik — dhe raportohet si i tillë. Ai nuk duhet ngatërruar me prevalencë.

4.8.2 Të dhënat reale

Nëse miratimi etik jepet, një grup prej tridhjetë deri në pesëdhjetë dokumentesh reale të anonimizuara përdoret ekskluzivisht si validim i jashtëm, për të kontrolluar nëse performanca e matur mbi dokumentet sintetike transferohet te faqesje reale të papara.

Për këtë grup, udhëzimet e anotimit përcaktohen paraprakisht me shkrim, një nënbashkësi anotohet në mënyrë të pavarur nga një anotues i dytë, dhe pajtueshmëria ndër-anotuese raportohet përmes koeficientit kappa të Cohen-it [64].

Nëse miratimi etik nuk jepet ose vonohet përtej afatit, punimi vazhdon mbi korpusin sintetik dhe kufizimi deklarohet shprehimisht në kapitullin e diskutimit.

4.9 Organizimi i komponentëve të aplikacionit

	main	orchestration	api	generation	verification	erasure	outbox	twofactor	audit	grounding	mail	security	ingestion	persistence	catalog	config	textnorm	domain
main		1	2								1					1		
orchestration				8	1	1	1		1	1	1		4	5		1		7
api				1		2	1	1	6		2	6		14	1	7	1	6
generation															1		1	10
verification										8							5	15
erasure									1			1		3		1		
outbox									1		1	1		1		1		
twofactor																		
audit														1				1
grounding													3		7		5	13
mail																1		
security																		
ingestion																		2
persistence																		2
catalog																		
config																		
textnorm																		
domain																		

Rreshti importon kolonën; numri është sa deklarata import ka.



modul i punimit (§5.9)



modul mbështetës



varësi që kthehet mbrapa

Figura 9. Struktura modulare e aplikacionit.

Aplikacioni është organizuar në module me përgjegjësi të ndara qartë. Moduli i domenit përmban modelet e të dhënave dhe nuk varet nga asnjë modul tjetër, gjë që e mban kontratën e të dhënave të qëndrueshme ndërsa pjesa tjetër e sistemit evoluon. Moduli i ngarkimit merret me leximin e dokumenteve dhe njohjen optike. Moduli i bazimit përmban të dyja degët e përpunimit. Moduli i gjenerimit përmban përshtatësin e modelit gjuhësor dhe kërkesat e versionuara. Moduli i verifikimit përmban rregullat dhe klasifikuesin. Moduli i orkestrimit

menaxhon makinën e gjendjeve dhe punët asinkrone. Moduli i qëndrueshmërisë menaxhon bazën e të dhënave, ndërsa moduli i auditimit regjistron çdo hap të përpunimit.

Kjo ndarje u kontrollua kundrejt importeve të vërteta. Figura 9 është matricë varësish e ndërtuar nga kodi (`scripts/build_figures.py`), dhe tregon se moduli i domenit nuk importon asnjë modul tjetër të aplikacionit, siç pretendohet më sipër. Një version i mëparshëm i kodit tregonte edhe një devijim: një varësi rrethore në nivel paketash mes auditimit, orkestrimit dhe qëndrueshmërisë (`audit.logger` importonte `orchestration.states`, `persistence.repository` importonte `orchestration.process`, dhe `orchestration.tasks` importonte të dyja). Tri llojet e përbashkëta (`Transition`, `Delivery`, `Explanation`, së bashku me `Attempt`) u zhvendosën te `domain.processing`, dhe `orchestration` i ri-eksporton; Figura 9 nuk ka më varësi që kthehet mbrapa, dhe `tests/unit/test_architecture.py` e ruan këtë (domeni nuk importon asgjë; nuk ka cikël paketash).

Ndarja e gjeneruesit të të dhënave dhe e infrastrukturës së vlerësimit në module të veçanta jashtë aplikacionit kryesor pasqyron faktin se ato i shërbejnë kërkimit dhe jo produktit.

4.10 Struktura e databazës




Figura 10. Entity Relationship Diagram (ERD) i databazës.

Baza e të dhënave është projektuar në formë të normalizuar dhe pasqyron rrjedhën e përpunimit. Tabela e përdoruesve lidhet me tabelën e dokumenteve, e cila nga ana e saj lidhet me tabelën e punëve të përpunimit që regjistron gjendjen aktuale të çdo dokumenti në makinën e gjendjeve. Llogaria ka tabelat e veta: users (me kohën e konfirmimit të email-it), email_confirmations (lidhje të ruajtura si HMAC, jo si token), auth_sessions dhe refresh_tokens (seanca të revokueshme), dhe login_failures e registration_attempts (numërues kufizimi me HMAC të email-it dhe të IP-së).

Tabela e gjetjeve laboratorike ruan për çdo analit vlerën e papërpunuar dhe atë të normalizuar, njësinë origjinale dhe atë kanonike, intervalin referent bashkë me burimin e tij, statusin, ashpërsinë dhe pozicionin në dokument. Ruajtja e pozicionit lejon theksimin e zonës burimore në ndërfaqen e përdoruesit.

Terminologjia dhe intervalet referente nuk ruhen në bazë: resources/ është burimi i vetëm, dhe një kopje në bazë do të largohet prej tij. Ruhet vetëm fjalori i secilit dokument, i plotë, që shpjegimi që pa pacienti të mbetet i gjurmueshëm edhe kur tabela ndryshon, bashkë me termat


e pashpjeguar dhe kombinimet e vërejtura. Tabela e pohimeve ruan pohimet e nxjerra nga raporti narrativ, ndërsa tabela e krahasimeve të kryqëzuara lidh pohimet me gjetjet përkatëse.

Tabela e shpjegimeve ruan veçmas daljen e papërpunuar të modelit dhe daljen përfundimtare të shfaqur, bashkë me versionin e kërkesës, modelin e përdorur dhe parametrat e tij. Diferenca ndërmjet dy fushave përbën gjurmën që dëshmon se asnjë tekst i paverifikuar nuk është shfaqur.

Tabela e rezultateve të verifikimit dhe ajo e shkeljeve ruajnë vendimet e shtresës së verifikimit. Kolona që tregon nëse një shkelje është zbuluar nga rregullat apo nga klasifikuesi është burimi i drejtpërdrejtë i të dhënave për krahasimin e tre qasjeve.

Prejardhja e eksperimenteve nuk ruhet në bazën e aplikacionit. Eksperimentet ekzekutohen nga harness-i në linjë komande, dhe çdo rezultat shkruhet si skedar `result.json` me farën e korpusit, versionin e tij, git sha dhe gjendjen e pemës së punës (seksioni 4.11.2.4), që të jetë i rindërtueshëm pa ndërmjetës. Tri tabela të tjera i shërbejnë hyrjes: `auth_sessions`, `refresh_tokens` dhe `login_failures`; e fundit mban email-in dhe adresën IP vetëm si hash me çelës (ADR 0014). Skema e plotë është te Shtojca G.

4.11 Metodologjia e vlerësimit



ID	Eksperimenti	Pyetja	Të dhënat	Metrika	Statusi	Gjurma
E1	Saktësia e nxjerrjes · dixhital	PK1	synthetic-v1	extraction	i matur	e plotë
E2	Saktësia e nxjerrjes · i skanuar	PK1	synthetic-v1	extraction	i matur	e plotë
E3	Klasifikimi i statusit	PK2	synthetic-v1	classification	i matur	e plotë
E4	Besnikëria e thjeshtimit	PK3	synthetic-v1	prose	i matur	e plotë
E5	Krahasimi i kryqëzuar	PK4	synthetic-v1	crossref	i matur	e plotë
E6	Ablacion A · pa bazim	PK5	synthetic-v1	violations	i matur	e plotë
E7	Ablacion B · vetëm bazim	PK5	synthetic-v1	violations	i matur	e plotë
E8	Ablacion C · + verifikim me rregulla	PK5	synthetic-v1	violations	i matur	e plotë
E9	Ablacion D · + klasifikues	PK5	synthetic-v1	violations	i matur	e plotë
E10	Zbuluesi: rregulla	PK6	corruption-test	detector	i matur	e plotë
E11	Zbuluesi: klasifikues	PK6	corruption-test	detector	i matur	e plotë
E12	Zbuluesi: gjykatës LLM	PK6	corruption-test	detector	i matur	pjesore
E13	Vlefshmëria mbi të dhëna reale <i>varet nga miratimi etik dhe nga dokumentet reale</i>	jashtme	real-subset	extraction	i bllokuar	
E14	Kuptueshmëria te përdoruesit · me / pa sistem <i>kërkon pjesëmarrës njerëz (Faza 10)</i>	PK7	n=12-20	comprehension	i bllokuar	
E15	Model lokal kundrejt në re · opsional <i>kërkon një model të dytë gjuhësor</i>	diskutim	synthetic-v1	violations	i bllokuar	

i matur = ekziston një result.json te evaluation/results/E*/ ose evaluation/results/llm/E*/. gati = mund të ekzekutohet, por s'ka rezultat.
 gjurma: e plotë = version korpusi dhe git sha; pa commit = prodhuar me ndryshime të pakomituar
 (sha nuk e përcakton kodin); pjesore = pa metadata të plota.

Figura 11. Tubacioni i vlerësimit dhe gjurmueshmëria e eksperimenteve.

Variablat e pavarura të studimit janë kushti i verifikimit, i cili merr katër vlera nga mungesa e plotë e bazimit deri te verifikimi i plotë; lloji i dokumentit, digjital ose i skanuar; dhe dega e sistemit, laboratorike ose narrative.

Variablat e varura janë F1-Score i nxjerrjes, saktësia e klasifikimit të statusit, norma e pohimeve të pambështetura, precision-i, recall-i dhe F1-Score i detektorit, normat e ruajtjes së mohimit dhe të shprehjeve të pasigurisë, dhe rezultati i kuptueshmërisë në studimin me përdorues.

Bazat krahasuese janë kërkesa naive pa bazim, verifikimi vetëm me rregulla, dhe modeli gjuhësor i përdorur si gjykatës.

4.11.1 Kontrolli i rrjedhjes së të dhënave

Korpusi i korruptuar rrjedh nga dalje të gjeneruara që nga ana e tyre rrjedhin nga një numër i vogël shabllonesh dokumentesh. Një ndarje e rastësishme e këtij korpusi në nivel fjalie do të vendoste fjali pothuajse identike njëkohësisht në grupin e trajnimit dhe në atë të testimit, duke e fryrë artificialisht performancën e matur të klasifikuesit dhe duke e bërë rezultatin e PK6 të pabesueshëm; rrjedhja e të dhënave është shkaku më i zakonshëm i rezultateve të paripërsëritshme në shkencën e bazuar në mësimin makinerik [63].

Prandaj ndarja bëhet në nivel dokumenti burimor, jo në nivel fjalie: asnjë dokument nuk ndodhet në dy grupe, dhe një test e kontrollon këtë. Kjo mbron nga rrjedhja e një dokumenti të vetëm, por nuk mbron nga rrjedhja e shabllonit, dhe matja tregoi se ndarja nuk e ndalon atë: forma e fjalisë (me numrat dhe emrat e hequr) e çdo fjalie me defekt të grupit të validimit gjendet te një fjali e trajnimit (100% për secilin lloj defekti, 99.9% për fjalitë e pastra), dhe çdo gjetje e shpikur nis me të njëjtën shprehje, “Vërehet gjithashtu”. Pasoja është se rezultati i klasifikuesit mbi korpusin sintetik mat sa i njëj shabllonet e gjeneruesit, jo sa zbulon defekte. Prandaj PK6 raportohet edhe mbi grupin B, fjali jashtë gjeneruesit, dhe rezultati sintetik nuk paraqitet si provë e aftësisë së klasifikuesit.

Tabela 7. Matrica e eksperimenteve

ID	Eksperimenti	Kushti	Metrika kryesore	Pyetja
E1	Nxjerrja e të dhënave	dokumente digjitale	Precision, Recall, F1	PK1
E2	Nxjerrja e të dhënave	dokumente të skanuara	Precision, Recall, F1	PK1
E3	Klasifikimi i statusit	—	Saktësi, matricë konfuzioni	PK2
E4	Besnikëria e thjeshtimit	—	Ruajtja e mohimit dhe e pasigurisë	PK3
E5	Krahasimi i kryqëzuar	—	Saktësi katërshe	PK4
E6	Ablacion, kushti A	pa bazim	Normë shkeljesh	PK5

ID	Eksperimenti	Kushti	Metrika kryesore	Pyetja
E7	Ablacion, kushti B	vetëm bazim	Normë shkeljesh	PK5
E8	Ablacion, kushti C	bazim dhe rregulla	Normë që arrin përdoruesin	PK5
E9	Ablacion, kushti D	bazim, rregulla, klasifikues	Normë që arrin përdoruesin	PK5
E10	Detektori me rregulla	—	Precision, Recall, F1	PK6
E11	Detektori me klasifikues	—	Precision, Recall, F1	PK6
E12	Detektori me LLM gjykatës	—	Precision, Recall, F1	PK6
E13	Validimi mbi të dhëna reale	—	F1, hendeku i transferimit	—
E14	Kuptueshmëria e përdoruesit	me dhe pa sistem	Rezultat kuptueshmërie	PK7
E15	Modeli lokal kundrejt atij në re	opsional	Normë shkeljesh	diskutim

4.11.2 Infrastruktura e vlerësimit

Kontributi kryesor i punimit është një mekanizëm verifikimi, dhe vlera e tij shprehet vetëm me numra krahasues. Prandaj infrastruktura që i prodhon ata u ndërtua përpara komponentëve që ajo mat — vendim metodologjik i shpjeguar në seksionin 4.1 dhe i zbatuar në rendin e fazave.

4.11.2.1 Ç’është një “sistem” për vlerësimin

Vlerësimi nuk njihet shtresa. Ai njihet diçka që merr një dokument dhe kthen atë që mendon për të: kontekstin e nxjerrë, tekstin e gjeneruar dhe vendimin e verifikimit. Kushtet e ablacionit të planit të eksperimenteve bëhen kështu zbatime të ndryshme të së njëjtës ndërfaqe, në vend që degë kushtëzimi brenda kodit të prodhimit.

Hyrja që i jepet sistemit mban vetëm identifikuesin e dokumentit dhe shtegun e skedarit. E vërteta bazë nuk kalon kurrë prej andej, dhe kjo ka test të vetin: prej saj varet vlefshmëria e çdo numri që del nga harness-i, dhe një rrjedhje e tillë nuk do të linte asnjë shenjë të dukshme në rezultate.

Çdo kusht ablacioni është sistem më vete, dhe harness-i refuzon ta regjistrojë rezultatin e njërit nën identifikuesin e një tjetri. Pa këtë, një ekzekutim i vetëm i sistemit të plotë do t’i mbushte E6-E9 me të njëjtat numra, dhe matrica do të tregonte një ablacion që nuk ndodhi. Qeliza e një kushti që sistemi nuk e zbaton mbetet [TO BE MEASURED], bashkë me arsyen.

Shablloni determinist luan për gjenerimin rolin që orakulli luan për nxjerrjen: i veshur si gjenerues, ai duhet të japë zero shkelje dhe zero kalime të shablloni rezervë. Mbi 500 dokumente ai jep pikërisht këtë, dhe kështu rruga nga gjeneruesi të qeliza të PK5 është e provuar përpara se të ekzistojë modeli gjuhësor.

Kur kushti rigjeneron, çdo draft i modelit numërohet ndër shkeljet e prodhuara, ndërsa te përdoruesi numërohen vetëm shkeljet e tekstit që ai mori — drafti i pranuar ose shablloni. Po të numërohej vetëm drafti i fundit, shkeljet e përpjekjes së parë, ato që verifikimi i ndali, do të zhdukeshin nga numri i të prodhuarave, dhe verifikimi do të dukej sikur e bën modelin më të mirë në vend që të vendosë çfarë del jashtë.

4.11.2.2 Metrikat

Të gjashtë pyetjet e para kërkimore kanë modulën e vet, dhe të gjitha janë funksione të pastra mbi çiftet e vërtetë–parashikim.

Nxjerrja (PK1) matet për fushë, me çiftim të rreshtave sipas kodit LOINC. Një rresht i humbur nuk është neutral për fushat e tij: ai llogaritet si mungesë për secilën prej tyre. Përndryshe një sistem që nxjerr vetëm rreshtat e lehtë do të dilte i përsosur.

Klasifikimi (PK2) raportohet edhe i ndarë sipas burimit të intervalit, sepse një status i gabuar do të thotë gjithmonë njëra nga dy gjëra: vlera u lexua gabim, ose intervali u zgjodh gabim. Veçmas raportohet edhe mbulimi i vlerave të painterpretueshme — SP5 i shprehur si numër, sepse rastet janë të pakta dhe saktësia e përgjithshme do t'i fshihte.

Shkeljet (PK5) ndajnë shkeljet e prodhuara nga ato që mbërrijnë te përdoruesi. Ky dallim është tërë argumenti i ablacionit: verifikimi nuk e bën modelin më të mirë, ai vendos çfarë del jashtë. Raportohet edhe përpjesa e daljeve që përfunduan në shabllonin determinist — çmimi i verifikimit, pa të cilin një sistem që refuzon gjithçka do të dukej i përkryer.

Zbuluesit (PK6) maten sipas llojit të defektit dhe jo vetëm në tërësi. Pritshmëria e formuluar përpara matjes është se rregullat do të mbizotërojnë te defektet numerike dhe do të humbasin te mohimi dhe pasiguria; një F1 i vetëm i përgjithshëm do ta fshihte plotësisht këtë.

Intervalet e besimit

Shkallët e PK5 dhe ruajtjet e PK3 raportohen me interval besimi 95% me rimostrim bootstrap [61] (2 000 rimostrime, farë e fiksuar). Njësia e rimostrimit është dokumenti dhe jo fjalia, sepse fjalitë e një dokumenti ndajnë kontekstin dhe gabimet e tyre nuk janë të pavarura; rimostrimi sipas fjalisë do ta ngushtonte intervalin pa të drejtë.

Kur mostra nuk ka asnjë ngjarje — zero shkelje, ose ruajtje e plotë — intervali përqindor del me gjerësi zero. Në atë rast raportohet kufiri i rregullit të treshit (3/n) [60]: mbi 500 dokumente (14 016 fjali), shablloni jep 0 shkelje për 100 fjali, me kufi të sipërm 0.021. Kjo

nuk është kujdes formal: “zero shkelje” mbi një mostër të vogël nuk do të thotë se sistemi nuk shkel kurrë.

4.11.2.3 Dy vendime të vogla me pasojë

Metrikat kthejnë vlerë të papërcaktuar kur emëruesi është zero, kurrë zero. “U mat dhe doli zero” dhe “nuk kishte çfarë të matej” janë pohime të ndryshme, dhe tabelat i shtypin ndryshe. Qelizat që presin një komponent të paekzistuar shënohen veçmas dhe nuk lihen bosh.

Dy sisteme shërbejnë si kufij të njohur. Orakulli kthen vetë të vërtetën dhe duhet të arrijë vlerën e përsosur kudo; një metrikë që nuk e arrin dot është e prishur në vetvete, dhe pa këtë kontroll gabimi i saj do të dukej më vonë si dobësi e sistemit të matur. Sistemi bosh nuk nxjerr asgjë dhe nuk duhet të marrë kurrë notë të mirë.

Kufiri i poshtëm e vërtetoi vlerën e vet menjëherë. Sistemi bosh prodhoi ruajtje mohimi 1.000, sepse emëruesi numëronte edhe dokumentet që nuk kishin prodhuar asnjë fjali. Një sistem që nuk shkruan asgjë nuk përmbys asnjë mohim; kjo nuk është besnikëri. Gabimi u gjet përpara se të ishte raportuar ndonjë numër.

4.11.2.4 Prejardhja e rezultateve

Çdo rezultat shkruhet bashkë me farën e korpusit, versionin e tij me shumat kontrolluese të tabelave burimore, sha-në e git-it, gjendjen e pastër ose të papastër të pemës së punës dhe versionin e katalogut të rregullave.

Gjendja e pemës së punës shënohet posaçërisht. Një numër i prodhuar mbi kod të pakommituar nuk është i rindërtueshëm, dhe kjo duhet të duket në skedar e jo të kujtohet nga ai që e ekzekutoi.

Rezultatet e matura me këtë infrastrukturë jepen te Kapitulli 5; gjendja e secilit eksperiment është përmbledhur te Figura 11.

4.12 Politika e sigurisë

Sistemi zbaton një grup politikash sigurie që janë kërkesa formale të implementimit dhe jo rekomandime. Secila prej tyre shoqërohet me një test automatik.

Sistemi nuk emeton asnjë pohim diagnostik, asnjë këshillë trajtimi ose medikamenti, dhe asnjë pohim prognostik. Gjetjet e klasifikuara si kritike shkaktojnë një njoftim eskalimi që shfaqet përpara çdo shpjegimi tjetër. Vlerat për të cilat nuk ekziston interval referent shënohen si të painterpresetueshme dhe nuk klasifikohen. Termat që nuk gjenden në tabelën

terminologjike shënohen si të pashpjeguar dhe nuk përkufizohen. Çdo dalje e sistemit përmban shënimin se sistemi nuk zëvendëson vlerësimin e profesionistit shëndetësor. Dhe në rast dështimi të përsëritur të verifikimit, shfaqet shpjegimi i gjeneruar nga shablloni determinist.

Sistemi mban dy gjurma të ndara.

Regjistri i auditimit (`audit_events`) mban ngjarje: ngarkimin (madhësia dhe sha-ja e skedarit), çdo kalim gjendjeje me arsyen teknike, dështimin e përpunimit (vetëm lloji i gabimit), fshirjen e dokumentit, ngjarjet e seancave, mbushjen e kovave të kufizimit dhe dështimin e dërgimit të email-it (vetëm lloji i gabimit). Ai nuk mban emra, email-e, adresa IP, vlera laboratorike apo tekst të gjeneruar: funksionet që e shkruajnë nuk i pranojnë (NFR5).

Gjurma e përpunimit ruhet te tabelat e domenit, jo te regjistri: gjetjet e nxjerra me koordinata, pohimet, fjalori dhe termat e pashpjeguar të dokumentit, kombinimet, çdo përpjekje gjenerimi me tekstin e saj, rezultati i verifikimit dhe shkeljet e zbuluara, dhe cila përpjekje u dorëzua. Ajo i shfaqet pronarit të dokumentit si «si u kontrollua». Kërkesa e dërguar modelit nuk ruhet: rindërtohet nga konteksti dhe nga versioni i kërkesës që mban emri i gjeneruesit. Dokumenti origjinal ruhet i koduar dhe fshihet kur fshihet dokumenti.

Llogaria dhe hyrja (ADR 0014, 0016). Llogaria aktivizohet vetëm pasi email-i të konfirmohet me një lidhje të dërguar me SMTP (në zhvillim, kutia e provës e Mailtrap); lidhja vlen një herë dhe skadon, dhe ruhet vetëm si HMAC. Regjistrimi kthen gjithmonë të njëjtën përgjigje, qoftë email-i i ri, i regjistruar apo i pakonfirmuar, dhe mesazhi dërgohet pas përgjigjes, që as përmbajtja as koha të mos tregojnë nëse ka llogari; zotëruesi i kutisë merr mesazhin që i përgjigjet rastit. Hyrja e dështuar ka një përgjigje të vetme, dhe tri kova (çifti email-IP, IP-ja, email-i) kufizojnë shpeshtësinë e përpjekjeve; adresat IPv6 numërohen sipas prefiksit /64, që një bllok adresash të mos i anashkalojë kovat. Regjistrimet dhe ridërgimet kanë kovat e veta (10 për IP dhe 3 për email në orë), që shërbimi të mos bëhet pikë për të mbushur kutinë e dikujt. Fjalëkalimet ruhen me Argon2id; seancat janë të revokueshme dhe tokeni i rifreskimit vlen një herë, me zbulim të ripërdorimit; përdoruesi mund të mbyllë seancën e tij ose të gjitha seancat («dil kudo»). Nuk ka rivendosje fjalëkalimi dhe nuk ka autentikim me dy faktorë (§6.6).

Gjenerimi në aplikacion (ADR 0017). Parazgjedhja është shablloni determinist dhe asnjë e dhënë nuk del nga sistemi. Modeli ndizet vetëm me `ANALYTE_SERVICE_GENERATOR=model`, një çelës i ndarë nga ofruesi që eksperimentet kërkojnë te `.env`. Atëherë ofruesit i dërgohet

vetëm konteksti i strukturuar (vlera, intervale, statuse, termat dhe citimet e mjekut; kurrë emri, mosha, gjinia apo skedari), pa cache në disk, me të njëjtin cikël verifikim, një rigjenerim dhe shabllon rezervë, dhe teksti i modelit mban njoftimin se e shkroi një model dhe se kontrolli kap vetëm një pjesë të gabimeve. Ndryshe nga eksperimentet, këtu të dhënat mund të jenë të pacientëve të vërtetë, çka kërkon vendim etik (§2.7.3, docs/ethics).

Hardimi i llogarisë (ADR 0018). Rivendosja e fjalëkalimit, hapi i dytë i hyrjes dhe rindërgimi i mesazheve janë të zbatuara dhe të provuara me teste (përfshirë prishje të qëllimshme). Kërkesat për rivendosje kthejnë gjithmonë të njëjtën përgjigje, tokenët ruhen vetëm si HMAC dhe shpenzohen një herë me një UPDATE të kushtëzuar; pas rivendosjes çdo seancë e përdoruesit revokohet, dhe rivendosja nuk e konfirmon kurrë një llogari të pakonfirmuar (një llogari e tillë merr lidhje konfirmimi, jo rivendosjeje). Hapi i dytë është TOTP sipas RFC 6238 (SHA-1, 30 s, 6 shifra, dritare ± 1), i realizuar me bibliotekën standarde dhe i provuar me vektorët e RFC-së; sekreti ruhet i koduar me çelësin Fernet të ruajtjes dhe kodet e rimëkëmbjes (8, njëpërdorimshe) vetëm si HMAC me çelës; një hap kohe i pranuar nuk pranohet dy herë, dhe kodet e gabuara kufizohen para se të kontrollohen. Mesazhet me lidhje kanë një regjistër dërgimi pa adresa; një mesazh që nuk u dërgua rindërgohet nga punëtori me një token të ri (i vjetri nuk rikthehet, sepse ruhet vetëm HMAC-i), me kufi ditor për përdorues. API-ja dhe ndërfaqja vendosin Referrer-Policy: no-referrer, X-Content-Type-Options: nosniff dhe X-Frame-Options: DENY.

Mbrojtja e të dhënave (ADR 0019). Kontrollat teknike i bëjnë vendimet e autorit të zbatueshme, jo pohime për kushtet e ofruesve. Modeli është i fikur si parazgjedhje; kur shërbimi e ka të ndezur, një dokument dërgohet te ofruesi vetëm nëse pacienti ka shënuar një kuti pëlqimi për atë ngarkim (e pashënuar si parazgjedhje, e ruajtur me kohë dhe e regjistruar te regjistri i auditimit pa të dhëna personale). Pa pëlqim shpjegimi del nga shablloni determinist dhe asnjë kërkesë nuk i dërgohet ofruesit. Edhe me pëlqim, citimet e mjekut dhe termat e pashpjeguar kalojnë një portë çidentifikimi që dështon e mbyllur: nëse shënohet emër, titull, datë, telefon, email, numër i gjatë, identifikues, moshë ose adresë, dokumenti nuk dërgohet fare dhe pacienti merr njoftim. Citimi nuk redaktohet kurrë, sepse R5, R6 dhe R8 e krahasojnë daljen me citimin origjinal dhe pacienti duhet ta shohë të pandryshuar. Pacienti mund ta fshijë një dokument ose gjithë llogarinë (me fjalëkalimin aktual) dhe t'i eksportojë të dhënat e veta; afati i ruajtjes është i konfigurueshëm (i fikur si parazgjedhje). Fshirja heq rreshtat, gjithçka të derivuar dhe skedarin e koduar; regjistri i auditimit mbetet pa identifikues përdoruesi dhe pa sha të skedarit. Baza ligjore, kushtet e ofruesit dhe miratimi etik nuk

vendosen nga sistemi dhe mbeten vendim i autorit; kuadri ligjor përshkruhet te seksioni 2.7.3 [58], [59].

Çfarë përdor shërbimi dhe çfarë u mat (ADR 0020, 0021). Shërbimi verifikon me katalogun r1.4 dhe lexon faqet e OCR-së me kontrollin e besueshmërisë; eksperimentet e ngrira (E4, E6–E11, grupet A, B, C) u matën me r1.3 dhe pa kontrollin, që rezultatet dhe cache-i i përgjigjeve të modelit të mbeten të vlefshme. Dallimi shkon te pipeline-t e harness-it (rules="r1.3", ocr_guard=False si parazgjedhje) dhe matjet e r1.4 dhe të kontrollit raportohen veçmas (§5.3.1, §5.6.2, §5.7.3). Klasifikuesi i fjalive nuk është pjesë e shërbimit (ADR 0022).

5 REZULTATET

Çdo vlerë numerike e këtij kapitulli lexohet nga një skedar rezultatesh te `evaluation/results/`, dhe tabelat 9, 10, 14, 15, 17, 19 dhe 22–24 gjenerohen prej tyre nga `scripts/build_chapter6_tables.py`, pa kopjim me dorë. Pjesa që nuk është matur është thënë si e tillë: nuk u kryen E13 (dokumente reale), E14 (studimi me përdorues) dhe E15 (modeli lokal kundrejt atij në re), dhe seksionet përkatëse e thonë këtë në vend që të japin një vlerë.

Prejardhja. E1, E2, E3 dhe E5 u ekzekutuan më 2026-10-02 nga një kopje e pastër e `commit-it 37b5be4 (working_tree_dirty: false)`, mbi korpusin `gen-1.0/s42/n500/37d8b080` (500 dokumente, prej tyre 332 dixhitale dhe 168 të skanuara); po ashtu E7–E9 me shabllonin si gjenerues (`evaluation/results/E7–E9`). Eksperimentet me modelin gjuhësor (E4, E6, E7, E8, E9; `evaluation/results/llm/`) u ekzekutuan më 2026-10-04 nga një kopje e pastër e `commit-it 4f5ea17`, mbi të njëjtin korpus. Gjeneruesi është `Mistral ministral-14b-2512` në planin falas, me kërkesën p1 për kushtet B–D dhe u1 për kushtin A, temperaturë 0 (ADR 0015). Përgjigjet e modelit lexohen nga `cache-i` i `commit-uar (evaluation/cache/llm/)`: katër nga pesë ekzekutimet e pastra nuk bënë asnjë thirrje të re; E6 bëri dy, për dy dokumente që në ekzekutimin e parë nuk kishin marrë përgjigje të vlefshme (përgjigjet e dështuara nuk ruhen kurrë). E10 dhe E11 u ekzekutuan më 2026-10-05 nga një kopje e pastër e `commit-it 34fa710 (working_tree_dirty: false)`, dhe rezultatet e tyre mbajnë sha-n e kodit dhe një identifikues të të dhënave: për E10 versioni i gjeneruesit, fara, madhësia dhe një shumë kontrolluese e tabelave burimore që nuk varet nga mbarimet e rreshtave; për E11 një shumë kontrolluese e parashikimeve të Colab-it që u lexuan. Metrikat dolën identike me ato të mëparshme. Katër rezultate kanë prejardhje më të dobët. Parashikimet e E11 u prodhuan në Colab (GPU Tesla T4, `xlm-roberta-base`, 3 epoka, fara 42), dhe `run.json` ruan versionet e bibliotekave por jo sha-n e kodit të trajnimit. Rezultati i klasifikuesit dhe ai i gjykatësve mbi grupin B (`kit_B.json`) nuk mbajnë metadata; rezultati i rregullave mbi B rillogaritet nga `python -m evaluation.kits check` dhe nuk ruhet si skedar. Dhe E12 dhe auditi i E8 nuk kanë sha git: gjykatësi është një model Claude i thirrur nga Claude Code si subagjent, kështu që rezultati rillogaritet nga përgjigjet e ruajtura (`answers_*.jsonl`) dhe çelësin e etiketave, jo nga një ekzekutim i përsëritshëm i kodit (§5.7.2). Korpusi i vetë (`data/v1`) pati një kufizim që u mbyll më 2026-10-05: `manifest.json` ruan shumat kontrolluese të bajteve të papërpunuara të `resources/*.csv`, dhe me `core.autocrlf=true` një kopje e re nga git kishte mbarime rreshtash të ndryshme

për terminology.csv dhe patterns.csv, kështu që versioni gen-1.0/s42/n500/37d8b080 nuk rindërtohej. Skedari .gitattributes (resources/*.csv -text) e ndalon konvertimin dhe depoja ruan tani saktësisht bajtet që u hashuan; python scripts/verify_corpus.py i krahason tabelat me manifestin, dhe u provua në një kopje të re që të pesë përputhen (para kësaj, 2 nga 5 nuk përputheshin). Versioni i korpusit nuk ndryshoi, prandaj asnjë rezultat nuk u ribë. Kufizim i mbetur: kur autori plotëson burimet te terminology.csv ose patterns.csv, shuma e tyre ndryshon dhe korpusi duhet ribërë ose manifesti ripërcaktuar.

Pasiguria. E4, E6, E7, E8 dhe E9 kanë intervale besimi (bootstrap në nivel dokumenti, 2 000 rimostrime); audit i E8 ka intervale Wilson 95% [62]. Të gjitha vlerat e tjera janë vlerësime pikësore. Grupi B ka 105 fjali dhe 5 deri 10 për çdo lloj defekti, ndaj një fjali e vetme e ndryshon F1 të një lloji me 0.05 deri 0.2, dhe asnjë diferencë mes dy detektorëve mbi B nuk është provuar statistikisht.

Ndryshimet e bëra pasi u pa një rezultat. Katër metoda u ndryshuan pasi rezultati i mëparshëm ishte parë, dhe lexuesi duhet t'i dijë:

1. Nxjerrësi filloi të refuzojë intervalet e lexuara si «vlerë me njësi» (ADR 0012). Vlerat e gabuara të pranura nga skanimi ranë nga 271 në 125.
2. Rregullat e verifikimit u rregulluan nga r1.1 në r1.3 pasi E10 dha 0.979 për herë të parë; macro F1 përfundimtar është 0.993. Rregullimet vijnë nga kontekste të ndërtuara me dorë dhe nga ndërfaqja, jo nga gabimet e mostrës së testit, por ato u bënë pasi testi ishte parë (ADR 0009).
3. F1 për një klasë që detektori e humb plotësisht kthehej None dhe mesatarja e anashkalonte; u korrigjua në $2TP/(2TP+FP+FN)$. Pragu i klasifikuesit i zgjedhur me macro F1 maksimal ignoronte alarmet e rreme, prandaj u shtua një rregull i dytë (jo më shumë se 5% e teksteve të pastra të validimit të bllokuara). Të dyja ndodhën pasi testi ishte parë, dhe E11 raporton të dy rregullat (ADR 0009).
4. Vlerësuesi i grupit B u ndryshua pasi matja e parë dha 0 nga 20 për fjalitë me citim: fjalia futej në fund të shabllonit dhe rregullat gjykonin citimin e parë, kështu që fjalia zëvendëson citimin burimor (ADR 0009).

Asnjë metodë nuk u ndryshua pasi u panë rezultatet e modelit. Kërkesa p1 u shkrua përpara ekzekutimit të parë dhe nuk u ndryshua pas tij; rregullat mbetën r1.3; audit i E8 u shtua sepse metrika e PK5 matet me rregullat që e bllokojnë tekstin, jo sepse rezultati i saj nuk i pëlqeu autorit (§5.6.1).

5.1 Rezultatet e implementimit të sistemit

Sistemi është zbatuar i plotë përveç chat-it të lidhur me dokumentin, që nuk është ndërtuar (shërbimi kthen 501). Gjeneruesi është ose shablloni determinist (teksti rezervë dhe kushti i kufirit) ose një model gjuhësor përmes një klienti të përgjithshëm me cache (ADR 0015). Ç’është ndërtuar dhe ç’u mat:

Tabela 8. Përbërësit e sistemit dhe gjendja e tyre e matur

Përbërësi	Gjendja e matur
Paneli i analiteve	38 analite me hartëzim LOINC (Tabela 3)
Tabela terminologjike	82 terma shqip, pa burime të shënuara (Shtojca A)
Kombinimet ndërmjet analiteve	11 rregulla, pa burime të shënuara (Tabela B.3)
Katalogu i verifikimit	r1.3: R1–R9 dhe SP1–3, dhjetë lloje shkeljesh (Tabela 6)
Modeli gjuhësor	Mistral ministral-14b-2512 (plan falas) përmes ChatClient me cache të përgjigjeve në depo, kufizim shpejtësie dhe rifreskim; kërkesa p1 merr vetëm GroundingContext (ADR 0015, Shtojca D). Te eksperimentet përdoret gjithmonë; te aplikacioni i uebit vetëm kur zgjidhet shprehimisht (ANALYTE_SERVICE_GENERATOR=model , pa cache në disk, me njoftim për pacientin; ADR 0017), dhe parazgjedhja është shablloni (§6.6, pika 12)
Gjykatësit e detektimit	Claude Sonnet dhe Haiku (subagjentë), 15 batch-e me 20 mostra secili, dhe një audit i tekstit të dorëzuar (§5.7.2, §5.6.1)
Kanali i leximit	Tekst dixhital dhe OCR (Tesseract 5, eng, - - psm 6, 200 dpi)
Shërbimi	API me autentikim të forcuar (konfirmim email-i, kufizim hyrjesh dhe regjistrimesh, seanca të revokueshme, dil kudo), regjistër auditimi, ruajtje e enkriptuar (ADR 0013, 0014, 0016)
Ndërfaqja	Next.js në shqip: regjistrimi me konfirmim email-i, hyrja, dil kudo, ngarkimi, historiku, hapat e përpunimit, njoftimi për vlera kritike, paralajmërimi i OCR-së, shpjegimi me treguesin e verifikimit, tabela e gjetjeve ku një klikim hedh dritë mbi rreshtin burimor
Vendimet arkitekturore	22 ADR (docs/adr/)
Testet	987 kalojnë, 0 anashkalohen (me testet e integritetit mbi PostgreSQL 16; pa ANALYTE_TEST_DATABASE_URL testet e PostgreSQL anashkalohen)

Korpusi sintetik i vlerësimit ka 500 dokumente (332 dixhitale, 168 të skanuara, 556 faqe), me 9 860 gjetje laboratorike, 2 749 pohime narrative dhe 36 dokumente me të paktën një vlerë kritike. Korpusi i korruptuar del nga 1 500 dokumente për trajnimin dhe validimin e klasifikuesit dhe nga 200 dokumente burimore për testin (192 mostra, E10 dhe E11); rrjedhja e dokumenteve ndërmjet trajnimit dhe validimit është zero (E11/leakage.json).

Pamjet 12–16 janë prodhuar nga aplikacioni që punon (python scripts/export_screenshots.py) mbi një dokument sintetik (doc_00335.pdf, korpusi gen-1.0/s42/n500/37d8b080; dixhital, me një vlerë kritike dhe një kundërshtim raport–laborator) dhe një përdorues prove. Shpjegimi është ai i **shabllonit determinist**, parazgjedhja e aplikacionit: skripti ndërton shërbimet e veta me të, që pamjet të mos varen nga një ofrues i jashtëm. Me modelin e lidhur (§6.6, pika 12), shumë dokumente (te eksperimentet rreth 25%)

dalin me shabllonin rezervë dhe njoftimin përkatës. Emrat e pacientëve në dokument janë të shpikur nga gjeneruesi.




Figura 12. Faqja e autentikimit të sistemit.




Figura 13. Hapat e përpunimit të dokumentit të ngarkuar, ndërsa ndodhin.

Çdo shenjë e plotësuar është një kalim i regjistruar në shërbim. Përpunimi u ngadalësua qëllimisht (4 sekonda te gjeneruesi) që hapi i tanishëm të duket.

Vlerat		14 vlera - 4 jashtë intervalit	
ANALITI	VLERA	INTERVALI REFERENT	STATUSI
Hematokrit Ht	64.5 %	36.0 – 48.0	Dukshëm e lartë
Volumi mesatar eritrocitar MCV	104.4 fL	79.8 – 100.1	E lartë
Kolesterol HDL HDL-kolesterol	45 mg/dL	50 – 85	E ulët
Kolesterol LDL LDL	158 mg/dL	50 – 130	E lartë
Hemoglobinë në gjak HGB	14.2 g/dL	12.0 – 16.0	Normale
Eritrocite Qelizat e kuqe	4.56 10 ¹² /L	4.00 – 5.20	Normale
Leukocite Leukocitet	7.0 10 ⁹ /L	4.0 – 10.0	Normale
Hemoglobina mesatare eritrocitare MCH	28.3 pg	27.0 – 33.0	Normale
Përqendrimi mesatar i hemoglobinës MCHC	34.2 g/dL	31.9 – 36.0	Normale
Glukozë në serum Glukoza (esëll)	83 mg/dL	70 – 99	Normale
Hemoglobinë e glikuar Hemoglobina e glikuar	4.6 %	4.0 – 5.6	Normale
Kolesterol total Kolesterol	172 mg/dL	120 – 200	Normale
Trigliceride Trigliceridet	121 mg/dL	50 – 150	Normale
Proteina C-reaktive CRP	3.5 mg/L	0.0 – 5.0	Normale

Dokumenti original

Laboratori Biomjekësor Vita

Pacienti: Mirela Kelmendi
Gjina: Femër
Moshë: 54 vjeç

Data e analizës: 02.09.2025
Nr. i protokollit: A6D0BA01
Materiali: gjak venoz

Analiti	Rrezultati	Njësia	Intervali referent
HEMOGRAMË E PLOTË			
HGB	14.2	g/dL	12.0 - 16.0
Ht	64.5	%	36.0 - 48.0
Qelizat e kuqe	4.56	10 ¹² /L	4.00 - 5.20
Leukocitet	7.0	10 ⁹ /L	4.0 - 10.0
MCV	104.4	fL	79.8 - 100.1
MCH	28.3	pg	27.0 - 33.0
MCHC	34.2	g/dL	31.9 - 36.0
BIOKIMI BAZË			
Glukoza (esëll)	83	mg/dL	70 - 99
Hemoglobina e glikuar	4.6	%	4.0 - 5.6
PROFILI LIPIDIK			
Kolesterol	172	mg/dL	120 - 200
HDL-kolesterol	45	mg/dL	50 - 85
LDL	158	mg/dL	50 - 130
Trigliceridet	121	mg/dL	50 - 150
TREGUES INFLAMACIONI			
CRP	3.5	mg/L	0.0 - 5.0

VLERËSIMI I MJEKUT
Analizat janë kryer me kërkues të mjekut familjar. Hematokriti dhe mbi intervalin referent. LDL-kolesterolit është brenda kufijve referentë. Leukocitet nuk dalin nën intervalin referent. Nuk vërehet shprehja të hemolizës. Funkcioni renal është vlerësuar në të mirë. Rekomandohet konsulti me mjekun specialist. Rekomandohet vlerësim klinik i mëtejshëm.

Mjeku përgjegës: Dr. A. Krasniq

Figura 14. Gjetjet laboratorike të strukturuar.

Vlera, intervali referent dhe statusi; klikimi mbi një vlerë e theksoi rreshtin burimor te faqja origjinale.

Shpjegimi

✓ I kontrolluar · asnjë shkelje e gjetur

Për Hemoglobinë në gjak vlera e matur është 14.2 g/dL, brenda intervalit referent (12 - 16).

Për Hematokrit vlera e matur është 64.5 %, dukshëm mbi intervalin referent (36 - 48).

Për Eritrocite vlera e matur është $4.56 \cdot 10^{12}/L$, brenda intervalit referent (4 - 5.2).

Për Leukocite vlera e matur është $7 \cdot 10^9/L$, brenda intervalit referent (4 - 10).

Për Volumi mesatar eritrocitar vlera e matur është 104.4 fL, mbi intervalin referent (79.8 - 100.1).

Për Hemoglobina mesatare eritrocitare vlera e matur është 28.3 pg, brenda intervalit referent (27 - 33).

Për Përqendrimi mesatar i hemoglobinës vlera e matur është 34.2 g/dL, brenda intervalit referent (31.9 - 36).

Për Glukozë në serum vlera e matur është 83 mg/dL, brenda intervalit referent (70 - 99).

[Lexo të gjithë shpjegimin \(11 fjali të tjera\)](#)

Çfarë ka shënuar mjeku

Fjalë për fjalë nga raporti — sistemi nuk i riformulon.

Hematokriti del mbi intervalin referent.

LDL -kolesteroli është brenda kufijve referentë.

Leukocitet nuk dalin nën intervalin referent.

Nuk vërehen shenja të hemolizës.

Funksioni renal është vlerësuar në tërësi.

Rekomandohet konsultë me mjekun specialist.

Rekomandohet vlerësim klinik i mëtejshëm.

Ky shpjegim është automatik dhe nuk zëvendëson vlerësimin e profesionistit shëndetësor. Për çdo vendim mjekësor konsultohuni me mjekun tuaj.

Figura 15. Shpjegimi në gjuhë të thjeshtë me treguesin e verifikimit, dhe fjalët e mjekut të vendosura veçmas, fjalë për fjalë.

Për t'u diskutuar me mjekun

"LDL -kolesteroli është brenda kufijve referentë"

Nuk përputhet me vlerën — vlera e matur: 158 mg/dL (e lartë)

Figura 16. Krahësimi i raportit mjekësor me rezultatet laboratorike.

Fjalë e mjekut që nuk përputhet me vlerën e matur, e shfaqur si «për t'u diskutuar me mjekun».

5.2 Saktësia e nxjerrjes së të dhënave laboratorike

Rezultatet i përgjigjen PK1 (E1 dhe E2).

Tabela 9. Saktësia e nxjerrjes së të dhënave laboratorike (E1 dhe E2)

Fusha	Precision (dig.)	Recall (dig.)	F1 (dig.)	Precision (skan.)	Recall (skan.)	F1 (skan.)
Emri i analitit	1.000	1.000	1.000	0.996	0.697	0.820
Vlera numerike	1.000	1.000	1.000	0.947	0.663	0.780
Njësia	1.000	1.000	1.000	0.781	0.547	0.643
Intervali referent	1.000	1.000	1.000	0.532	0.372	0.438
Mikro-mesatarja	1.000	1.000	1.000	0.814	0.570	0.670

Dixhitale: 332 dokumente, 6 472 vlera për çdo fushë. Të skanuara: 168 dokumente, 3 388 vlera për çdo fushë, OCR i ndezur.

Kanali dixhital. Të katër fushat dalin 1.000. Kjo vlerë nuk provon që nxjerrja është e zgjidhur: ajo thotë se tubacioni është lidhur saktë mbi një korpus që vizaton tekst të pastër në koordinata të njohura (§4.3.7). Vendimi për të mos e vështirësuar korpusin u mor më 2026-09-27, dhe vlefshmëria e jashtme mbështetej te E13, që nuk u krye.

Kanali i skanuar. Mikro-F1 është 0.670, me një rënie të dukshme sipas fushës: analiti 0.820, vlera 0.780, njësia 0.643, intervali 0.438. Treguesi që ka rëndësi nuk është F1 por saktësia e vlerës, 0.947: nga 2 370 vlera të nxjerra nga skanimet, **125 janë të gabuara dhe pranohen.** Një vlerë e humbur nuk interpretohet; një vlerë e gabuar interpretohet me siguri dhe asgjë më poshtë në rrjedhë nuk e vë re (ADR 0012). Pjesa tjetër e gabimeve është e gjatë por më pak e rrezikshme: 1 028 nga 3 388 vlera (30.3%) nuk u nxorën fare, sepse emri i analitit nuk u njoh; 518 nga 2 370 njësitë e nxjerra dhe 1 108 nga 2 370 intervalet e nxjerra nuk përputhen me të vërtetën. Pasoja e këtyre te statusi matet te §5.3.

Numri 125 është pas korrigjimit të përmendur më sipër (271 në matjen e parë).

5.3 Saktësia e klasifikimit kundrejt intervaleve referente

Rezultatet i përgjigjen PK2 (E3). Matja bëhet mbi gjetjet që nxjerrësi i përputhi me një gjetje të së vërtetës: 8 832 nga 9 860 vlera të korpusit të plotë (me OCR). Pjesa tjetër, 1 028 vlera të pa-nxjerra, është jashtë bazës së PK2 dhe u raportua te §5.2.

Tabela 10. Saktësia e klasifikimit të statusit (E3, tërë korpusi, me OCR)

Statusi i vërtetë	Mbështetja	Precision	Recall	F1
normal	6930	1.000	0.873	0.932
high	960	0.990	0.907	0.947
low	740	0.941	0.899	0.919
critical_high	24	0.667	0.917	0.772
critical_low	9	1.000	0.778	0.875
uninterpretable	169	0.146	1.000	0.255
Të gjitha	8832			saktësia 0.881

Mbi dokumentet dixhitale saktësia është 1.000 (6 472 vlera), pra e gjithë rënia te 0.881 vjen nga kanali i skanuar. Pjesa tjetër e matricës së konfuzionit:

Tabela 11. Matrica e konfuzionit të E3.

Rreshti është statusi i vërtetë, kolona statusi i dhënë nga sistemi.

e vërtetë ↓ / e parashikuar →	normal	high	low	critical_high	critical_low	uninterpretable
normal	6050	9	36	9	0	826
high	0	871	6	1	0	82
low	0	0	665	0	0	75
critical_high	0	0	0	22	0	2
critical_low	0	0	0	1	7	1
uninterpretable	0	0	0	0	0	169

Si lexohet. Nga 8 832 vlera, 7 784 morën statusin e saktë. Të tjerat ndahen në dy grupe që nuk kanë të njëjtin kuptim:


- **986 vlera (11.2%) u bënë uninterpretable** pa qenë të tilla, sepse intervali nuk u lexua dhe SP5 refuzoi interpretimin. Këto janë gabime të sigurta: përdoruesi nuk merr shpjegim për vlerën, por nuk merr as shpjegim të gabuar. Kjo shpjegon saktësinë 0.146 të klasës uninterpretable: shumica e parashikimeve të saj janë refuzime të sigurta.
- **62 vlera (0.70%) morën një status të interpretuar dhe të gabuar.** Prej tyre 11 u shënuan kritike të larta pa qenë të tilla: 9 vlera normale, 1 e lartë dhe 1 kritike e ulët. Këto janë rastet që një kontroll besueshmërie do t'i ndalte; ai nuk ekziston (§5.10).

Të 169 vlerat pa interval referent në dokument u njohën të gjitha si uninterpretable (recall 1.000): SP5 refuzoi secilën.

Tabela 12. Saktësia e statusit sipas burimit të intervalit (E3)

Burimi i intervalit	Vlera	Pjesa	Saktësia e statusit
dokumenti	6782	0.767	0.877
tabela e brendshme	1881	0.214	0.885
asnjë (pa interval)	169	0.019	1.000

Rreth 77% e vlerave kanë intervalin nga dokumenti dhe 21% nga tabela e brendshme. Saktësia ndërmjet të dyjave ndryshon pak (0.877 dhe 0.885), prandaj gabimet nuk vijnë nga burimi i intervalit por nga leximi.



Ngjyra është pjesa e rreshtit (recall); numri është numërimi. 8 832 vlera të përputhura.

Figura 17. Matrica e konfuzionit për klasifikimin e statusit (E3, tërë korpusi, me OCR).

Ngjyra është pjesa e rreshtit (recall), numri brenda është numërimi; e gjithë rënia nga diagonali është nga kanali i skanuar. Të dhënat: `evaluation/results/E3/result.json`.

5.3.1 Kontrolli i besueshmërisë për vlerat e lexuara nga OCR-ja

62 statuse të interpretuara dhe të gabuara dhe 11 kritike të rreme (më sipër) kanë një shkak të vetëm: presja dhjetore që OCR-ja e humb, te intervali i shtypur (42 raste: “2,5 – 4,5” lexohet “25 – 45”) ose te vlera (20 raste: “46,6” lexohet “466”). Një kontroll i ngushtë (ADR 0020) e trajton secilin vetëm te faqet e OCR-së, me tri hapa: (1) intervali i shtypur që është 10, 100

ose 1000 herë ai i tabelës së brendshme hidhet dhe përdoret tabela; (2) vlera e shtypur pa presje që del mbi intervalin dhe brenda tij pas një ose dy presjesh nuk merret fare; (3) një përqindje e lexuar mbi 100 nuk merret (e pamundur nga përkufizimi, pa nevojë për burim mjekësor). U mat me python -m evaluation.ocr_guard_report, që e lexon çdo dokument të skanuar një herë dhe nxjerr dy herë mbi të njëjtat faqe:

Tabela 13. Efekti i kontrollit të besueshmërisë së OCR-së mbi 168 dokumentet e skanuara

	pa kontroll	me kontroll
Statuse të interpretuara dhe të gabuara	62	0
Prej tyre kritike të larta pa qenë	11	0
Rreshta të krahasueshëm me të vërtetën	2 360	2 337
Vlera të lexuara gabim ndër ta	64	41
Të interpretueshme që u bënë të paiminterpretueshme	986	1 006

23 rreshta u refuzuan nga kontrollët e vlerës; të 23 kishin vlerë të lexuar gabim, asnjë të saktë, dhe 46 intervale u zëvendësuan nga tabela. Në harness (--ocr --ocr-guard): F1 i nxjerrjes $0.670 \rightarrow 0.669$, saktësia e statusit $0.881 \rightarrow 0.886$, E5 (krahasimi i kryqëzuar) $0.863 \rightarrow 0.861$.

Si lexohet. Kontrolli u projektua pasi u panë gabimet e E3 mbi këto dokumente (dy hapat e parë; i treti pasi mbetën dy gabime që zhvendosja e presjes nuk i kapte), dhe pragjet (10, 100, 1000; toleranca 15%) u zgjodhën me to; numrat tregojnë sa e kap defektin e njohur, jo përgjithësimin. Çmimi i tij është një rresht i humbur, jo një status i gabuar; një vlerë e vërtetë e shtypur pa presje që plotëson kushtin do të humbiste (te korpusi sintetik kjo nuk ndodh, te dokumentet reale formati i laboratorëve është i panjohur). Nuk u shtua kontroll me kufij fiziologjikë absolutë: ata kërkojnë burime të lexuara që nuk ekzistojnë, dhe asnjë kufi nuk u shpik. Një vlerë e lexuar gabim që del brenda intervalit (4,35 për 4,3) nuk kapet. Shërbimi e ka kontrollin të ndezur; §5.6.2 e jep efektin mbi ablacionin.

5.4 Besnikëria e thjeshtimit të tekstit mjekësor

Rezultatet i përgjigjen PK3 (E4), mbi 500 dokumente me modelin ministeral-14b-2512 në kushtin C: drafti i fundit i modelit para dorëzimit (5 935 fjali).

Tabela 14. Besnikëria e thjeshtimit (E4)

Metrika	Vlera	Numëruesi
Norma e ruajtjes së mohimit	0.994 [95%: 0.985–1.000]	327 nga 329 pohime të mohuara
Norma e ruajtjes së shprehjeve të pasigurisë	1.000 [95%: ≥ 0.974]	114 nga 114 pohime me rezervë
Norma e gjetjeve të shpikura	0.51 për 100 fjali	30 gjetje në 5935 fjali
Norma e rekomandimeve të humbura	0.049	30 nga 612 rekomandime
Gjatësia mesatare e fjalisë, burim	nuk matet	—

Metrika	Vlera	Numëruesi
kundrejt dalje		
Raporti i termave mjekësorë, burim kundrejt dalje	nuk matet	—
Vlerësimi i ekspertëve, shkallë Likert	nuk matet (nuk u krye rishikim ekspertësh)	—

Si lexohet. Tri kufizime e ndryshojnë kuptimin e këtyre numrave:

1. **Matet ndjekja e udhëzimit të kopjimit, jo thjeshtimi.** Kërkesa p1 e urdhëron modelin t'i kopjojë pohimet e mjekut fjalë për fjalë me parashtesën «Mjeku ka shënuar:». Ruajtja e mohimit (327 nga 329) dhe e rezervës (114 nga 114) tregon se modeli e zbatoi këtë udhëzim, jo se thjeshtoi një prozë të vështirë pa ndryshuar kuptimin. PK3 në formën e planifikuar (parafrazim i prozës klinike) nuk u mat, sepse kërkesa e gjeneruesit e ndalon parafrazimin e citimeve (Shtojca D.2).
2. **Numëruesi vjen nga rregullat.** PK3 numëron gabimet që R5–R8 shohin: polaritetin, rezervën, gjetjen e shpikur, rekomandimin e humbur. Kur një rregull nuk e sheh një gabim, PK3 tregon ruajtje të përsosur. Rregullat arrijnë F1 1.00 për polarity_flip dhe hedge_removed te grupi B (§5.7), prandaj numrat e mohimit dhe të rezervës janë më të besueshëm se ai i gjetjeve të shpikura, ku auditi (§5.6.1) gjen probleme që rregullat nuk i numërojnë.
3. **Mbështetja e rezervës është e vogël:** 114 pohime; kufiri i poshtëm 95% i ruajtjes është 0.974.

Dy gabime të mohimit (polarity_flip) u prodhuan nga 329 pohime të mohuara. Humbja e rekomandimeve është më e dukshme: 30 nga 612 (4.9%) mungojnë nga drafti, dhe R8 i kap ato, prandaj te kushtet C dhe D ato shkojnë te regjenerimi ose te shablloni. Gjatësia mesatare e fjalisë, raporti i termave dhe vlerësimi i ekspertëve nuk u matën: nuk u krye rishikim ekspertësh (§5.9).

5.5 Saktësia e krahasimit të kryqëzuar

Rezultatet i përgjigjen PK4 (E5): 10 009 çifte analit–dokument, me katër gjendje.

Tabela 15. Saktësia e krahasimit të kryqëzuar (E5)

Gjendja	Mbësh tetja	Precision (me OCR)	Recall: dixhital	Recall: gjithë korpusi, pa OCR	Recall: gjithë korpusi, me OCR
agreement (përputhje)	1163	1.000	1.000	0.679	0.679
contradiction (kundërshtim)	87	1.000	1.000	0.678	0.678
mentioned_not_mea- sured (përmendur, jo matur)	149	1.000	1.000	0.617	0.617

Gjendja	Mbësh tetja	Precision (me OCR)	Recall: dixhital	Recall: gjithë korpusi, pa OCR	Recall: gjithë korpusi, me OCR
measured_not_mentioned (matur, jo përmendur)	8610	0.965	1.000	0.653	0.894
Saktësia e përgjithshme	10009		1.000	0.656	0.863

Mbi dokumentet dixhitale të katër gjendjet kthehen pa gabim (1.000, pa referenca të rreme).

Mbi tërë korpusin saktësia është 0.656 pa OCR dhe 0.863 me OCR; vlera e vjetër 0.563 e një drafti më të hershëm nuk ka korpust të regjistruar dhe nuk përdoret (§4.4.5).

Dy gjëra duhen vënë re:

1. **I gjithë përmirësimi me OCR vjen nga measured_not_mentioned** (0.653 në 0.894). Recall-i i tri gjendjeve të tjera, që kërkojnë një pohim narrativ, është i njëjtë me dhe pa OCR (0.679, 0.678, 0.617). Matrica e E5 e përputh me këtë: nga 373 përputhjet e humbura, në 263 vlera laboratorike u lexua por pohimi narrativ nuk u rikthye, dhe në 110 mungoi vetë vlera. Këtu ka një sinjal se narrativa e dokumenteve të skanuara nuk rikthehet nga tubacioni i tanishëm, por **shkaku nuk është hetuar në nivel dokumenti** dhe nuk pohohet.
2. **28 nga 87 kundërshtime humbën**, të gjitha në dokumente të skanuara (mbi dixhitalet recall-i është 1.000): 19 u raportuan si «matur, jo përmendur» dhe 9 si të munguara. Në këto raste mospërputhja ndërmjet raportit dhe laboratorit nuk i tregohet pacientit. Rezultati është më i rëndë se saktësia e përgjithshme e sugjeron, sepse kundërshtimi është gjendja që ekziston pikërisht për t'u shfaqur.

Dhjetë referenca të rreme (spurious_cross_references: 10) dolën me OCR dhe asnjë pa të.

5.5.1 Dega B mbi fjali të dorëzuara nga autori (grupi C)

E5 mat krahasimin e kryqëzuar mbi narrativa të prodhuara nga gjeneruesi. Për të parë nxjerrjen e pohimeve jashtë fjalorit të tij, autori dorëzoi 60 fjali narrative (evaluation/handwritten/C_narrativa.csv), me etiketën e pritur për lloj, polaritet, siguri, analit dhe drejtim, sipas recetës së README-së së grupeve (15 negacione të thjeshta, 10 pseudo-negacione, 10 me rezervë, 10 rekomandime, 15 pohime të drejtpërdrejta). Rregullat nuk u ndryshuan pas matjes (r1.3). Autorësia është sipas deklaratës së autorit. Matja: python -m evaluation.kit_c_report.

Tabela 16. Dega B mbi fjalitë e grupit C.

«Të gjitha fushat saktë»: lloji, polariteti, siguria, analiti dhe drejtimi përputhen njëkohësisht me etiketën.

Lloji i fjalisë	Rreshta	Të gjitha fushat saktë	Pohim i nxjerrë fare	Drejtimi saktë
negacione të thjeshta	15	0	9	0
pseudo-negacione	10	0	8	0
me rezervë	10	10	10	10
rekomandime	10	7	7	7
pohime të drejtpërdrejta	15	15	15	15
Të gjitha	60	32	49	32

Si lexohet.

- Vetëm 32 nga 60 fjali (53%) dalin plotësisht saktë.** Në të dyja grupet e para, negacionet e thjeshta dhe pseudo-negacionet, **asnjë nga 25 fjalitë nuk del plotësisht saktë**, ndërsa pohimet e drejtpërdrejta (15 nga 15) dhe ato me rezervë (10 nga 10) dalin të gjitha saktë. **Kufizim i grupit:** të 25 fjalitë e dy grupeve të para janë ndërtuar me të njëjtin ndërtim, emrin «rritje/ulje e X» («Nuk vërehet rritje e leukociteve», «Nuk përjashtohet ulja e hemoglobinës»). Rezultati vlen pra për këtë ndërtim, jo për çdo negacion apo pseudo-negacion; një grup me forma të ndryshme («nuk ka rritje të...», «...nuk është i rritur», «mungojnë shenjat e...») do ta ndante këtë.
- Mbivendosja me gjeneruesin e shpjegon pjesën më të madhe të suksesit.** 19 nga 60 fjali janë identike me fjali që gjeneruesi i prodhon (narrativat e korpusit dhe deklaratat e mjekut te kontekstet), dhe të 19 dalin saktë. Mbi 41 fjalitë e tjera, vetëm 13 nga 41 (32%) dalin plotësisht saktë dhe 30 nga 41 nxirren fare. Prandaj numri i përgjithshëm duhet lexuar me këtë ndarje, jo si saktësi mbi tekst të lirë.
- Dështimet kanë shkaqe të përcaktuara.** Drejtimi njihet vetëm në format «mbi/nën intervalin», «i rritur», «e ulët» dhe të ngjashme; kur drejtimi shprehet me emër, «Nuk vërehet rritje e leukociteve», «Nuk përjashtohet ulja e hemoglobinës», ai mbetet i papërcaktuar ose pohimi nuk nxirret fare (drejtimi saktë: 0 nga 25 te dy grupet e para). «Nuk mund të mohohet ulja e FT4» lexohet si mohim i thjeshtë, jo si pohim me rezervë. Rekomandimet me «nuk nevojitet» ose «nevoja për» nuk njihen, dhe disa emra analitesh të shumëfjalshëm nuk zgjidhen.

Kjo është arsyeja e njëjtë me atë që auditi i §5.6.1 gjeti te teksti i modelit: vokabulari i drejtimit dhe i polaritetit është i ngushtë, dhe forma e lirë e shqipes e kalon.

5.6 Efekti i shtresës së verifikimit

Ky është eksperimenti kryesor i punimit dhe përgjigjja e drejtpërdrejtë ndaj hipotezës së parë (PK5). Katër kushtet u ekzekutuan me modelin *ministral-14b-2512* mbi të njëjtat 500 dokumente me OCR: A (pa bazim, E6), B (vetëm bazim, E7), C (bazim dhe rregulla me një rigjenerim, E8) dhe D (C plus klasifikuesi i fjalisë, E9). Nën «shkelje» kuptohet një shkelje e katalogut r1.3 që verifikuesi e zbulon në tekstin që arrin te përdoruesi.

Tabela 17. Rezultatet e ablacionit të verifikimit (modeli gjuhësor.

OCR i ndezur; 500 dokumente)

Kushti	Eksperimenti	Fjali	Shkelje të prodhuara	Shkelje që arrijnë te përdoruesi	Për 100 fjali (95% CI)	Dega A	Dega B	Dokumente me shkelje (nga 500)	Shabllon rezervë
A — pa bazim	E6	37823	20570	20570	54.38 [51.55–57.18]	15440	5130	500	—
B — vetëm bazim	E7	5804	554	554	9.55 [8.12–11.22]	334	220	247	—
C — bazim dhe rregulla	E8	8892	906	0	0.000 (95%: ≤ 0.034, rregulla e tre)	0	0	247	126 (25.2%)
D — bazim, rregulla dhe klasifikues	E9	10359	1930	41	0.40 [0.25–0.56]	41	0	380	302 (60.4%)

Në C dhe D, «Fjali» numëron fjalitë e të gjitha përpjekjeve (edhe të drafteve të ndaluara).

Emëruesi. Te A dhe B çdo fjali e gjeneruar arrin te përdoruesi (nuk ka verifikim), prandaj «për 100 fjali» është për 100 fjali të dorëzuara. Te C dhe D emëruesi janë fjalitë e të gjitha drafteve të modelit, përfshirë ato të ndaluara, dhe nuk përfshin tekstin e shabllonit që u dorëzua në vend të tyre; numëruesi janë shkeljet në tekstin e dorëzuar. Për të parë çfarë ndryshon, E8 dhe E9 u rillogaritën nga cache-i (0 thirrje të reja; totalet e harness-it dolën të njëjta: 8 892 fjali dhe 0 shkelje, 10 359 dhe 41) duke numëruar fjalitë e tekstit të dorëzuar (*evaluation/results/supplementary/e8_e9_delivered_denominator.json*; llogaritur nga një kopje e pastër e commit-it 2d93c52 me kodin e ngrirë (r1.3, pa kontrollin e OCR-së); totalet e harness-it dolën të njëjta me ato të ngrira). **Te C** teksti i dorëzuar ka 7 907 fjali, prej të cilave 3 444 (43.6%) janë të shabllonit rezervë: kufiri i sipërm 95% bëhet 0.038 për 100 fjali të dorëzuara, dhe mbi fjalitë e shkruara nga vetë modeli (4 463, nga 374 dokumente) është 0 shkelje me kufi 0.067. **Te D** teksti i dorëzuar ka 10 454 fjali, prej të cilave 8 407 (80.4%) janë shabllon; të 41 shkeljet janë në shabllon (302 dokumente) dhe asnjë në 2 047 fjalët e modelit (198 dokumente), dhe norma për 100 fjali të dorëzuara është 0.39, pothuajse e njëjta me 0.40. Pra 0.000 i C përzien dy popullata, 374 dokumente me tekst të modelit që kaluan rregullat dhe 126 me shabllon; për pyetjen «sa shkelje që rregullat shohin mbeten në

tekstin e modelit pasi ai kalon rregullat», emëruesi i duhur është 4 463 fjali, jo 8 892, dhe kufiri është dy herë më i lartë.

Tabela 18. Shkeljet e prodhuara nga modeli, sipas llojit (të gjitha përpjekjet.

Në C dhe D numërohen edhe drafte që verifikimi i ndaloi). Për D, lloji është ai që parashikoi klasifikuesi.


Lloji i shkeljes	A (E6)	B (E7)	C (E8, drafte)	D (E9, drafte)
direction_mismatch	1508	235	432	445
fabricated_finding	4580	113	143	226
omitted_recommendation	357	104	134	146
ungrounded_number	11075	71	150	148
ungrounded_analyte	2854	22	31	948
missing_critical	3	6	11	13
polarity_flip	0	3	5	4
ungrounded_term_explanation	62	0	0	0
prohibited_claim	131	0	0	0

Çfarë tregon çdo hap.

- **Nga A te B: bazimi e ul normën nga 54.4 në 9.5 për 100 fjali** (intervalët 51.6–57.2 dhe 8.1–11.2 nuk priten). Pa bazim, 500 nga 500 dokumente kanë të paktën një shkelje (41.1 shkelje për dokument); me bazim 247 nga 500 (1.1 për dokument). Dy kujdese: kërkesa A është naive me qëllim (§D.5) dhe çdo numër jashtë vlerave të matura, përfshirë një datë ose një moshë nga teksti i dokumentit, numërohet ungrounded_number (11 075 nga 20 570 shkelje); dhe teksti pa bazim është gati 6.5 herë më i gjatë (37 823 kundrejt 5 804 fjali), prandaj krahasimi bëhet për 100 fjali dhe për dokument, jo me numër të pastër.
- **Nga B te C: verifikimi e ul normën nga 9.5 në 0.000** (kufiri i sipërm 95%: 0.034 për 100 fjali). Modeli prodhoi 906 shkelje në të dyja përpjekjet, dhe asnjë nuk arriti te përdoruesi. **Çmimi:** 247 dokumente kishin shkelje në përpjekjen e parë; rigjenerimi i riparoi 121, dhe 126 (25.2%) përfunduan te shablloni rezervë.
- **Nga C te D: klasifikuesi nuk e përmirëson daljen e matur dhe e shton çmimin.** Norma është 0.40 për 100 fjali [0.25–0.56] dhe 302 dokumente (60.4%) shkojnë te shablloni, kundrejt 25.2% pa klasifikues. Të 41 shkeljet që arrijnë te përdoruesi janë alarme të rreme mbi shablloni rezervë, që është i bazuar nga ndërtimi (kontrolli i auditit: 0 nga 10 shabllone kanë problem). Mekanizmi i njohur nga E9 me shabllon, njësitë e prishura nga OCR që klasifikuesi s'i ka parë (ADR 0009), është shpjegimi më i mundshëm, por nuk u verifikua për këtë ekzekutim. Vlerësimi nuk është plotësisht i

drejtë ndaj klasifikuesit: një pjesë e 302 shablloneve mund të jenë gabime të vërteta që rregullat nuk i shohin, dhe auditi nuk u krye mbi daljen e D.

- **Hipoteza e parë.** H1 pretendon se verifikimi ul ndjeshëm normën e pohimeve të pambështetura që arrijnë te përdoruesi, krahasuar me bazimin pa verifikim. Në formën e matur ajo **konfirmohet**: mes B dhe C norma bie nga 9.5 në 0.000 për 100 fjali. Forma më e fortë, që asnjë pohim i pambështetur nuk arrin te përdoruesi, **nuk provohet**: metrika numëron vetëm shkeljet që rregullat shohin, dhe auditi më poshtë matet nga jashtë tyre.



500 dokumente, OCR, minstral-14b-2512. B = vetëm bazim; C = + rregulla (+ një rigjenerim); D = C + klasifikues. «0.000» numëron vetëm shkeljet që rregullat shohin (§6.6.1).

Figura 18. Rezultatet e ablacionit të shtresës së verifikimit (Tabela 17).

- (a) Shkeljet që arrijnë te përdoruesi për 100 fjali (te C dhe D emërues janë fjalitë e të gjitha drafteve, jo vetëm të tekstit të dorëzuar; shih «Emëruesi» më sipër), me intervalin 95%; për C tregohet kufiri i sipërm i rregullës së tre. Vlera 0.000 numëron vetëm shkeljet që rregullat shohin (§5.6.1). (b) Pjesa e dokumenteve që shkojnë te shablloni rezervë; te A dhe B nuk ka verifikim, prandaj shablloni rezervë nuk zbatohet. Të dhënat: evaluation/results/llm/E6–E9.

5.6.1 Auditi i pavarur i tekstit të dorëzuar

Metrika e PK5 matet me po ato rregulla që e bllokojnë tekstin. «Zero shkelje arrijnë te përdoruesi» do të thotë pra «zero që rregullat shohin», dhe nuk përjashton gabime që ato humbasin. Për ta matur këtë, një gjykatës i pavarur nga rregullat lexoi një mostër të tekstit të dorëzuar në E8 kundrejt kontekstit dhe listoi çdo problem: 90 tekste të gjeneruara që kaluan

verifikimin (62 dixhitale, 28 të skanuara, nga 374 të tilla) dhe 10 shabllone rezervë si kontroll. Gjykatësi është Claude Sonnet (subagjent; §5.7.2), dhe përveç llojeve të katalogut ka një klasë për pohimet që asnjë rregull nuk i kontrollon (other_unsupported: njohuri mjekësore e shtuar, qetësim, këshillë).

Tabela 19. Auditi i pavarur i 90 teksteve të gjeneruara që kaluan verifikimin e E8

Kriteri i problemit	Tekste me problem	Pjesa (95% Wilson)
Çdo problem (përfshirë shpjegime termash dhe pohime të pambështetura)	52 nga 90	0.578 [0.475–0.675]
Problem i llojeve që rregullat synojnë (numër, analit, gjetje e shpikur, drejtim, polaritet, rezervë, rekomandim, pohim i ndaluar)	32 nga 90	0.356 [0.264–0.459]
Vetëm llojet me pasojë klinike (drejtim, polaritet, rezervë, rekomandim i humbur, vlerë kritike, pohim i ndaluar)	24 nga 90	0.267 [0.186–0.366]
Drejtim i gabuar (direction_mismatch)	21 nga 90	0.233 [0.158–0.331]

Kontrolli me shabllon është i pastër: **0 nga 10 shabllone kanë problem**, çka tregon se gjykatësi nuk shpik probleme mbi tekst të bazuar. Problemet e gjetura te 90 tekstet, sipas llojit, jepen te Tabela 20.

Tabela 20. Problemet e gjetura nga auditi, sipas llojit

Lloji i problemit	Numri i problemeve
other_unsupported	31
ungrounded_term_explanation	26
direction_mismatch	24
fabricated_finding	10
ungrounded_number	8
prohibited_claim	2
polarity_flip	2
hedge_removed	1

Si lexohet. Rezultati varet nga rreptësia, prandaj jepen tri vlera. Nën leximin më të rreptë, 52 nga 90 tekste (58%) kanë ndonjë problem; por 20 prej tyre kanë vetëm shpjegime termash ose pohime të pambështetura që shpesh janë të vogla. Nën leximin që numëron vetëm llojet që rregullat synojnë, 32 nga 90 (36%, intervali 26–46%) kanë problem; nën atë me pasojë klinike (drejtim, polaritet, rezervë, rekomandim, vlerë kritike, pohim i ndaluar), 24 nga 90 (27%, 19–37%). Mes llojeve që rregullat synojnë, më i shpeshti është drejtimi i gabuar: 21 nga 90 (23%).

Një kontroll i 20 gjetjeve të gjykatësit kundrejt kontekstit, nga asistenti që kreu auditin (jo nga një njeri i pavarur), tregoi se shumica ishin gabime të vërteta të modelit që rregullat i kaluan: një vlerë 37.4 g/dL e quajtur «brenda intervalit» 32–36; pohime të përgjithshme si «të gjitha vlerat e tjera janë brenda intervalit referent» pranë një vlere jashtë tij; dhe shpjegime të

shpikura ose të gabuara, si «TSH (hormoni i stimulimit të mëlçisë)» dhe «pallakat që ndihmojnë në pjekjen e gjakut». Disa gjetje janë kufitare: numra të shkruar me fjalë («dy vlera jashtë kufijve»), që janë numërime të nxjerrura nga konteksti, ose shpjegime të padëmshme si «qelizat e kuqe të gjakut». Pra shifra është një vlerësim me gjykatës të pasaktë, jo një normë e matur me saktësi.

Pasoja për PK5. Rregullat arrijnë F1 0.993 mbi korpusin e korruptuar dhe 0.795 mbi grupin B, por mbi tekstin e vërtetë të modelit humbasin një pjesë të madhe të gabimeve, sepse ato njohin drejtimin dhe analitin vetëm në format që kanë, dhe nuk kontrollojnë pohime të përgjithshme apo shpjegime të shtuara. Kjo shpjegon pse nga 906 shkelje të prodhuara 0 arrijnë te përdoruesi dhe megjithatë rreth një e treta e teksteve të kaluar ka një problem të llojeve që rregullat synojnë. Verifikimi me rregulla ul rrezikun e matur; garanci nuk jep.

5.6.2 Të njëjtat kushte me r1.4 dhe kontrollin e OCR-së

Pas matjeve të mësipërme u ndërtuan kontrolli i OCR-së (§5.3.1) dhe katalogu r1.4 (§5.7.3), dhe shërbimi i përdor të dyja. Që të dihet çfarë ndryshon për ablacionin, E4 dhe E6–E8 u rishikuan me --rules r1.4 --ocr-guard, me të njëjtin model, kërkesë (p1/u1), temperaturë 0 dhe cache të përgjigjeve; u desh të thirreshin 254 përgjigje të reja (60 te E7, 194 te E8), sepse kontekstet e dokumenteve të skanuara ndryshuan dhe rregullat e reja ndalojnë më shumë drafte (E6 doli me 0 thirrje të reja). Rezultatet janë te evaluation/results/llm_r14/ (ekzekutim nga pema e punës; kopja e pastër pas commit-it).

Tabela 21. Kushtet e ablacionit me r1.3 dhe me r1.4 bashkë me kontrollin e OCR-së

Kushti	r1.3: fjali	shkelje te përdoruesi për 100 fjali	shabllon rezervë	r1.4 + kontroll: fjali	shkelje te përdoruesi për 100 fjali	shabllon rezervë
A — pa bazim (E6)	37 823	54.38 [51.55–57.18]	—	37 823	73.93 [70.69–77.03]	—
B — vetëm bazim (E7)	5 804	9.55 [8.12–11.22]	—	5 677	13.56 [11.86–15.54]	—
C — bazim dhe rregulla (E8)	8 892	0.000 (≤ 0.034)	126 (25.2%)	9 250	0.000 (≤ 0.032)	166 (33.2%)

Tre gjëra lexohen nga kjo tabelë. **Numrat midis versioneve nuk krahasohen drejtpërdrejt:** r1.4 numëron lloje shkeljesh që r1.3 nuk i shihte (pohime diagnostike, trajtimi, prognoze dhe shpjegime të termave; te E6 përbëjnë 2 657 dhe 3 213 nga 27 961 shkelje), kështu që i njëjti tekst del me më shumë shkelje. **Brenda secilit version ablacioni mban të njëjten formë:** bazimi e ul normën me 82.4% me r1.3 dhe 81.7% me r1.4, dhe verifikimi e çon te zero te të dyja. **Çmimi rritet:** 289 dokumente (nga 500) kishin shkelje në përpjekjen e parë

(247 me r1.3), dhe 166 përfunduan të shablloni (126 me r1.3). Fjalitë e dorëzuara të E8 janë 8 519, prej të cilave 4 780 (56.1%) të shabllonit; mbi 3 739 fjalitë e shkruara nga vetë modeli (334 dokumente) janë 0 shkelje me kufi të sipërm 0.080 për 100 fjali, dhe mbi të gjithë tekstin e dorëzuar 0.035 (evaluation/results/supplementary/e8_delivered_denominator_r14.json; me r1.3 ishin 43.6% shabllon dhe kufijtë 0.067 dhe 0.038, §5.6).

E4 me r1.4: ruajtja e mohimit 0.997 (0.994 me r1.3), e rezervës 1.000 (1.000), rekomandime të humbura 5.4% (4.9%), gjetje të shpikura 0.59 për 100 fjali (0.51). Dallimet janë të vogla dhe nuk lexohen si ndryshim të vërtetë të sjelljes së modelit; ato ndjekin ndryshimin e draftit të fundit që del nga rregullat e reja.

Çfarë nuk u rimat. E9 (klasifikuesi) mbetet me r1.3: peshat e klasifikuesit u humbën (një fshirje e bërë gabimisht gjatë punës) dhe duhen rindërtuar në Colab. Audit i E8 (§5.6.1) mbulon 90 tekste të dorëzuara me r1.3; me r1.4 tekstet e dorëzuara janë të ndryshme, dhe r1.4 shënon 25 nga ato 90 (§5.7.3), pra shumë prej tyre sot do të ndaleshin; një audit i ri i tekstit të dorëzuar me r1.4 nuk u krye. Prandaj 36% (26–46%) të auditit vlen për r1.3 dhe nuk mund të bartet te r1.4. Si të çdo matje e kësaj pjese, r1.4 u hartua pasi u panë gabimet, dhe «0.000» numëron vetëm shkeljet që rregullat shohin.

5.7 Saktësia e vetë shtresës së verifikimit

Rezultatet i përgjigjen PK6 (E10, E11, E12 dhe grupi B). Janë dy mostra me natyrë të ndryshme, dhe krahasimi mes tyre është pjesa më informuese e kapitullit. Të tre detektorët (rregullat, klasifikuesi XLM-RoBERTa dhe gjykatësi LLM) vlerësohen mbi të njëjtat mostra.

- **Korpusi i korruptuar (E10, E11).** 192 tekste të testit, secili një shpjegim i plotë: 30 të pastra dhe 162 me një defekt të futur nga një korruptues mbi tekstin e shabllonit. Defektet vijnë nga i njëjti gjenerues që ka ndërtuar tekstin e pastër.
- **Grupi B.** 105 fjali natyrale për 25 kontekste, secila e futur në shabllonin e kontekstit të vet: 30 të pastra dhe 75 me defekt, të dorëzuara nga autori (§5.7.1 për prejardhjen). Së bashku me grupin C (§5.5.1) dhe grupin A, është lënda e punimit që nuk ka kaluar nëpër gjeneruesin sintetik.
- **Grupi A.** 25 shpjegime referuese, një për secilin kontekst, të dorëzuara nga autori; gjithçka që ato thonë (vlerat, intervalet, termat, citimet e mjekut) vjen nga konteksti. Rregullat ekzekutohen mbi to dhe çdo shënim është alarm i rremë ose gabim i

shpjegimit; ky grup nuk ka defekte të futura, prandaj nuk jep precision as recall, vetëm shkallën e alarmeve të rreme mbi prozë që gjeneruesi nuk e ka prodhuar (§5.7.1).

Katalogu ka lloje që nuk maten në asnjërën mostër: `missing_critical` (R4) nuk ka asnjë mostër dhe për të nuk ka matje; `omitted_recommendation` (R8) ka mostra vetëm te korpusi i korruptuar, ndërsa `ungrounded_term_explanation` (R9) dhe `prohibited_claim` (SP1–3) vetëm te B.

Tabela 22. Krahاسimi i qasjeve të detektimit.

P, R dhe F1 janë mikro-mesatare mbi llojet e defektit; macro F1 është mesatarja e F1 mbi llojet e defektit me mbështetje.

Qasja	Korpusi i korruptuar: P	R	F1	Macro F1	Të pastra të bllokuara	Grupi B: P	R	F1	Macro F1	Të pastra të bllokuara
Rregullat deterministe (r1.3)	0.994	0.988	0.991	0.993	0 / 30	0.983	0.773	0.866	0.795	1 / 30
Klasifikuesi XLM-R, fjalia, rregulli 1 (prag 0.3)	0.380	0.451	0.412	0.481	30 / 30	0.105	0.147	0.122	0.053	30 / 30
Klasifikuesi XLM-R, fjalia, rregulli 2 (prag 0.85)	1.000	0.302	0.465	0.385	0 / 30	0.143	0.013	0.024	0.015	2 / 30
Klasifikuesi XLM-R, fjalia + konteksti, rregulli 1 (prag 0.4)	0.526	0.617	0.568	0.538	29 / 30	0.175	0.240	0.202	0.177	29 / 30
Klasifikuesi XLM-R, fjalia + konteksti, rregulli 2 (prag 0.9)	0.917	0.407	0.564	0.326	2 / 30	0.667	0.080	0.143	0.104	0 / 30
Gjykatësi LLM: Claude Sonnet (E12)	1.000	1.000	1.000	1.000	0 / 30	1.000	1.000	1.000	1.000	0 / 30
Gjykatësi LLM: Claude Haiku (E12, kontroll)	0.882	0.463	0.607	0.625	5 / 30	0.582	0.427	0.492	0.514	9 / 30

Gjykatësi LLM është Claude Sonnet (gjykatësi kryesor) dhe Claude Haiku (kontroll i dytë), të dy si subagjentë, mbi të njëjtat 297 mostra (192 të E10 dhe 105 të B) në batch-e të përziera pa etiketat; çdo gjykatës merr kontekstin, tekstin dhe përkufizimet e katalogut, dhe kthen një etiketë (§5.7.2). Klasifikuesi është i matur me dy rregulla pragu (ADR 0009): rregulli 1 maksimizon macro F1 në validim, rregulli 2 kërkon që më së shumti 5% e teksteve të pastra të validimit të bllokohen; rregulli 2 është ai që përdoret në E9. «Fjalia + konteksti» sheh edhe kontekstin e strukturuar, «fjalia» vetëm fjalinë. Klasifikuesi nuk e sheh kurrë një defekt `omitted_recommendation`, sepse një fjali që mungon nuk është fjali; ky lloj hyn në macro F1 të E11 me F1 0.00.

Si lexohet.

1. **Rregullat bien nga 0.993 në 0.795 kur fjalitë nuk vijnë nga gjeneruesi.** Mikro-precision mbetet e lartë (0.994 në 0.983), recall-i bie nga 0.988 në 0.773. Pra rregullat

flasin pak, jo shpesh gabim: ato humbasin defekte që nuk njohin, dhe te B kanë një alarm të rremë nga 30 fjali të pastra.

2. **Klasifikuesi është afër të pavlefshmit mbi tekst natyral:** macro F1 0.015–0.177. Mbi korpusin e korruptuar shifrat (0.326–0.538) janë më të larta, por te rregulli 1 ai bllokun 30 nga 30 (fjalia) dhe 29 nga 30 (fjalia + konteksti) tekste të pastra, pra nuk dallon të pastrin nga i prishuri; te rregulli 2 ai bllokun pak të pastra (0 dhe 2 nga 30) por kap pak defekte (recall 0.302 dhe 0.407).
3. **Gjykatësi Claude Sonnet është i vetmi detektor që mban nivelin mbi tekst natyral:** macro F1 1.000 te të dyja mostrat, me 0 tekste të pastra të bllokuara, kundrejt 0.993 dhe 0.795 të rregullave. Gjykatësi Claude Haiku, i njëjti protokoll, arrin vetëm 0.625 dhe 0.514, dhe bllokun 5 dhe 9 tekste të pastra. Pra aftësia e gjykatësit e përcakton rezultatin, dhe një gjykatës LLM nuk është automatikisht më i mirë se rregullat: i fuqishmi i kalon ato te B, i vogli mbetet nën to mbi të dyja mostrat.
4. **Rregulli 2 nuk e mban premtimin e tij te teksti i vërtetë:** te «fjalia + konteksti» ai bllokun 2 nga 30 tekste të pastra të testit (6.7%, mbi buxhetin 5%), dhe te E9 me shabllonin si gjenerues ai çon te shablloni 10.2% të dokumenteve (51 nga 500), të gjitha alarme të rreme nga dokumente të skanuara (§5.10, ADR 0009).

Tabela 23. F1 sipas llojit të defektit, korpusi i korruptuar (192 mostra).

Rreshtat pa mbështetje nuk janë paraqitur.

Lloji i defektit	Mbështetja	Rregullat	Fjalia, R1	Fjalia, R2	Fj.+konteksti, R1	Fj.+konteksti, R2	Sonnet	Haiku
ungrounded_number	30	1.00	0.20	0.00	0.48	0.36	1.00	0.65
ungrounded_analyte	30	0.98	0.75	0.70	0.92	0.92	1.00	0.72
direction_mismatch	27	0.98	0.20	0.00	0.39	0.00	1.00	0.62
polarity_flip	12	1.00	0.22	0.00	0.26	0.00	1.00	0.63
hedge_removed	3	1.00	1.00	1.00	0.80	0.00	1.00	0.80
fabricated_finding	30	0.98	1.00	1.00	0.92	1.00	1.00	0.58
omitted_recommendation	30	1.00	0.00	0.00	0.00	0.00	1.00	0.38

Tabela 24. F1 sipas llojit të defektit, grupi B (105 mostra).

omitted_recommendation nuk ka rreshta në B.

Lloji i defektit	Mbështetja	Rregullat	Fjalia, R1	Fjalia, R2	Fj.+konteksti, R1	Fj.+konteksti, R2	Sonnet	Haiku
ungrounded_number	10	0.95	0.00	0.00	0.18	0.00	1.00	0.60
ungrounded_analyte	10	1.00	0.15	0.12	0.67	0.40	1.00	0.00

Lloji i defektit	Mbështetje	Rregullat	Fjalë, R1	Fjalë, R2	Fj.+konteksti, R1	Fj.+konteksti, R2	Sonnet	Haiku
te								
direction_mismatch	10	0.67	0.06	0.00	0.12	0.00	1.00	0.53
polarity_flip	10	1.00	0.22	0.00	0.21	0.00	1.00	0.67
hedge_removed	10	1.00	0.00	0.00	0.00	0.00	1.00	0.57
fabricated_finding	10	0.95	0.00	0.00	0.23	0.43	1.00	0.42
ungrounded_term_explanation	5	0.33	0.00	0.00	0.00	0.00	1.00	0.75
prohibited_claim	10	0.46	0.00	0.00	0.00	0.00	1.00	0.57

Çfarë tregojnë tabelat sipas llojit.

- **Pritshmëria e formular para matjes ishte që rregullat të ishin të plota për defektet numerike dhe të pafuqishme për ato semantike**, ndërsa klasifikuesi të sillej në mënyrën e kundërt. Pjesa e parë u kundërshtua: rregullat arritën macro F1 0.993 edhe te mohimi dhe pasiguria, sepse ato shohin kontekstin e plotë të strukturuar (ADR 0009). Te B kjo vazhdon të ndodhë për citimet e mjekut: polarity_flip dhe hedge_removed marrin F1 1.00, por këto rreshta janë më pak të pavarura se të tjerat (§5.7.1).
- **Dobësitë e rregullave të B janë leksikore, jo konceptuale.** direction_mismatch 0.67 (5 nga 10), prohibited_claim 0.46 (3 nga 10), ungrounded_term_explanation 0.33 (1 nga 5). §5.10 jep shkaqet.
- **Perfeksioni i klasifikuesit të fabricated_finding (1.00) është artefakt i shabllonit:** çdo gjetje e shpikur e korpusit të korruptuar fillon me «Vërehet gjithashtu» (E11/leakage.json). Mbi fjali të shkruara ndryshe ai bie në 0.00–0.43.
- **Rrjedhja e shabllonit:** për 100% të fjalive me defekt të validimit forma e tyre (pa numra e emra) gjendet te një fjali e trajnimit; ndarja në nivel dokumenti nuk e ndalon këtë (§4.11.1). E11 mbi korpusin e korruptuar mat njohjen e shablloneve të gjeneruesit më shumë se zbulimin e defektit; grupi B është prova e vetme e vërtetë.


Hipoteza e dytë (H2). H2 pret që precision-i dhe recall-i i detektorit të jenë më të lartë për degën laboratorike (A) sesa për atë narrative (B). Tabela më poshtë i mbledh përfundimet e Tabelës 23 sipas degës (A: ungrounded_number, ungrounded_analyte, direction_mismatch, missing_critical; B: të tjerat).

Tabela 25. Detektimi sipas degës (A: laboratorike; B: narrative)

Detektori	Dega	Korpusi i korruptuar: P	R	Grupi B: P	R
Rregullat deterministe (r1.3)	A	1.000	0.977	0.962	0.833
Rregullat deterministe (r1.3)	B	0.987	1.000	1.000	0.733

Detektori	Dega	Korpusi i korruptuar: P	R	Grupi B: P	R
Klasifikuesi XLM-R, fjalia, rregulli 1 (prag 0.3)	A	0.459	0.322	0.071	0.100
Klasifikuesi XLM-R, fjalia, rregulli 1 (prag 0.3)	B	0.344	0.600	0.127	0.178
Klasifikuesi XLM-R, fjalia, rregulli 2 (prag 0.85)	A	1.000	0.184	0.143	0.033
Klasifikuesi XLM-R, fjalia, rregulli 2 (prag 0.85)	B	1.000	0.440	—	0.000
Klasifikuesi XLM-R, fjalia + konteksti, rregulli 1 (prag 0.4)	A	0.478	0.736	0.186	0.367
Klasifikuesi XLM-R, fjalia + konteksti, rregulli 1 (prag 0.4)	B	0.643	0.480	0.159	0.156
Klasifikuesi XLM-R, fjalia + konteksti, rregulli 2 (prag 0.9)	A	0.857	0.414	0.600	0.100
Klasifikuesi XLM-R, fjalia + konteksti, rregulli 2 (prag 0.9)	B	1.000	0.400	0.750	0.067
Gjykatësi LLM: Claude Sonnet (E12)	A	1.000	1.000	1.000	1.000
Gjykatësi LLM: Claude Sonnet (E12)	B	1.000	1.000	1.000	1.000
Gjykatësi LLM: Claude Haiku (E12, kontroll)	A	0.870	0.540	0.455	0.333
Gjykatësi LLM: Claude Haiku (E12, kontroll)	B	0.903	0.373	0.667	0.489

Gjykatësi Sonnet arrin 1.000 te të dyja degët, pra nuk jep asnjë diferencë. Për rregullat te B, recall-i është në drejtimin e H2 (dega A 0.833, dega B 0.733) por precision-i në të kundërtën (0.962 dhe 1.000); te korpusi i korruptuar precision-i është në drejtimin e H2 (1.000 kundrejt 0.987) por recall-i në të kundërtën (0.977 kundrejt 1.000). Te klasifikuesi nuk ka model të qëndrueshëm. Nuk ka test statistikor dhe mbështetja është 30 deri 45 fjali për degë. **H2 nuk konfirmohet nga këto matje**, as nuk hidhet poshtë; vetë ndarja nuk është e pastër, sepse llojet më të dobëta te B janë të përziera (*direction_mismatch* në A, *prohibited_claim* dhe *ungrounded_term_explanation* në B), dhe H2 pretendon një diferencë që një detektor i përsosur (Sonnet) nuk mund ta tregojë.



Rreshti është lloji i vërtetë, kolona lloji i parashikuar; ngjyra është pjesa e rreshtit. Klasifikuesi: fjalia, rregulli 2 (prag 0.85), ai i vendosur në E9.
u_ = ungrounded_ (number, analyte, term); omitted_rec = omitted_recommendation.

Figura 19. Matricat e konfuzionit për tre qasjet e detektimit.

Rreshti sipër: korpusi i korruptuar (192 tekste të testit); rreshti poshtë: grupi B (105 fjali të dorëzuara nga autori). Rreshti i secilës matricë është lloji i vërtetë, kolona lloji i parashikuar. Klasifikuesi është ai i vendosur në E9 (fjalia, rregulli 2, prag 0.85). Gjykatësi Claude Haiku nuk shfaqet këtu; rezultatet e tij janë në Tabelën 22 dhe te [evaluation/results/llm/E12_haiku](#). Gjykatësi Sonnet nuk është i pavarur nga sistemi (§5.7.2).




Figura 20. Llojet e shkeljeve: çfarë prodhon modeli dhe sa mirë zbulohen.

(a) Pjesa e secilit lloj në shkeljet e prodhuara nga modeli në kushtet A, B dhe C (drafte; Tabela 17). (b) F1 e secilit detektor sipas llojit mbi grupin B (Tabela 23); lloji pa mostër në B nuk ka pikë. Të dhënat: evaluation/results/llm/ dhe evaluation/results/E10–E12.

5.7.1 Prejardhja e grupeve B dhe A

Grupi B u dorëzua nga autori si punë e vet më 2026-10-02. Gjatë punës ekzistonte në depo një draft i mëparshëm i hartuar nga një model gjuhësor (Claude), i cili u zëvendësua dhe nuk është më pjesë e depos. **12 nga 105 rreshta të skedarit të tanishëm janë identikë (kontekst dhe fjali) me rreshta të atij drafti:** 6 polarity_flip dhe 6 hedge_removed, pra vetëm citime të mjekut; edhe 4 fjali të tjera përputhen nëse nuk merret parasysh konteksti. 93 rreshtat e tjerë janë të ndryshëm. Forma e rreshtave me citim është shumë e kufizuar (parashtesa dhe fjala e mjekut me një ndryshim), prandaj përputhja mund të ndodhë pa kopjim, por skedari nuk e vërteton si ndodhi. Skedari nuk ka rreshta të përsëritur. Kufizime të tjera: 9 nga 105 fjali ndajnë formën me një fjali të trajnimit të klasifikuesit (të gjitha citime të mjekut), asnjë nuk gjendet fjalë për fjalë te shablloni, dhe fjalitë e pastra ndjekin pothuajse të njëjtën formë, çka ngushton llojin e fjalive që testohen. Asnjë prag nuk u akordua mbi B: pragjet e klasifikuesit vijnë nga E11.

Grupi A. Autori deklaron se lexoi vetëm A_kontekstet.md, nxori kërkesat për A01–A25, hartoi shpjegimet dhe pastaj e rishikoi skedarin pasi Claude i dha vërejtje për versionet e mëparshme: që proza të ishte origjinale dhe që çdo pohim i mjekut të ishte fjali e plotë më vete. Skedari nuk e vërteton këtë deklaratë. Versionet e mëparshme nuk u instaluan (një riformatim fjalë për fjalë i kontekstit, një prozë e shabllonizuar me fjali meta për konvertimin, një version me shenja citimi të një mjeti, [cite: 1]), as një version paralel që ndryshonte fjalët e mjekut në 6 citime dhe shtonte terma që nuk ishin në raport. Versioni i instaluar (evaluation/handwritten/A_shpjegimet.md, 2026-10-05) ka 0 fjali identike me fjali të kontekstit; citimet e mjekut janë kopjuar fjalë për fjalë, siç kërkohet. Shpjegimet nuk janë të pavarura nga gjeneruesi: vlerat, intervalet, përkufizimet e termave dhe citimet vijnë nga të njëjtat tabela, dhe kriteret e prozës i erdhën autorit nga vetë Claude. **Rregullat shënojnë 5 nga 25 shpjegime (20%),** dhe të 5 janë alarme të rreme të rregullave, jo defekte të tekstit: te A11, A14 dhe A16 trajta e shquar «Kolesteroli HDL/LDL» lexohet si kolesterol total (analit që dokumenti nuk e ka matur), dhe te A18 dhe A20 «25» te «Vitamina D 25-OH» lexohet si numër i pabazuar. Të njëjtat dy alarme ishin gjetur më parë te B (ADR 0009). Rregullat nuk u ndryshuan pas kësaj matjeje; nëse ndryshohen, ndryshimi duhet raportuar si i bërë pasi rezultati u pa. Rezultati është te evaluation/results/supplementary/kit_A.json.

5.7.2 Gjykatësi LLM: si u krye dhe çfarë nuk dihet

Asnjë ofrues me API falas nuk e mbulonte E12 mirë (ADR 0015), prandaj gjykatës është një model Claude i thirrur nga Claude Code si subagjent. Mostrat u ndanë në 15 batch-e me 20 elemente (evaluation/cache/judge_claude/), të përzier me farë të fiksuar; batch-et nuk përmbajnë etiketat e vërteta, që qëndronin te një skedar çelës jashtë dosjes që lexonin gjykatësit. Çdo përgjigje ruhet (answers_*.jsonl) dhe vlerësimi bëhet nga evaluation/judge_batches.py, me po atë kod metrikash si për rregullat dhe klasifikuesin.

Kufizimet që duhen thënë:

1. **Gjykatësi nuk është i pavarur nga sistemi:** është asistenti që ndihmoi ta ndërtojë; modelet e mëdha gjuhësore njohin dhe favorizojnë daljet e veta kur veprojnë si vlerësues [49], [47].
2. **Rezultati nuk garantohet të përsëritet:** temperatura dhe mostrimi nuk fiksohen. Çdo përgjigje është ruajtur, por një ekzekutim i ri mund të japë etiketa të tjera.
3. **Qasja te etiketat nuk u audit-ua teknikisht.** Çelësi ishte në një shteg që gjykatësit nuk e njihnin dhe udhëzimi e ndalonte kërkimin, por transkriptet e subagjentëve ishin

bosh. Provë indirekte: çdo subagjent Sonnet përdori 5 deri 7 thirrje mjetesh (lexim i udhëzimeve, i batch-it në pjesë, shkrim i përgjigjeve), pa hapësirë për kërkim; Haiku përdori 5 deri 47, tetë nga 15 mbi 25, dhe pati saktësi shumë më të ulët. Kjo nuk e provon mungesën e qasjes.

4. **Perfeksioni i Sonnet nuk është tavan i detyrës:** Haiku pajtohet me Sonnet në 152 nga 288 mostrat që iu përgjigj (53%), humbet 23 nga 30 rekomandime të munguara dhe 21 nga 40 analite të pambështetura, dhe bllokoi 14 nga 59 tekste të pastra. Pra detyra nuk është e lehtë për çdo model.
5. **Protokolli i Haiku ka dobësi të veta:** 9 nga 297 mostra mbetën pa përgjigje dhe katër skedarë kishin një rresht të parë të palexueshëm; ato numërohen si humbje, çka i ul pak numrat e tij. Edhe përjashtuar këto, saktësia mbi mostrat e përgjigjura është rreth 53%.

5.7.3 Katalogu r1.4: çfarë ndryshon dhe me çfarë çmimi

Gabimet e grupeve A, B, të E10 dhe të auditit të E8 ishin kryesisht leksikore: trajta e shquar e emrave (“Kolesteroli HDL” lexohej si kolesterol total, “25” te “Vitamina D 25-OH” si numër), drejtimi i shprehur me mbiemra ose emra (“të larta”, “ritja e”) që fjalori nuk e njohte, një drejtim i vetëm për tërë fjalinë, pohimi i përgjithshëm “të gjitha vlerat e tjera janë brenda intervalit”, dhe shpjegimet e shpikura në kllapa. r1.4 (ADR 0021) përmirëson katër rregulla (R1, R2, R3, R9) pa shtuar rregull të ri; r1.3 mbetet i riprodhueshëm, dhe vetëm shërbimi përdor r1.4. Të dy versionet u matën mbi të njëjtat mostra (python -m evaluation.compare_rules):

Tabela 26. Katalogu r1.3 kundrejt r1.4 mbi të njëjtat mostra

Matje	r1.3	r1.4
Shablloni mbi 500 kontekstet	0 shkelje	0 shkelje
E10, macro F1 (192 tekste testi)	0.993	1.000
Grupi B, macro F1 (105 fjali)	0.795	0.857
Grupi B, F1 e <code>direction_mismatch / ungrounded_number</code>	0.67 / 0.95	1.00 / 1.00
Grupi B, tekste të pastra të shënuara	1 nga 30	0 nga 30
Grupi A, shpjegime të shënuara	5 nga 25	0 nga 25
Auditi i E8, tekste të shënuara (nga 90)	0	25
Prej 40 teksteve me problem të llojeve të rregullave sipas auditit: të shënuara	0	17
Prej 38 teksteve që auditori i gjeti të pastra: të shënuara	0	2

Dy tekstet e shënuara që auditori i kishte gjetur të pastra janë pohime të përgjithshme ku një gjetje jashtë intervalit nuk përmendet (acidi urik; fosfori); sipas dëshmisë duken gabime të

vërteta që auditori i humbi, por kjo nuk u verifikua nga një gjykatës i pavarur. Në harness, r1.3 dhe r1.4 japin rezultate të ndryshme vetëm kur kërkohet shprehimisht (--rules r1.4). Tabelat e Kapitullit 5 janë me r1.3; E4 dhe E6–E8 me r1.4 janë te §5.6.2, ndërsa E9 dhe auditit vetëm me r1.3.

Si lexohet. r1.4 u hartua duke parë pikërisht këto gabime (shembujt e auditit, alarmet e rreme të A dhe B, vetë grupi B), prandaj A, B, E10 dhe auditit nuk janë më mostra të reja për të: tabela tregon sa kap defektet e njohura dhe sa mban pastërtinë e shabllonit, jo si do të sillej mbi tekst të pa parë, që mbetet i pamatur. Alarmet e rreme që hoqi janë, megjithatë, defekte të njohjes së emrave dhe jo përshtatje me një mostër. **Çfarë u përmirësua pak dhe çfarë jo:** fjalori i SP1–SP3 u zgjerua nga përkufizimi i politikave dhe nga shqipja klinike e zakonshme (pa lexuar rreshtat e B, dhe i matur një herë, pa u ritunuar sipas gabimeve të tij), dhe prohibited_claim ngjitet nga F1 0.46 në 0.57 mbi B; ungrounded_term_explanation mbetet 0.33 (1 nga 5), që do të thotë se shenjat e shpjegimit që shtova nuk e kapin formën e atyre fjalive. Citimet e mjekut nuk gjykohen nga SP1–SP3 dhe R9 te r1.4. E8 me r1.4 u ekzekutua (§5.6.2): ndalon më shumë drafte dhe ngre pjesën që përfundon te shablloni nga 25.2% në 33.2%.

5.8 Validimi mbi të dhëna reale

Nuk u krye. Nuk ka miratim etik dhe nuk u përdor asnjë dokument real; E13 është e pamatur. Pasoja është e rëndë: **asnjë rezultat i këtij kapitulli nuk mat sjellje mbi dokumente reale.** E1 dhe E3 (1.000) matin lidhjen e tubacionit mbi tekst të pastër; E2 dhe E5 matin një skanim të simuluar nga i njëjti gjenerues, jo një skaner dhe një faqosje të vërtetë; detektorët e testuar mbi tekst natyral (grupi B) janë testuar mbi fjali të dorëzuara nga autori, jo mbi raporte të mjekëve. Të gjitha këto janë kufij të sipërm të asaj që do të maten mbi dokumente reale, jo vlerësime të saj.

5.9 Rezultatet e studimit me përdorues

Nuk u krye. Nuk ka studim me përdorues dhe nuk ka rishikim ekspertësh; PK7 dhe pjesa e PK3 që kërkon vlerësim ekspertësh nuk kanë matje. Nuk fabrikohen përgjigje pjesëmarrësish. Pohimi që sistemi e bën rezultatin më të kuptueshëm për pacientin **nuk mbështetet nga asnjë matje e këtij punimi.**

5.10 Analiza e gabimeve

Taksonomia më poshtë ndërtohet nga gabimet e vërejtura gjatë eksperimenteve, jo nga një listë e paracaktuar. Kolona «Pasoja» thotë nëse gabimi është i sigurt (sistemi heshtet ose refuzon) apo i pasigurt (sistemi pohon diçka të gabuar).

Tabela 27. Taksonomia e gabimeve të vërejtura

#	Gabimi	Ku u vërejt	Sa	Pasoja	Gjendja
	Leximi (OCR)				
1	Vlerë e gabuar e pranuar (ndarësi dhjetor humbet: «15,7» lexohet «157»)	E2	125 nga 2 370 vlera të nxjerra	Pasigurt: vlera interpretohet me siguri. E3 ka 62 statuse të interpretuara gabim, 11 prej tyre kritike të rreme; ADR 0012 i lidh me ndarësin dhjetor të humbur	E hapur: kërkon kufij fiziologjikë me burim për çdo analit, ose deklarimin e kanalit të skanuar si të pasigurt për interpretim
2	Intervali referent i humbur ose i prishur	E2, E3	1 108 nga 2 370 intervale të nxjerra nuk përputhen; 986 vlera u bënë uninterpretable	I sigurt në 986 raste (SP5 refuzon); pjesa tjetër hyn te rreshti 1	Pjesërisht e mbyllur (SP5)
3	Analiti nuk u njoh dhe vlera nuk u nxor	E2	1 028 nga 3 388 vlera (30.3%)	Heshtje për atë vlerë; paralajmërimi i OCR-së në krye të faqes e tregon kanalën	E hapur
4	Njësi e prishur	E2, E9	518 nga 2 370 njësi të nxjerra nuk përputhen; E9: 158 shënime të rreme në 51 dokumente	E sigurt për përdoruesin (fallback), por dëmton shpjegimin	E hapur
5	Pohimi narrativ i një dokumenti të skanuar nuk rikthehet	E5	373 përputhje të humbura (263 me vlerë të lexuar, 110 pa vlerë); 28 nga 87 kundërshtime humbën	Pasigurt në heshtje: një kundërshtim raport-laborator nuk shfaqet	E hapur; shkak nuk është hetuar
6	Referencë e kryqëzuar e rreme	E5	10	Pasigurt, por i rrallë	E hapur
	Verifikimi me rregulla (grupi B)				
7	Drejtimi i shprehur me mbiemër nuk njihet («Eritrocitet janë të larta»; «Glukoza në serum është e lartë»)	B, E10	5 nga 10 <code>direction_mismatch</code> te B; 1 nga 27 te E10	Pasigurt: një drejtim i kthyer kalon verifikimin	E hapur. Fjalori i drejtimit (<code>find_direction</code>) njeh vetëm format e shabllonit
8	Pohime SP1–SP3 jashtë listës leksikore («ka diabet», «duhet të filloni trajtim», «do të normalizohet vetë»)	B	7 nga 10 <code>prohibited_claim</code>	Pasigurt: diagnoza, trajtim ose prognozë kalon	E hapur; lista leksikore është e shkurtër me qëllim
9	Shpjegim i termit të pashpjeguar në formë të shquar («Monocitoza do të thotë...» kundrejt «monocitozë» në	B	4 nga 5 <code>ungrounded_term_explanation</code>	Pasigurt: SP6 shkelet	E hapur. R9 krahason formën e palosur të termit pa morfologji (ndajshesa e shquar ndryshon zanoren e

#	Gabimi	Ku u vërej t	Sa	Pasoja	Gjendja
	tabelë)				fundit); kapi vetëm «eozinofilia» sepse fjala përmban «eozinofili»
10	Gjetje e shpikur me term jashtë tabelës («vërehet pankreatit»)	B	1 nga 10 fabricated_finding	Pasigurt	E hapur; mbulimi i tabelës së 82 termave
11	Shifra në emrin e analitit lexohet si numër i pambështetur («Vitamina D 25-OH»)	B	1 nga 30 fjali të pastra	Alarm i rremë, tekst i pastër bllokohet	E hapur
	Klasifikuesi				
12	Bllokun tekst të pastër	E11	rregulli 1: 30/30 dhe 29/30 të pastra; rregulli 2: 0 dhe 2 nga 30	Alarm i rremë; me rregull 1 detektor i është i padobishëm	Raportuar
13	Mëson shabllonin dhe jo defektin	E11, B	100% e formave të validimit të defekteve ishin në trajnim; fabricated_finding 1.00 → 0.00–0.43	Rezultati në korpusin sintetik është i fryrë	Raportuar (ADR 0009)
14	Alarme të rreme mbi njësi të OCR-së	E9	79 shkelje në tekstin e dorëzuar; 10.2% e dokumenteve	Tekst rezervë në vend të shpjegimit	E hapur
	Modeli gjuhësor (E4, E6–E9, auditi i E8)				
15	Drejtimit i gabuar që rregullat nuk e shohin: pohim i përgjithshëm («të gjitha vlerat e tjera janë brenda intervalit») pranë vlerës jashtë tij, vlerë e vendosur te analiti tjetër	Audit i i E8	21 nga 90 tekste të kaluara (23%); në E7, 235 shkelje drejtimi të prodhuara, 42% e të gjitha	Pasigurt: një drejtim i kthyer kalon verifikimin	E hapur; pasqyrë e kufijve të R3 (rreshti 7)
16	Shpjegim i shpikur ose i gabuar i një termi ose analiti («TSH — hormoni i stimulimit të mëlçisë») dhe pohime të tjera të pambështetura	Audit i i E8	31 probleme other_unsupported dhe 26 ungrounded_term_explanation te 90 tekste; një pjesë janë të padëmshme	Pasigurt kur shpjegimi është i gabuar	E hapur; asnjë rregull nuk e kontrollon një shpjegim analiti
17	Rekomandim i mjekut i humbur nga modeli	E4, E7	30 nga 612 (4.9%) te drafti; 104 shkelje omitted_recommendation te E7	Rrezik; i kapur nga R8	E mbyllur nga R8 dhe rigjenerimi
18	Çmimi i verifikimit: tekst i gjeneruar i zëvendësuar me shabllon	E8	126 nga 500 dokumente (25.2%); rigjenerimi riparoi 121 nga 247	I sigurt, por më pak i dobishëm për pacientin	Raportuar
19	Klasifikuesi i fjalisë dërgon dokumente te shablloni	E9	302 nga 500 dokumente (60.4%); 41 shkelje në shabllone (alarme të rreme)	I sigurt, çmim i lartë	E hapur; klasifikuesi nuk u vlerësua mbi tekst të modelit pa rregullat
20	Dega B nuk njih drejtimin e shprehur me emër («rritja e TSH-së», «ulje e kreatininës»), lexon «nuk mund të mohohet» si mohim të	Grupi C	0 nga 25 negacione dhe pseudo-negacione plotësisht saktë; 13 nga 41 fjali jo-identike me gjeneruesin	Pasigurt në heshtje: polariteti ose drejtimi i një pohimi të mjekut kthehet ose humbet	E hapur; vokabulari i drejtimit dhe i polaritetit (assertions.py)

#	Gabimi	Ku u vërej t	Sa	Pasoja	Gjendja
	thjeshtë dhe nuk njih «nuk nevojitet»/«nevoja për»				

Për rreshtat 7 deri 11, §5.7 dhe ADR 0009 japin shkaqet; për 15 dhe 16, §5.6.1; për 20, §5.5.1. Rregullat r1.3 **nuk u ndryshuan pasi grupi B u mat**, që B të mbetet matje e pavarur; ndryshimi i tyre pas kësaj do të duhej raportuar si ndryshim pas shikimit të rezultatit.

Gabime të vetë matjes. Pesë gabime të harness-it ose të metrikës u gjetën gjatë punës dhe janë korrigjuar, por ato tregojnë se një matje që duket e rregullt mund të jetë e prishur: (1) F1 hidhej poshtë për një klasë që detektori e humbte plotësisht, dhe një klasifikues që nuk kapte asgjë në pesë nga shtatë llojet dilte me macro F1 0.96; (2) pragu me macro F1 maksimal nuk kishte kufi për alarmet e rreme dhe zgjidhte pika që bllokunin ~98% të teksteve të pastra; (3) një vlerësues që shtonte citimin e përmbysur në fund jepte 0 nga 20 për një arsye që s’kishte lidhje me rregullat; (4) metrika e PK5 matet me po ato rregulla që e bllokojnë tekstin, prandaj «0 shkelje» nuk thotë «0 gabime»: u shtua audit i pavarur i §5.6.1; (5) një rresht i përsëritur te B (korrigjuar nga autori) e fryente llojin e tij. Gjithashtu, ndërfaqja gjeti dy defekte që asnjë metrikë nuk i kishte gjetur: një interval i lexuar si «vlerë dhe njësi» e shfaqur pacientit si vlerë e matur, dhe një pikë e OCR-së që ndante çdo numër dhjetor dhe e bënte shabllonin vetë të dështonte verifikimin (ADR 0011 dhe 0012).

6 DISKUTIME DHE PËRFUNDIME

6.1 Diskutimi i rezultateve

Seksioni lexon PK1–PK7 në dritën e hipotezave (§3.2). Çdo pohim mbështetet te një tabelë e Kapitullit 5 dhe mban kufizimet e saj; asnjë rezultat nuk vjen nga dokumente reale.

PK1 dhe PK2 (nxjerrja dhe statusi). Mbi dokumentet dixhitale të korpusit sintetik të dyja dalin 1.000, dhe kjo thotë vetëm se tubacioni është lidhur saktë (§5.2). Mbi skanimet e simuluar F1 është 0.670 dhe saktësia e statusit 0.881; ajo që ka rëndësi është se 125 vlera të gabuara pranohen dhe 62 marrin status të interpretuar gabim, 11 prej tyre kritike të rreme (§5.3). Një kontroll i ngushtë i presjes dhjetore i ul ato 62 në 0 për çmimin e 23 rreshtave të humbur (§5.3.1), por është matur vetëm mbi dokumentet mbi të cilat u projektua, dhe pa kufij fiziologjikë me burim dhe pa dokumente reale kanali i skanuar nuk është i sigurt për interpretim.

PK3 (besnikëria e thjeshtimit). Ruajtja e mohimit (0.994) dhe e rezervës (1.000) është matur mbi një model që e kopjon fjalën e mjekut sipas udhëzimit, jo mbi një model që e parafrazon; ajo tregon pra që modeli e ndoqi udhëzimin e kopjimit. Numëruesi vjen nga rregullat, që kanë kufijtë e tyre. PK3 në formën e planifikuar mbetet e pamatur (§5.4).

PK4 (krahasimi i kryqëzuar). 1.000 mbi dokumentet dixhitale dhe 0.863 me OCR. Rëndësi ka që 28 nga 87 kundërshtime humbën, të gjitha në dokumente të skanuara: një mospërputhje raport–laborator nuk i shfaqet pacientit pikërisht aty ku OCR-ja dështon (§5.5). Mbi 60 fjali të dorëzuara nga autori (sipas deklaratës së tij), nxjerrja e pohimeve del plotësisht e saktë vetëm te 32, dhe te 13 nga 41 fjali jo-identike me gjeneruesin; negacionet dhe pseudo-negacionet me drejtim të shprehur me emër nuk njihen (§5.5.1).

PK5 dhe hipoteza e parë. Bazimi e ul normën e shkeljeve nga 54.4 në 9.5 për 100 fjali, dhe verifikimi me rregulla e ul deri në 0.000, me çmimin e 25% të dokumenteve që përfundojnë te shablloni (§5.6). Ky zero është kufi i poshtëm i gabimeve, jo mungesë e tyre: një audit i pavarur i 90 teksteve që kaluan verifikimin gjeti një problem të llojeve që rregullat synojnë te 36% e tyre (26–46%), më shpesh drejtim të gabuar (23%). H1 konfirmohet pra në formën e matur dhe jo si garanci. Dy mësimet dalin: pjesa më e madhe e punës bëhet nga bazimi (54.4 në 9.5), dhe pjesa e mbetur me një model të vogël është kryesisht pohime ose shpjegime të pambështetura dhe drejtim i gabuar; dhe rregullat e shkruara kundrejt formave të pritura humbasin një pjesë të madhe të gabimeve kur ato shprehen në formë të lirë.

PK6 dhe hipoteza e dytë. Rregullat arrijnë macro F1 0.993 mbi korpusin e korruptuar dhe 0.795 mbi fjalitë natyrale; klasifikuesi vetëm 0.015–0.177 mbi to; gjykatësi Claude Sonnet 1.000 dhe Haiku 0.625 dhe 0.514 (§5.7). H2, që detektori është më i saktë për degën laboratorike, nuk konfirmohet: nuk ka diferencë të qëndrueshme mes degëve, dhe një detektor i përsosur nuk mund ta tregojë një diferencë.

PK7. Nuk u mat: nuk u krye studim me përdorues (§5.9).

6.2 Asimetria e bazimit ndërmjet të dhënave të strukturuar dhe tekstit të lirë

Kjo është gjetja konceptuale kryesore e punimit dhe mund të artikulohet pavarësisht nga madhësia e efektit të matur.

Kur burimi është një objekt i strukturuar me vlera numerike të njohura, pyetja nëse një pohim mbështetet nga burimi ka përgjigje të vendosshme. Verifikimi është krahasim dhe jo gjykim, dhe norma e gabimit të tij kufizohet vetëm nga saktësia e fazës së nxjerrjes.

Kur burimi është prozë klinike, ekuivalenca semantike nuk reduktohet në krahasim të saktë. Pyetja nëse një fjali e ruan kuptimin e burimit kërkon gjykim, dhe çdo mekanizëm automatik gjykimi ka normë gabimi të pashmangshme. Rezultati i raportuar nga Laban et al. [4], një saktësi e balancuar prej afërsisht 74 përqind për zbulimin e mospërpjethjeve me metoda të bazuara në natural language inference, ilustron se ky nuk është kufizim i implementimit konkret të këtij punimi por i qasjes në përgjithësi në gjendjen aktuale të teknikës.

Pasoja praktike është se garancia që sistemi mund t’i japë përdoruesit nuk është uniforme. Për vlerat laboratorike, pohimi se asnjë numër i pambështetur nuk arrin të përdoruesi është i fortë dhe i verifikueshëm. Për tekstin narrativ, pohimi i barasvlershëm është probabilistik dhe duhet formuluar si i tillë.

Ky punim argumenton se kjo asimetri duhet deklaruar hapur në çdo sistem të ngjashëm. Paraqitja e të dy rasteve pas një treguesi të vetëm që thotë thjesht se dalja është verifikuar do të ishte mashtruese për përdoruesin, sepse do t’i jepte të njëjtin nivel besimi dy pohimeve me forcë të ndryshme evidence.

Çfarë thonë matjet. Matjet nuk e konfirmojnë asimetrinë si diferencë të matur të detektimit (H2), por auditi i §5.6.1 tregon diçka më të hollë. Edhe te dega e vlerave të strukturuar — drejtimi, numri, analiti, ku pyetja ka përgjigje të vendosshme — verifikimi me rregulla humbet gabime kur ato shprehen në formë të lirë: drejtim i gabuar në 23% të teksteve që kaluan. Vendosshmëria e pyetjes nuk është pra vendosshmëri e zbatimit: një rregull

deterministe është i saktë vetëm për format që njih. Argumenti konceptual qëndron; garancia e fortë për vlerat laboratorike nuk u arrit nga rregullat e zbatuara, dhe kjo pjesë mbetet punë e hapur.

6.3 Rregullat, klasifikuesi dhe gjykatësi LLM në verifikim

Tre detektorë u krahasuan mbi të njëjtat mostra (Tabela 22):

- **Rregullat** arrijnë macro F1 0.993 mbi korpusin e korruptuar dhe 0.795 mbi grupin B, me alarme të rreme pothuajse zero. Recall-i bie kur gabimi shprehet ndryshe nga forma e pritur, dhe mbi tekstin e vërtetë të modelit, të rreth një e treta e teksteve që kaluan verifikimin ka problem që rregullat nuk e kapën (§5.6.1).
- **Klasifikuesi XLM-RoBERTa**, trajnuar mbi korpusin e korruptuar, arrin 0.326–0.538 aty dhe 0.015–0.177 mbi grupin B: ai mëson shabllonet e gjeneruesit (100% e formave të validimit ishin në trajnim). Me një prag që kufizon alarmet e rreme nuk kap asgjë për drejtimin dhe polaritetin, dhe në E9 e çon 60% të dokumenteve të shablloni, kundrejt 25% pa të.
- **Gjykatësi LLM**: Claude Sonnet 1.000 mbi të dyja mostrat, Claude Haiku 0.625 dhe 0.514.

Argumenti strukturor i hartimit paraprak, që rregullat janë të plota aty ku problemi është i vendosshëm dhe klasifikuesi i domosdoshëm aty ku nuk është, nuk gjen mbështetje: klasifikuesi i trajnuar mbi shabllone nuk është kompetent pikërisht aty ku rregullat dështojnë. Klasa e gabimeve në korpusin sintetik është kryesisht e vendosshme me mjete deterministe, por kjo është veti e korpusit sintetik, jo e tekstit të vërtetë: mbi dalje të vërteta të modelit rregullat humbasin gabime që një lexues i vëmendshëm i gjen.

Ajo që e mbush boshllëkun është një detektor që e kupton tekstin, dhe ai ka kosto: një model i fuqishëm, rezultat që nuk përsëritet saktësisht, dhe që në këtë punim nuk është i pavarur nga sistemi (§5.7.2). Gjykatësi i vogël tregon se jo çdo model LLM e mbush boshllëkun. Një projektim i arsyeshëm do t'i kombinonte rregullat si shtresë të parë, të lirë dhe të përsëritshme, me një gjykatës LLM si shtresë të dytë; ky kombinim nuk u mat këtu (E9 mat rregullat plus klasifikuesin, jo rregullat plus gjykatësin).

Çfarë ndryshoi pas matjeve, dhe çfarë nuk. Dy përmirësime u bënë pasi u panë gabimet: kontrolli i presjes dhjetore të OCR-së (§5.3.1) dhe katalogu r1.4 (§5.7.3). Të dyja janë matur mbi mostra që ndikuan hartimin e tyre; vlera e tyre mbi tekst të pa parë është e pamatur.

Tabelat kryesore të Kapitullit 5 janë me r1.3 dhe pa kontrollin, dhe E4 e E6–E8 janë rishikuar veçmas me të dyja (§5.6.2): bazimi dhe verifikimi mbajnë të njëjtën formë, por çmimi (shablloni rezervë) ngrihet nga 25.2% në 33.2%. Klasifikuesi nuk u përmirësua dhe nuk është pjesë e shërbimit (ADR 0022): shkak është mungesa e fjalive natyrale me etiketa të pavarura, jo madhësia e modelit. Kjo e ngushton pretendimin e punimit për verifikim me mësim makinerik: ai u ndërtua, u mat dhe u gjet i pamjaftueshëm mbi tekst natyral, ndërsa verifikimi i vendosur është me rregulla, me kufijtë që §6.6 i emërton.

6.4 Përpunimi i gjuhës natyrore mjekësore për shqipen

Mungesa e modeleve klinike të paratrajnuara për shqipen e detyroi dizajnin drejt fjalorëve dhe rregullave për komponentët e vendosshëm, dhe drejt enkoderëve shumëgjuhësh të përgjithshëm për ata semantikë.

Tabela terminologjike e ndërtuar në kuadër të këtij punimi (82 terma) mund të shërbejë si pikënisje për punime të ardhshme, por sot nuk është artefakt i ripërdorshëm: asnjë nga 82 shpjegimet nuk ka burim të shënuar dhe asnjë nuk është rishikuar nga një klinikist.

Cilësia e gjenerimit në shqip nuk u vlerësua. Punimi nuk ka rishikim ekspertësh dhe as lexim të tekstit të gjeneruar nga një folës i shqipes (§5.9); pjesa e PK3 që kërkon vlerësim njerëzor mbetet pa matje. Ajo që u mat është besnikëria ndaj bazimit, jo rrjedhshmëria apo kuptueshmëria: E4 (§5.4) mat që mohimi, rezerva dhe rekomandimi mbijetojnë kur modeli i kopjon fjalët e mjekut, dhe audit i E8 (§5.6.1) gjeti shpjegime të shpikura ose të gabuara të termave dhe analiteve (p.sh. TSH shpjeguar si «hormoni i stimulimit të mëlçisë») në tekste që kaluan verifikimin. Prandaj pohimi për shqipen kufizohet te pasoja arkitekturore e mungesës së modeleve klinike; punimi nuk ka rezultat që thotë se modeli shkruan shqip mjekësor të mirë.

6.5 Konsideratat e sigurisë dhe rregullatore

Sistemi është projektuar si mjet shpjegues dhe refuzon në mënyrë sistematike pohimet diagnostike, terapeutike dhe prognostike. Punimi nuk pretendon se ky pozicionim e vendos sistemin përfundimisht jashtë fushës së rregullores për pajisjet mjekësore, sepse kufiri ndërmjet informacionit shpjegues dhe informacionit që përdoret për vendimmarrje klinike varet nga përdorimi real dhe jo vetëm nga qëllimi i deklaruar.

Për sa i përket Aktit Evropian për Inteligjencën Artificiale, detyrimet e transparencës janë tashmë të zbatueshme, ndërsa regjimi për sistemet me rrezik të lartë hyn në fuqi më vonë.

Sistemi i zbaton detyrimet e transparencës përmes shënimit të përhershëm dhe treguesit të verifikimit të pranishëm në çdo dalje.

6.6 Kufizimet e punimit

Kufizimet renditen nga më e rëndësishmja. Secila thotë çfarë nuk dihet, jo çfarë shpresohet.

1. Nuk ka dokumente reale, studim me përdorues dhe rishikim ekspertësh. Nuk ka miratim etik; E13 dhe E14 nuk u kryen. Korpusi vizaton tekst të pastër në koordinata të njohura, prandaj E1 dhe E3 (1.000 mbi dixhitalet) matin lidhjen e tubacionit, jo vështirësinë; skanimi është i simuluar, jo një skaner i vërtetë. Asnjë numër i Kapitullit 5 nuk është vlerësim i sjelljes mbi dokumente reale, dhe nuk ka asnjë provë se sistemi e bën rezultatin më të kuptueshëm për pacientin (PK7). Ky është kufizimi më i rëndësishëm.

2. Një model gjuhësor i vetëm, i vogël, me plan falas. Gjeneruesi është Mistral ministral-14b-2512; rezultatet e E4 dhe E6–E9 nuk thonë asgjë për modele të tjera, as më të forta (që do të gabonin ndryshe) as lokale (E15, e pamatur). Shqipja nuk u verifikua si gjuhë e mbështetur zyrtarisht prej tij, dhe cilësia e shqipes së gjeneruar nuk u vlerësua nga një folës amtar. Kërkesa p1 përshtatet me fjalorin e verifikuesit (Shtojca D.2), prandaj kushtet B–D maten më favorshëm për verifikimin se me një kërkesë të lirë.

3. Metrika kryesore është pjesërisht rrethore, dhe auditit që e korrigjon është i kufizuar. Normat e PK5 numërojnë shkeljet me po ato rregulla që e bllokojnë tekstin; «0 shkelje» do të thotë «asnjë që rregullat shohin». Auditit i pavarur (§5.6.1) mbulon 90 tekste, ka gjykatës të pasaktë, gjetje kufitare, dhe mat një kufi të poshtëm; nuk mat normën e vërtetë të pohimeve të pambështetura. Verifikimi semantik nuk ofron garanci por vetëm ulje të matshme të rrezikut, dhe norma e tij e gabimit nuk është zero.

4. Gjykatësi LLM nuk është i pavarur dhe nuk përsëritet saktësisht. Gjykatësi i E12 dhe i auditit është një model Claude që ndihmoi ta ndërtojë sistemin; temperatura dhe mostrimi nuk fiksohen; qasja te etiketat nuk u audit-ua teknikisht (§5.7.2). Perfeksioni i Sonnet (1.000) nuk është tavan i detyrës: Haiku merr 0.625 dhe 0.514. Gjykatësi i dytë, i pavarur nga ndërtuesi, mungon.

5. Detektorët u matën mbi tekst të prodhuar nga i njëjti gjenerues dhe mbi një grup të vogël fjalish natyrale. Macro F1 0.993 i rregullave përshkruan korpusin e korruptuar; rënia në 0.795 mbi grupin B dhe humbja e gabimeve mbi tekstin e modelit janë provat se ai numër nuk përgjithësohet. Grupi B ka 105 fjali me 5 deri 10 për lloj defekti, një autor, fjali të pastra

shumë njëtrajtëshme, dhe nuk ka rreshta për `missing_critical`. Grupi B u dorëzua nga autori si punë e vet; gjatë punës ekzistonte në depo një draft i mëparshëm i hartuar nga një model gjuhësor (Claude), që u zëvendësua, dhe 12 nga 105 rreshta të skedarit përfundimtar (vetëm citime të mjekut) janë identikë me rreshta të atij drafti (§5.7.1). Grupi A (25 shpjegime referuese, të dorëzuara nga autori sipas deklaratës së tij) nuk ka defekte të futura dhe jep vetëm shkallën e alarmeve të rreme të rregullave mbi prozë të riformuluar nga të njëjtat tabela: 5 nga 25 (§5.7.1). Grupi C (60 fjali narrative, të dorëzuara nga autori sipas deklaratës së tij) u mat vetëm për Degën B (§5.5.1): 19 nga 60 fjali janë identike me fjali të gjeneruesit, prandaj vlera e tij mbi tekst të lirë jepet te 41 fjalitë e tjera.

6. Klasifikuesi mëson shabllonin. 100% e formave të fjalive me defekt të validimit ishin tashmë në trajnim, dhe çdo gjetje e shpikur fillon me të njëjtën shprehje. Rezultati mbi korpusin sintetik nuk është dëshmi e zbulimit të defektit. Klasifikuesi u trajnua një herë (një farë, tri epoka, GPU Tesla T4), pa variancë ndërmjet ekzekutimeve; pragu i dytë u shtua pasi testi ishte parë. Efekti i tij mbi tekstin e modelit (E9) matet vetëm me rregullat, jo nga një auditor i pavarur. Klasifikuesi nuk është pjesë e verifikimit të vendosur dhe nuk u rihartua: problemi janë të dhënat (fjali natyrale me etiketa të pavarura), që nuk ekzistojnë jashtë grupeve të rezervuara për provë, dhe trajnimi kërkon GPU (ADR 0022).

7. Pasiguria statistikore dhe prejardhja. E4 dhe E6–E9 kanë intervale besimi; vlerat e tjera (E10, E11, grupi B, E12) janë pikësore, me mostra të vogla: te E10 `hedge_removed` ka 3 mostra dhe `polarity_flip` 12. E10 dhe E11 mbajnë tani sha-n e një kopjeje të pastër, por parashikimet e E11 vijnë nga Colab pa sha të kodit të trajnimit; grupi B (klasifikuesi dhe gjykatësit) nuk mban metadata; E12 dhe auditi nuk kanë sha git; dhe versioni i korpusit, që nuk rindërtohej nga një kopje e re për shkak të mbarimeve të rreshtave, riderivohet tani (`.gitattributes`, `scripts/verify_corpus.py`; §5, hyrja) për sa kohë tabelat burimore nuk ndryshojnë. Katër metoda u ndryshuan pasi rezultati i mëparshëm ishte parë (§5, hyrja).

8. OCR-ja është rrezik sigurie, jo vetëm saktësie. Me Tesseract, një konfigurim, 125 nga 2 370 vlera të nxjerra nga skanimet janë të gabuara dhe pranohen. Pa kontroll, 62 marrin status të interpretuar gabim, 11 prej tyre kritike të rreme; një kontroll i ngushtë i presjes dhjetore (ADR 0020, §5.3.1) i ul në 0 dhe 0, për çmimin e 23 rreshtave të humbur, por është projektuar dhe matur mbi të njëjtat dokumente, nuk kap vlera të tjera të lexuara gabim, dhe një vlerë e vërtetë e shtypur pa presje do të humbiste. Nuk ka kontroll me kufij fiziologjikë me burim, dhe deri sa kontrolli të testohet mbi skanime reale (E13), interpretimi i kanalit të skanuar nuk duhet të konsiderohet i sigurt. E4 e E6–E8 u rishikuan me kontrollin (§5.6.2); E9 dhe auditi

jo. Pohimet narrative të dokumenteve të skanuara nuk rikthehen (28 nga 87 kundërshtime humbën), dhe shkaku nuk u hetua.

9. Rregullat kanë kufij leksikorë të njohur, dhe r1.4 u hartua mbi gabimet e njohura.

Me r1.3 rregullat njihnin drejtimin vetëm në format që kishin (5 nga 10 gabime drejtimi nuk u kapën te B; 23% e teksteve të modelit që kaluan kishin drejtim të gabuar), 7 nga 10 pohime diagnostike, trajtimi ose prognoze kaluan, dhe R9 humbi 4 nga 5 shpjegime të termave të pashpjeguar. r1.4 (ADR 0021, §5.7.3) i trajton disa prej tyre (macro F1 mbi B $0.795 \rightarrow 0.857$; 17 nga 40 tekste me problem sipas auditit tani shënohen), por u hartua pasi u panë pikërisht ato gabime, prandaj A, B dhe auditit nuk janë më mostra të pastra për të; diagnoza, trajtimi dhe prognoza u përmirësuan pak (3 nga 10 në F1 $0.46 \rightarrow 0.57$) dhe shpjegimet e termave aspak (0.33). Kapitulli 5 jep të dyja versionet (§5.6.2); E9 dhe auditit vetëm me r1.3.

10. Burimet. Tabela terminologjike ka 82 terma dhe nuk mbulon çdo term të mundshëm mjekësor; asnjë nga 82 termat dhe asnjë nga 11 rregullat e kombinimit nuk ka burim të shënuar, dhe asnjë nuk është vlerësuar klinikisht. Paneli ka 38 analite, dhe rezultatet laboratorike jonumerike nuk mbulohen fare. Chat-i i lidhur me dokumentin nuk është ndërtuar.

11. Llogaria është e forcuar, jo e plotë. Konfirmimi me email, rivendosja e fjalëkalimit, hapi i dytë TOTP, rindërgimi i mesazheve, kufizimi i regjistrimeve dhe i hyrjeve, seancat e revokueshme dhe «dil kudo» janë të provuara me teste (përfshirë prishje të qëllimshme që testet i kapën, teste integrimi mbi PostgreSQL 16 dhe prova konkurrence), por: nuk ka rrugë rimëkëmbjeje nëse humbasin edhe aplikacioni i vërtetimit edhe kodet e rimëkëmbjes; nuk ka rigjenerim kodesh, WebAuthn, SMS apo pajisje të besuara; sekretet TOTP ndajnë çelësin e ruajtjes me skedarët, prandaj ndërrimi i tij kërkon rikodim të të dyjave; kufizimet janë te baza e të dhënave dhe një sulmues që e di fjalëkalimin mund ta mbyllë përkohësisht hapin e dytë të një përdoruesi; koha e barabartë e degëve u siguruar duke e ekzekutuar Argon2 në secilën, por nuk u mat; rindërgimi automatik varet nga punëtori arq dhe nuk u provua me Redis të vërtetë; nuk ka CSP dhe HSTS; dërgimi me SMTP u provua me transporte të simuluar dhe një herë kundrejt kutisë së provës të Mailtrap (mesazhi mbërriti dhe lidhja konfirmoi llogarinë), jo kundrejt një kutie të vërtetë apo një ofruesi prodhimi; regjistrimi i një email-i të tjetrit para zotëruesit mbetet i mundshëm deri në konfirmim (ADR 0016). Asnjë nga këto nuk prek matjet e Kapitullit 5.

12. Modeli në aplikacion është i fikur si parazgjedhje dhe i pa-provuar mbi të dhëna reale. ANALYTE_SERVICE_GENERATOR=model e ndez (ADR 0017); pa të, build_services

ndërton TemplateGenerator, edhe kur .env ka ofruesin për eksperimentet. Shtegu «model, verifikim, rigjenerim, shabllon rezervë» është provuar me një ofrues të simuluar (13 teste) dhe një herë me Mistral të vërtetë mbi një dokument sintetik, ku verifikimi e refuzoi dy herë (4 dhe 1 shkelje) dhe doli shablloni rezervë; cilësia e tekstit të modelit mbi dokumente reale nuk u mat (E13). Me modelin e ndezur, të dhënat e pacientëve dalin te një ofrues i jashtëm. Kontrollat teknike ekzistojnë (pëlqim për çdo ngarkim, portë çidentifikimi me dështim të mbyllur, fshirje, eksport, afat ruajtjeje; ADR 0019, §4.12), por vendimet mbeten të hapura: kushtet e planit falas për ruajtjen dhe përdorimin e të dhënave, a vlen një kuti pëlqimi si pëlqim ligjor për të dhëna shëndetësore, baza ligjore, marrëveshja e përpunimit, transferimi jashtë BE-së dhe miratimi etik. Pamjet e ndërfaqes (Figurat 12–16) janë prodhuar me shabllonin.

13. Porta e çidentifikimit dhe fshirja kanë kufij të njohur. Porta është heuristikë mbi shqipen e lirë: nuk kap emra me shkronja të vogla, emra që rastisin me një fjalë të fjalorit, as pothuajse-identifikues pa trajtë (profesion i rrallë, ngjarje e veçantë, vend i përshkruar me fjalë); mbi-blokon fjali me fjalë të zakonshme jashtë listës dhe numra me katër shifra. U provua vetëm me fjali të shkruara nga ndërtuesi dhe me narrativa sintetike (0 nga 400 të shënuara, e pamatur mbi tekst real), dhe fjalori u formua mbi të njëjtat narrativa; një dokument që e kalon mund të mbajë ende të dhëna personale. Intervallet referente që varen nga gjinia dërgohen si numra, prandaj gjinia mund të nxirret tërthorazi. Pas fshirjes mbetet regjistri i auditimit (identifikuesi i rastësishëm i dokumentit, koha, lloji i ngjarjes), një ngarkim që shkruhet pikërisht kur fshihet llogaria mund të lërë një skedar të koduar pa rresht, kopjet rezervë nuk preken, dhe fshirja e llogarisë dhe eksporti ekzistojnë vetëm si API, pa ndërfaqe. Sistemi nuk mund t'i kërkojë ofruesit fshirjen e asaj që ka marrë. Matjet e modelit te Kapitulli 5 janë pa këto filtra dhe nuk përshkruajnë më atë që sheh një përdorues real me modelin e ndezur.

6.7 Mundësitë për zhvillime të mëtejshme

Validimi mbi një grup më të gjerë dokumentesh reale nga laboratorë të ndryshëm do të ishte hapi i parë dhe më i rëndësishëm për të konfirmuar përgjithësueshmërinë e rezultateve.

Zgjerimi i tabelës terminologjike dhe i panelit të analiteve do ta rriste mbulimin praktik të sistemit pa ndryshuar arkitekturën.

Zhvillimi i modeleve të specializuara të përpunimit të gjuhës natyrore për shqipen mjekësore do ta hiqte kufizimin themelor që ka formësuar dizajnin e këtij sistemi.

Metoda më të sofistikuar të verifikimit semantik mund ta ngushtojnë hendekun ndërmjet dy degëve, megjithëse argumenti i nënkapitullit 6.2 sugjeron se ai nuk mund të mbyllet plotësisht.

Vendosja lokale e një modeli gjuhësor me peshë të hapur do ta eliminonte transferimin e të dhënave shëndetësore te palë të treta dhe do të thjeshtonte ndjeshëm pozicionin e sistemit në raport me mbrojtjen e të dhënave.

Zgjerimi i rregullave që të mbulojnë drejtimin dhe analitin në formë të lirë (përshkrime me mbiemra, pohime të përgjithshme si «të gjitha vlerat e tjera janë brenda intervalit», morfologjia e shquar e shqipes) do të ngushtonte hendekun që auditi i §5.6.1 tregoi, pa ndryshuar arkitekturën; ndryshimi duhet matur mbi një grup të ri, jo mbi B.

Përsëritja me një model më të fortë, me një model lokal (E15) dhe me një gjykatës të dytë të pavarur nga ndërtuesi i sistemit, me temperaturë të fiksuar, do ta ndante rezultatin e punimit nga cilësia e një modeli të vetëm të vogël.

Së fundi, validimi klinik me pjesëmarrjen e profesionistëve shëndetësorë do të ishte parakusht për çdo përdorim real të sistemit përtej kontekstit kërkimor.

6.8 Përfundimet

Pyetja kryesore. Pyetja ishte deri në ç'masë mund të gjenerojë një sistem shpjegime të kuptueshme për pacientin pa përmbajtje të pambështetur, dhe si ndryshon siguria e garancisë mes të dhënave të strukturuar dhe tekstit të lirë. Matjet japin një përgjigje të kufizuar. Me një model të vogël falas mbi një korpus sintetik, bazimi e ul normën e shkeljeve nga 54.4 në 9.5 për 100 fjali dhe verifikimi me rregulla e ul deri në 0.000, por me çmimin e 25% të dokumenteve që përfundojnë te shablloni dhe pa garanci. Emëruesi i 0.000 janë fjalitë e të gjitha drafteve; mbi tekstin e dorëzuar, 44% e të cilit është shabllon, kufiri i sipërm është 0.038, dhe mbi fjalitë e vetë modelit 0.067 (§5.6). Garancia mungon sepse një audit i pavarur gjen një problem të llojeve që rregullat synojnë te 36% e teksteve që kaluan (26–46%), më shpesh drejtim të gabuar. Diferenca mes dy degëve e pritur nga asimetria e bazimit nuk u pa te detektimi.

Hipotezat. H1 (verifikimi e ul ndjeshëm normën e pohimeve të pambështetura që arrijnë te përdoruesi) **konfirmohet në formën e matur** dhe jo si garanci. H2 (detektori është më i saktë për degën laboratorike) **nuk konfirmohet**.

Kontributet e konfirmuara nga rezultatet.

1. Një arkitekturë ku modeli merr vetëm një objekt të tipizuar bazimi, e zbatuar dhe e provuar me test, mbi të cilën matet ablacioni me një model të vërtetë (54.4, 9.5, 0.000).
2. Një infrastrukturë vlerësimi me prejardhje, cache të përgjigjeve të modelit dhe riekzekutim nga kopje e pastër, që e bën çdo numër të rikrijueshëm pa thirrje të reja.
3. Gjetja se metrika e shkeljeve matet me rregullat që e bllokojnë tekstin dhe se «0 shkelje» nuk thotë «0 gabime», dhe një audit i pavarur që e mat diferencën.
4. Gjetja se klasifikuesi i trajnuar mbi një korpus të korruptuar mëson shabllonin e gjeneruesit, dhe se rregullat e shkruara kundrejt atij korpusi humbasin një pjesë të gabimeve të tekstit të vërtetë.
5. Gjetja se OCR-ja është rrezik sigurie: 125 vlera të gabuara pranohen me siguri; dhe një kontroll i ngushtë i presjes dhjetore që i ul statusët e gabuara nga 62 në 0 (§5.3.1), i matur vetëm mbi dokumentet mbi të cilat u projektua.
6. Struktura e verifikimit si e vendosur: rregulla të versionuara (r1.3 i ngrirë, r1.4 i përmirësuar), me matje të ndara për secilin dhe me kontaminimin e deklaruar (§5.7.3), dhe një klasifikues i matur dhe i hequr nga shërbimi (ADR 0022).

Ajo që mbetet e paprovuar. Sjellja mbi dokumente reale; kuptueshmëria për përdoruesin; rezultati me një model më të fortë ose lokal; rishikimi i ekspertëve klinikë; një gjykatës i pavarur nga ndërtuesi i sistemit; dhe kombinimi i rregullave me një gjykatës LLM si shtresë e dytë.

7 REFERENCAT

- [1] W. W. Chapman, W. Bridewell, P. Hanbury, G. F. Cooper, and B. G. Buchanan, “A simple algorithm for identifying negated findings and diseases in discharge summaries,” *Journal of Biomedical Informatics*, vol. 34, no. 5, pp. 301–310, 2001, doi: 10.1006/jbin.2001.1029.
- [2] H. Harkema, J. N. Dowling, T. Thornblade, and W. W. Chapman, “ConText: An algorithm for determining negation, experiercer, and temporal status from clinical reports,” *Journal of Biomedical Informatics*, vol. 42, no. 5, pp. 839–851, 2009, doi: 10.1016/j.jbi.2009.05.002.
- [3] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, “Survey of hallucination in natural language generation,” *ACM Computing Surveys*, vol. 55, no. 12, Art. no. 248, 2023, doi: 10.1145/3571730.
- [4] P. Laban, T. Schnabel, P. N. Bennett, and M. A. Hearst, “SummaC: Re-visiting NLI-based models for inconsistency detection in summarization,” *Transactions of the Association for Computational Linguistics*, vol. 10, pp. 163–177, 2022, doi: 10.1162/tacl_a_00453.
- [5] Y. Ozarda, “Reference intervals: current status, recent developments and future considerations,” *Biochemia Medica*, vol. 26, no. 1, pp. 5–11, 2016, doi: 10.11613/BM.2016.001.
- [6] Clinical and Laboratory Standards Institute, *Defining, Establishing, and Verifying Reference Intervals in the Clinical Laboratory; Approved Guideline—Third Edition*, CLSI document EP28-A3c. Wayne, PA, USA: CLSI, 2010.
- [7] C. J. McDonald, S. M. Huff, J. G. Suico, G. Hill, D. Leavelle, R. Aller, A. Forrey, K. Mercer, G. DeMoor, J. Hook, W. Williams, J. Case, and P. Maloney, “LOINC, a universal standard for identifying laboratory observations: A 5-year update,” *Clinical Chemistry*, vol. 49, no. 4, pp. 624–633, 2003, doi: 10.1373/49.4.624.
- [8] T. D. Giardina, J. Baldwin, D. T. Nystrom, D. F. Sittig, and H. Singh, “Patient perceptions of receiving test results via online portals: a mixed-methods study,” *Journal of the American Medical Informatics Association*, vol. 25, no. 4, pp. 440–446, 2018, doi: 10.1093/jamia/ocx140.
- [9] B. J. Zikmund-Fisher, A. M. Scherer, H. O. Witteman, J. B. Solomon, N. L. Exe, B. A. Tarini, and A. Fagerlin, “Graphics help patients distinguish between urgent and non-urgent

deviations in laboratory test results,” *Journal of the American Medical Informatics Association*, vol. 24, no. 3, pp. 520–528, 2017, doi: 10.1093/jamia/ocw169.

[10] P. Fraccaro, M. Vigo, P. Balatsoukas, S. N. van der Veer, L. Hassan, R. Williams, G. Wood, S. Sinha, I. Buchan, and N. Peek, “Presentation of laboratory test results in patient portals: influence of interface design on risk interpretation and visual search behaviour,” *BMC Medical Informatics and Decision Making*, vol. 18, Art. no. 11, 2018, doi: 10.1186/s12911-018-0589-7.

[11] B. D. Steitz, R. W. Turer, C.-T. Lin, S. MacDonald, L. Salmi, A. Wright, C. U. Lehmann, K. Langford, S. A. McDonald, T. J. Reese, P. Sternberg, Q. Chen, S. T. Rosenbloom, and C. M. DesRoches, “Perspectives of patients about immediate access to test results through an online patient portal,” *JAMA Network Open*, vol. 6, no. 3, Art. no. e233572, 2023, doi: 10.1001/jamanetworkopen.2023.3572.

[12] F. Pillemer, R. A. Price, S. Paone, G. D. Martich, S. Albert, L. Haidari, G. Updike, R. Rudin, D. Liu, and A. Mehrotra, “Direct release of test results to patients increases patient engagement and utilization of care,” *PLoS ONE*, vol. 11, no. 6, Art. no. e0154743, 2016, doi: 10.1371/journal.pone.0154743.

[13] C. Friedman, P. O. Alderson, J. H. M. Austin, J. J. Cimino, and S. B. Johnson, “A general natural-language text processor for clinical radiology,” *Journal of the American Medical Informatics Association*, vol. 1, no. 2, pp. 161–174, 1994, doi: 10.1136/jamia.1994.95236146.

[14] G. K. Savova, J. J. Masanz, P. V. Ogren, J. Zheng, S. Sohn, K. C. Kipper-Schuler, and C. G. Chute, “Mayo clinical Text Analysis and Knowledge Extraction System (cTAKES): architecture, component evaluation and applications,” *Journal of the American Medical Informatics Association*, vol. 17, no. 5, pp. 507–513, 2010, doi: 10.1136/jamia.2009.001560.

[15] Y. Wang, L. Wang, M. Rastegar-Mojarad, S. Moon, F. Shen, N. Afzal, S. Liu, Y. Zeng, S. Mehrabi, S. Sohn, and H. Liu, “Clinical information extraction applications: A literature review,” *Journal of Biomedical Informatics*, vol. 77, pp. 34–49, 2018, doi: 10.1016/j.jbi.2017.11.011.

[16] S. Fu, D. Chen, H. He, S. Liu, S. Moon, K. J. Peterson, F. Shen, L. Wang, Y. Wang, A. Wen, Y. Zhao, S. Sohn, and H. Liu, “Clinical concept extraction: A methodology review,” *Journal of Biomedical Informatics*, vol. 109, Art. no. 103526, 2020, doi: 10.1016/j.jbi.2020.103526.

- [17] J. Lee, W. Yoon, S. Kim, D. Kim, S. Kim, C. H. So, and J. Kang, “BioBERT: a pre-trained biomedical language representation model for biomedical text mining,” *Bioinformatics*, vol. 36, no. 4, pp. 1234–1240, 2020, doi: 10.1093/bioinformatics/btz682.
- [18] E. Alsentzer, J. Murphy, W. Boag, W.-H. Weng, D. Jindi, T. Naumann, and M. McDermott, “Publicly available clinical BERT embeddings,” in *Proceedings of the 2nd Clinical Natural Language Processing Workshop*, Minneapolis, MN, USA, 2019, pp. 72–78, doi: 10.18653/v1/W19-1909.
- [19] B. Ondov, K. Attal, and D. Demner-Fushman, “A survey of automated methods for biomedical text simplification,” *Journal of the American Medical Informatics Association*, vol. 29, no. 11, pp. 1976–1988, 2022, doi: 10.1093/jamia/ocac149.
- [20] A. Devaraj, W. Sheffield, B. C. Wallace, and J. J. Li, “Evaluating factuality in text simplification,” in *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, Dublin, Ireland, 2022, pp. 7331–7345, doi: 10.18653/v1/2022.acl-long.506.
- [21] A. Devaraj, I. J. Marshall, B. C. Wallace, and J. J. Li, “Paragraph-level simplification of medical texts,” in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2021, pp. 4972–4984, doi: 10.18653/v1/2021.naacl-main.395.
- [22] J. Trienes, J. Schlötterer, H.-U. Schildhaus, and C. Seifert, “Patient-friendly clinical notes: Towards a new text simplification dataset,” in *Proceedings of the Workshop on Text Simplification, Accessibility, and Readability (TSAR-2022)*, Abu Dhabi, UAE, 2022, pp. 19–27, doi: 10.18653/v1/2022.tsar-1.3.
- [23] K. Jeblick, B. Schachtner, J. Dextl, A. Mittermeier, A. T. Stüber, J. Topalis, T. Weber, P. Wesp, B. O. Sabel, J. Ricke, and M. Ingris, “ChatGPT makes medicine easy to swallow: An exploratory case study on simplified radiology reports,” *European Radiology*, vol. 34, no. 5, pp. 2817–2825, 2024, doi: 10.1007/s00330-023-10213-1.
- [24] K. S. Amin, M. A. Davis, R. Doshi, A. H. Haims, P. Khosla, and H. P. Forman, “Accuracy of ChatGPT, Google Bard, and Microsoft Bing for simplifying radiology reports,” *Radiology*, vol. 309, no. 2, Art. no. e232561, 2023, doi: 10.1148/radiol.232561.
- [25] J. Zaretsky, J. M. Kim, S. Baskharoun, Y. Zhao, J. Austrian, Y. Aphinyanaphongs, R. Gupta, S. B. Blecker, and J. Feldman, “Generative artificial intelligence to transform inpatient

discharge summaries to patient-friendly language and format,” *JAMA Network Open*, vol. 7, no. 3, Art. no. e240357, 2024, doi: 10.1001/jamanetworkopen.2024.0357.

[26] J. Cadamuro, F. Cabitza, Z. Debeljak, S. De Bruyne, G. Frans, S. Martin Perez, H. Ozdemir, A. Tolios, A. Carobene, and A. Padoan, “Potentials and pitfalls of ChatGPT and natural-language artificial intelligence models for the understanding of laboratory medicine test results. An assessment by the European Federation of Clinical Chemistry and Laboratory Medicine (EFLM) Working Group on Artificial Intelligence (WG-AI),” *Clinical Chemistry and Laboratory Medicine*, vol. 61, no. 7, pp. 1158–1166, 2023, doi: 10.1515/cclm-2023-0355.

[27] Z. He, B. Bhasuran, Q. Jin, S. Tian, K. Hanna, C. Shavor, L. Garcia Arguello, P. Murray, and Z. Lu, “Quality of answers of generative large language models versus peer users for interpreting laboratory test results for lay patients: Evaluation study,” *Journal of Medical Internet Research*, vol. 26, Art. no. e56655, 2024, doi: 10.2196/56655.

[28] A. Névéol, H. Dalianis, S. Velupillai, G. Savova, and P. Zweigenbaum, “Clinical Natural Language Processing in languages other than English: opportunities and challenges,” *Journal of Biomedical Semantics*, vol. 9, Art. no. 12, 2018, doi: 10.1186/s13326-018-0179-8.

[29] M. Kastrati and M. Biba, “Natural language processing for Albanian: a state-of-the-art survey,” *International Journal of Electrical and Computer Engineering*, vol. 12, no. 6, pp. 6432–6439, 2022, doi: 10.11591/ijece.v12i6.pp6432-6439.

[30] N. Kote, K. Kalliri, K. Kalliri, A. Haveriku, B. Muraku, and E. Kajo Meçe, “NER for Albanian language: A manually annotated corpus and machine learning models,” in *Advanced Information Networking and Applications (AINA 2025)*, Lecture Notes on Data Engineering and Communications Technologies, vol. 247. Cham: Springer, 2025, pp. 153–165, doi: 10.1007/978-3-031-87769-8_14.

[31] N. Tsourakis, R. Troqe, J. Gerlach, P. Bouillon, and H. Spechbach, “An Albanian text-to-speech system for the BabelDr medical speech translator,” *Studies in Health Technology and Informatics*, vol. 270, pp. 527–531, 2020, doi: 10.3233/SHTI200216.

[32] J. Maynez, S. Narayan, B. Bohnet, and R. McDonald, “On faithfulness and factuality in abstractive summarization,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 1906–1919, doi: 10.18653/v1/2020.acl-main.173.

[33] L. Huang, W. Yu, W. Ma, W. Zhong, Z. Feng, H. Wang, Q. Chen, W. Peng, X. Feng, B. Qin, and T. Liu, “A survey on hallucination in large language models: Principles, taxonomy,

challenges, and open questions,” *ACM Transactions on Information Systems*, vol. 43, no. 2, pp. 1–55, 2025, doi: 10.1145/3703155.

[34] K. Singhal, S. Azizi, T. Tu, S. S. Mahdavi, J. Wei, H. W. Chung, et al., “Large language models encode clinical knowledge,” *Nature*, vol. 620, no. 7972, pp. 172–180, 2023, doi: 10.1038/s41586-023-06291-2.

[35] A. J. Thirunavukarasu, D. S. J. Ting, K. Elangovan, L. Gutierrez, T. F. Tan, and D. S. W. Ting, “Large language models in medicine,” *Nature Medicine*, vol. 29, no. 8, pp. 1930–1940, 2023, doi: 10.1038/s41591-023-02448-8.

[36] L. Tang, Z. Sun, B. Idnay, J. G. Nestor, A. Soroush, P. A. Elias, Z. Xu, Y. Ding, G. Durrett, J. F. Rousseau, C. Weng, and Y. Peng, “Evaluating large language models on medical evidence summarization,” *npj Digital Medicine*, vol. 6, Art. no. 158, 2023, doi: 10.1038/s41746-023-00896-7.

[37] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.

[38] K. Shuster, S. Poff, M. Chen, D. Kiela, and J. Weston, “Retrieval augmentation reduces hallucination in conversation,” in *Findings of the Association for Computational Linguistics: EMNLP 2021*, 2021, pp. 3784–3803, doi: 10.18653/v1/2021.findings-emnlp.320.

[39] A. Parikh, X. Wang, S. Gehrmann, M. Faruqui, B. Dhingra, D. Yang, and D. Das, “ToTTo: A controlled table-to-text generation dataset,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 1173–1186, doi: 10.18653/v1/2020.emnlp-main.89.

[40] O. Dušek and Z. Kasner, “Evaluating semantic accuracy of data-to-text generation with natural language inference,” in *Proceedings of the 13th International Conference on Natural Language Generation*, 2020, pp. 131–137, doi: 10.18653/v1/2020.inlg-1.19.

[41] S. R. Bowman, G. Angeli, C. Potts, and C. D. Manning, “A large annotated corpus for learning natural language inference,” in *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, 2015, pp. 632–642, doi: 10.18653/v1/D15-1075.

[42] W. Kryscinski, B. McCann, C. Xiong, and R. Socher, “Evaluating the factual consistency of abstractive text summarization,” in *Proceedings of the 2020 Conference on Empirical*

Methods in Natural Language Processing (EMNLP), 2020, pp. 9332–9346, doi: 10.18653/v1/2020.emnlp-main.750.

[43] O. Honovich, R. Aharoni, J. Herzig, H. Taitelbaum, D. Kukliansy, V. Cohen, T. Scialom, I. Szpektor, A. Hassidim, and Y. Matias, “TRUE: Re-evaluating factual consistency evaluation,” in *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2022, pp. 3905–3920, doi: 10.18653/v1/2022.naacl-main.287.

[44] P. Manakul, A. Liusie, and M. J. F. Gales, “SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023, pp. 9004–9017, doi: 10.18653/v1/2023.emnlp-main.557.

[45] S. Min, K. Krishna, X. Lyu, M. Lewis, W.-t. Yih, P. W. Koh, M. Iyyer, L. Zettlemoyer, and H. Hajishirzi, “FActScore: Fine-grained atomic evaluation of factual precision in long form text generation,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023, pp. 12076–12100, doi: 10.18653/v1/2023.emnlp-main.741.

[46] J. Li, X. Cheng, W. X. Zhao, J.-Y. Nie, and J.-R. Wen, “HaluEval: A large-scale hallucination evaluation benchmark for large language models,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023, pp. 6449–6464, doi: 10.18653/v1/2023.emnlp-main.397.

[47] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36, 2023, pp. 46595–46623.

[48] Y. Liu, D. Iter, Y. Xu, S. Wang, R. Xu, and C. Zhu, “G-Eval: NLG evaluation using GPT-4 with better human alignment,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023, pp. 2511–2522, doi: 10.18653/v1/2023.emnlp-main.153.

[49] A. Panickssery, S. R. Bowman, and S. Feng, “LLM evaluators recognize and favor their own generations,” in *Advances in Neural Information Processing Systems*, vol. 37, 2024, pp. 68772–68802.

- [50] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*, 2019, pp. 4171–4186, doi: 10.18653/v1/N19-1423.
- [51] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, “Unsupervised cross-lingual representation learning at scale,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 8440–8451, doi: 10.18653/v1/2020.acl-main.747.
- [52] R. Smith, “An overview of the Tesseract OCR engine,” in *Proceedings of the 9th International Conference on Document Analysis and Recognition (ICDAR 2007)*, Curitiba, Brazil, 2007, pp. 629–633, doi: 10.1109/ICDAR.2007.4376991.
- [53] D. van Strien, K. Beelen, M. Coll Ardanuy, K. Hosseini, B. McGillivray, and G. Colavizza, “Assessing the impact of OCR quality on downstream NLP tasks,” in *Proceedings of the 12th International Conference on Agents and Artificial Intelligence (ICAART 2020), Volume 1*, 2020, pp. 484–496, doi: 10.5220/0009169004840496.
- [54] Regulation (EU) 2017/745 of the European Parliament and of the Council of 5 April 2017 on medical devices, *Official Journal of the European Union*, L 117, 5.5.2017, pp. 1–175. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2017/745/oj>, date accessed: 06.10.2026.
- [55] Medical Device Coordination Group, “MDCG 2019-11 Rev. 1: Guidance on qualification and classification of software in Regulation (EU) 2017/745 – MDR and Regulation (EU) 2017/746 – IVDR,” European Commission, June 2025. [Online]. Available: https://health.ec.europa.eu/document/download/b45335c5-1679-4c71-a91c-fc7a4d37f12b_en?filename=mdcg_2019_11_en.pdf, date accessed: 06.10.2026.
- [56] Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act), *Official Journal of the European Union*, L, 2024/1689, 12.7.2024. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>, date accessed: 06.10.2026.
- [57] Regulation (EU) 2026/1744 of the European Parliament and of the Council of 8 July 2026 amending Regulations (EU) 2024/1689, (EU) 2018/1139 and (EU) 2023/1230 as regards the simplification of the implementation of harmonised rules on artificial intelligence (Digital

Omnibus on AI), *Official Journal of the European Union*, L, 2026/1744, 24.7.2026. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2026/1744/oj>, date accessed: 06.10.2026.

[58] Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation), *Official Journal of the European Union*, L 119, 4.5.2016, pp. 1–88. [Online]. Available: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>, date accessed: 06.10.2026.

[59] Republika e Kosovës, *Ligji Nr. 06/L-082 për Mbrojtjen e të Dhënave Personale*, Gazeta Zyrtare e Republikës së Kosovës, Nr. 6, 25 shkurt 2019. [Online]. Available: <https://gzk.rks-gov.net/ActDocumentDetail.aspx?ActID=18616>, date accessed: 06.10.2026.

[60] J. A. Hanley and A. Lippman-Hand, “If nothing goes wrong, is everything all right? Interpreting zero numerators,” *JAMA*, vol. 249, no. 13, pp. 1743–1745, 1983, doi: 10.1001/jama.1983.03330370053031.

[61] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York, NY, USA: Chapman & Hall, 1993.

[62] E. B. Wilson, “Probable inference, the law of succession, and statistical inference,” *Journal of the American Statistical Association*, vol. 22, no. 158, pp. 209–212, 1927, doi: 10.1080/01621459.1927.10502953.

[63] S. Kapoor and A. Narayanan, “Leakage and the reproducibility crisis in machine-learning-based science,” *Patterns*, vol. 4, no. 9, Art. no. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[64] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960, doi: 10.1177/001316446002000104.

8 APPENDIXES

Shtojca A — Tabela e plotë terminologjike shqip me shpjegimet, kategoritë dhe sinonimet

Shtojca B — Paneli i plotë i analiteve me kodet LOINC dhe intervalet referente rezervë

Shtojca C — Katalogu i plotë i rregullave të verifikimit me shembuj

Shtojca D — Kërkesat e përdorura për modelin gjuhësor, me versionim

Shtojca E — Udhëzimet e anotimit për dokumentet reale

Shtojca F — Instrumenti i studimit me përdorues

Shtojca G — Skema SQL e bazës së të dhënave

Shtojca H — Konfigurimet e eksperimenteve dhe farat fillestare

Shtojca I — Shembuj dokumentesh nga korpusi sintetik

Shtojca A — Tabela e plotë terminologjike shqip

Tabela mban 82 terma. Shpjegimet janë përkufizime pune të autorit dhe nuk janë referuar te një burim i verifikueshëm. Pa referencë, tabela vetë është burim informacioni të paverifikuar; kjo është kufizim i shprehur te seksioni 6.6, jo detaj i fshehur këtu.

Tabela A.1. Termat, shpjegimet, kategoritë dhe sinonimet

Termi	Shpjegimi	Kategori a	Sinonimet
anemi	nivel i ulët i hemoglobinës në gjak	gjendje	anemia, anemik
eritropoezë	prodhimi i qelizave të kuqe të gjakut në palcën kockore	proces	eritropoeza
leukocitozë	numër i rritur i qelizave të bardha të gjakut	gjendje	leukocitoza
leukopeni	numër i ulët i qelizave të bardha të gjakut	gjendje	leukopenia
trombocitopeni	numër i ulët i pllakëzave të gjakut	gjendje	trombocitopenia
trombocitozë	numër i rritur i pllakëzave të gjakut	gjendje	trombocitoza
hiperglicemi	nivel i rritur i sheqerit në gjak	gjendje	hiperglicemia
hipoglicemi	nivel i ulët i sheqerit në gjak	gjendje	hipoglicemia
hiperkalemi	nivel i rritur i kaliumit në gjak	gjendje	hiperkalemia
hipokalemi	nivel i ulët i kaliumit në gjak	gjendje	hipokalemia
hipernatremit	nivel i rritur i natriumit në gjak	gjendje	hipernatremia
hiponatremi	nivel i ulët i natriumit në gjak	gjendje	hiponatremia
hiperkalcemi	nivel i rritur i kalciumit në gjak	gjendje	hiperkalcemia
hipokalcemi	nivel i ulët i kalciumit në gjak	gjendje	hipokalcemia
transaminaza	enzima që lidhen me funksionin e mëlçisë	enzima	transaminazat, ALT, AST
kolestazë	rrjedhje e penguar e biliarit nga mëlçia	gjendje	kolestaza
hiperbilirubinemi	nivel i rritur i bilirubinës në gjak	gjendje	hiperbilirubinemia
ikter	ngjyrim i verdhë i lëkurës dhe i syve	shenjë	ikteri, verdhëz

Termi	Shpjegimi	Kategori a	Sinonimet
dislipidemi	vlera të çrregulluara të yndyrave në gjak	gjendje	dislipidemia
hiperkolesterolemi	nivel i rritur i kolesterolit në gjak	gjendje	hiperkolesterolemia
hipertrigliceridemi	nivel i rritur i trigliceridëve në gjak	gjendje	hipertrigliceridemia
hipotiroidizëm	veprimtari e ulët e gjëndrës tiroide	gjendje	hipotiroidizmi, hipotiroidi
hipertiroidizëm	veprimtari e shtuar e gjëndrës tiroide	gjendje	hipertiroidizmi, hipertiroidi
azotemi	nivel i rritur i mbetjeve azotike në gjak	gjendje	azotemia
proteinuri	prani e proteinave në urinë	gjendje	proteinuria
inflamacion	përgjigje mbrojtëse e organizmit ndaj dëmtimit ose infeksionit	proces	inflamacioni, inflamator
sideropeni	rezerva të ulëta të hekurit në organizëm	gjendje	sideropenia
hemolizë	shkatërrim i parakohshëm i qelizave të kuqe	proces	hemoliza, hemolitik
hipoalbuminemi	nivel i ulët i albuminës në gjak	gjendje	hipoalbuminemia
hiperurikemi	nivel i rritur i acidit urik në gjak	gjendje	hiperurikemia
nefropati	sëmundje e veshkave	gjendje	nefropatia
hepatopati	sëmundje e mëlçisë	gjendje	hepatopatia
steatozë	grumbullim i yndyrës në mëlçi	gjendje	steatoza
glikemi	niveli i sheqerit në gjak	matje	glikemia
elektrolit	minerale në gjak që mbajnë ekuilibrin e ujit dhe punën e qelizave	matje	elektrolitet, elektrolitike
hemogram	analiza e plotë e qelizave të gjakut	analize	hemograma, analiza e plotë e gjakut
interval referent	kufijtë brenda të cilëve vlera konsiderohet e zakonshme	metodologji	vlera referente, intervale referent
analit	substancia e matur në analizë	metodologji	analiti, analitet
funksioni renal	mënyra si punojnë veshkat	matje	funksioni i veshkave, renal
funksioni hepatic	mënyra si punon mëlçia	matje	funksioni i mëlçisë, hepatic
metabolizëm	tërësia e proceseve kimike që mbajnë gjallë organizmin	proces	metabolizmi, metabolik
ferritinë	proteina që ruan hekurin në organizëm	matje	ferritina
hemoglobinë	proteina që bart oksigjenin në qelizat e kuqe	matje	hemoglobina
kreatininë	mbetje e punës së muskujve që largohet nga veshkat	matje	kreatinina
albuminë	proteina kryesore e gjakut e prodhuar nga mëlçia	matje	albumina
tiroide	gjëndra që rregullon shpejtësinë e metabolizmit	organ	tiroidja, tiroidea
neutropeni	numër i ulët i një lloji të qelizave të bardha	gjendje	neutropenia
neutrofili	numër i rritur i një lloji të qelizave të bardha	gjendje	
limfocitozë	numër i rritur i limfociteve në gjak	gjendje	limfocitoza
limfopeni	numër i ulët i limfociteve në gjak	gjendje	limfopenia
policitemi	numër i rritur i qelizave të kuqe në gjak	gjendje	policitemia
hemostazë	procesi i ndalimit të gjakderdhjes	proces	hemostaza
koagulum	mpiksja e gjakut	proces	koagulimi, koagulues
filtrim glomerular	shpejtësia me të cilën veshkat pastrojnë gjakun	matje	filtrimi glomerular, GFR
klirens	masa e pastrimit të një substance nga gjaku	matje	klirensi
hematuri	prani e gjakut në urinë	gjendje	hematuria

Termi	Shpjegimi	Kategori a	Sinonimet
glikozuri	prani e sheqerit në urinë	gjendje	glikozuria
ketonuri	prani e trupave ketonikë në urinë	gjendje	ketonuria
urobilinogjen	produkt i zbërthimit të bilirubinës	matje	urobilinogjeni
lipoproteinë	grimcë që bart yndyrnat në gjak	matje	lipoproteina, lipoproteinat
ateroskleroze	ngurtësim dhe ngushtim i enëve të gjakut	gjendje	ateroskleroza
sindrom metabolik	bashkësi çrregullimesh të metabolizmit	gjendje	sindromi metabolik
rezistencë ndaj insulinës	përgjigje e dobësuar e qelizave ndaj insulinës	gjendje	rezistenca ndaj insulinës
insulinë	hormoni që ul nivelin e sheqerit në gjak	matje	insulina
kortizol	hormon i gjëndrave mbiveshkore	matje	kortizoli
paratiroide	gjëndra që rregullojnë kalciumin	organ	paratiroidet
osteoporozë	humbje e dendësisë së kockave	gjendje	osteoporoza
hiperfosfatemi	nivel i rritur i fosforit në gjak	gjendje	hiperfosfatemia
hipofosfatemi	nivel i ulët i fosforit në gjak	gjendje	hipofosfatemia
hipomagnezemi	nivel i ulët i magnezit në gjak	gjendje	hipomagnezemia
hipokloremi	nivel i ulët i klorit në gjak	gjendje	hipokloremia
hiperkloremi	nivel i rritur i klorit në gjak	gjendje	hiperkloremia
serum	pjesa e lëngshme e gjakut pa faktorët e mpiksjes	material	serumi
plazmë	pjesa e lëngshme e gjakut me faktorët e mpiksjes	material	plazma
gjëndër	organ që prodhon dhe lëshon substanca në trup	organ	gjëndra, gjëndrat
enzimë	proteinë që përshpejton reaksionet kimike në trup	matje	enzima, enzimat
antitrop	proteinë mbrojtëse e prodhuar nga sistemi imunitar	matje	antitropa, antitrupat
antigjen	substancë që nxit përgjigje të sistemit imunitar	matje	antigjeni
biomarkues	tregues i matshëm i një gjendjeje në trup	metodologji	biomarkuesi
depistim	kontroll i rregullt për zbulim të hershëm	metodologji	depistimi
gjakderdhje	humbje gjaku nga enët e gjakut	gjendje	gjakderdhja
imunitet	aftësia e trupit për t'u mbrojtur nga infeksionet	proces	imuniteti, imunitar

Shtojca B — Paneli i plotë i analiteve

Tabelat dalin nga `resources/` me `scripts/build_tables.py`, po ata skedarë që lexon sistemi. Intervallet janë ato të tabelës së brendshme, që përdoren vetëm kur dokumenti nuk e shtyp vetë intervalin.

Tabela B.1. Paneli i analiteve dhe hartëzimi LOINC

Intervallet janë ato të tabelës së brendshme, e cila përdoret vetëm kur dokumenti nuk e shtyp vetë intervalin. Aty ku kufijtë ndryshojnë sipas gjinisë, jepen të dy.

Kodi LOINC	Analiti	Njësia	Paneli	Interval (M)	Interval (F)
718-7	Hemoglobinë në gjak	g/dL	hematologji	13.5 – 17.5	12.0 – 16.0
4544-3	Hematokrit	%	hematologji	40.0 – 52.0	36.0 – 48.0
789-8	Eritrocite	10 ¹² /L	hematologji	4.50 – 5.90	4.00 – 5.20
6690-2	Leukocite	10 ⁹ /L	hematologji	4.0 – 10.0	—
777-3	Trombocite	10 ⁹ /L	hematologji	150 – 400	—
787-2	Volumi mesatar eritrocitar	fL	hematologji	80.0 – 100.0	—
785-6	Hemoglobina mesatare eritrocitare	pg	hematologji	27.0 – 33.0	—
786-4	Përqendrimi mesatar i hemoglobinës	g/dL	hematologji	32.0 – 36.0	—
2345-7	Glukozë në serum	mg/dL	biokimi	70 – 99	—
4548-4	Hemoglobinë e glikuar	%	biokimi	4.0 – 5.6	—
2160-0	Kreatininë në serum	mg/dL	veshkat	0.70 – 1.30	0.60 – 1.10
3094-0	Ure në serum	mg/dL	veshkat	15 – 45	—
3084-1	Acid urik në serum	mg/dL	veshkat	3.4 – 7.0	2.4 – 6.0
2951-2	Natrium në serum	mmol/L	elektrolite	135 – 145	—
2823-3	Kalium në serum	mmol/L	elektrolite	3.5 – 5.1	—
2075-0	Klor në serum	mmol/L	elektrolite	98 – 107	—
17861-6	Kalcium në serum	mg/dL	elektrolite	8.6 – 10.2	—
2777-1	Fosfor në serum	mg/dL	elektrolite	2.5 – 4.5	—
2601-3	Magnez në serum	mg/dL	elektrolite	1.7 – 2.4	—
1742-6	Alanin aminotransferazë	U/L	melcia	10 – 40	7 – 35
1920-8	Aspartat aminotransferazë	U/L	melcia	10 – 40	—
6768-6	Fosfatazë alkaline	U/L	melcia	40 – 130	—
2324-2	Gama-glutamyl transferazë	U/L	melcia	10 – 71	6 – 42
1975-2	Bilirubinë totale	mg/dL	melcia	0.20 – 1.20	—
1751-7	Albuminë në serum	g/dL	melcia	3.5 – 5.2	—
2885-2	Proteina totale	g/dL	melcia	6.4 – 8.3	—
2093-3	Kolesterol total	mg/dL	lipide	120 – 200	—
2085-9	Kolesterol HDL	mg/dL	lipide	40 – 70	50 – 85
13457-7	Kolesterol LDL	mg/dL	lipide	50 – 130	—
2571-8	Trigliceride	mg/dL	lipide	50 – 150	—
3016-3	Hormoni stimulues i tiroides	mIU/L	tiroide	0.40 – 4.00	—
3024-7	Tiroksinë e lirë	ng/dL	tiroide	0.80 – 1.80	—
3051-0	Triiodotironinë e lirë	pg/mL	tiroide	2.3 – 4.2	—
2276-4	Ferritinë në serum	ng/mL	hekuri	30 – 400	15 – 150
2498-4	Hekur në serum	ug/dL	hekuri	65 – 175	50 – 170
1988-5	Proteina C-reaktive	mg/L	inflamacion	0.0 – 5.0	—
2132-9	Vitaminë B12	pg/mL	vitamina	200 – 900	—
1989-3	Vitaminë D 25-OH	ng/mL	vitamina	30.0 – 100.0	—

Tabela përmban 38 analite me interval referent.

Krahas tyre, sistemi njeh me emër edhe 8 analite për të cilat tabela e brendshme nuk përmban interval. Këto nuk janë mangësi e tabelës por rasti që rregullon politika SP5: vlera matet, emri njihet, dhe interpretimi refuzohet.

Kodi LOINC	Analiti	Njësia
13965-9	Homocisteinë në serum	umol/L
33959-8	Prokalcitoninë	ng/mL
3040-3	Lipazë në serum	U/L
1798-8	Amilazë në serum	U/L
10839-9	Troponinë I	ng/mL

Kodi LOINC	Analiti	Njësia
2857-1	Antigjen specifik i prostatës	ng/mL
1834-1	Alfa-fetoproteinë	ng/mL
2532-0	Laktat dehidrogjenazë	U/L

Tabela B.2. Faktorët e konvertimit të njësive

Faktori shumëzon vlerën e shtypur në njësinë e parë për ta kthyer në njësinë kanonike. Konvertimi varet nga analiti kudo ku në të hyn masa molare, prandaj shumica e rreshtave janë specifike për një kod LOINC.

Nga	Në	Faktori	Analiti
g/L	g/dL	0.1	çdo analit
mmol/L	mg/dL	18.0182	2345-7
umol/L	mg/dL	0.0113122	2160-0
mmol/L	mg/dL	6.006	3094-0
umol/L	mg/dL	0.0584795	1975-2
mmol/L	mg/dL	38.67	2093-3
mmol/L	mg/dL	38.67	2085-9
mmol/L	mg/dL	38.67	13457-7
mmol/L	mg/dL	88.57	2571-8

Tabela B.3. Rregullat e kombinimit ndërmjet analiteve

Një rregull ndizet kur të gjitha kushtet plotësohen njëkohësisht. Vlera kritike numërohet sipas drejtimit të saj; vlera pa interval referent nuk merr pjesë (SP5). Rregulli nuk emërton gjendje: dalja thotë vetëm se kombinimi kërkon vlerësim nga profesionisti shëndetësor.

ID	Kushtet
P01	Hemoglobinë në gjak ↓ + Ferritinë në serum ↓
P02	Hemoglobinë në gjak ↓ + Volumi mesatar eritrocitar ↓
P03	Hemoglobinë në gjak ↓ + Vitaminë B12 ↓
P04	Glukozë në serum ↑ + Hemoglobinë e glikuar ↑
P05	Kreatininë në serum ↑ + Ure në serum ↑
P06	Alanin aminotransferazë ↑ + Aspartat aminotransferazë ↑
P07	Fosfatazë alkaline ↑ + Gama-glutamil transferazë ↑
P08	Hormoni stimulues i tiroides ↑ + Tirosinë e lirë ↓
P09	Hormoni stimulues i tiroides ↓ + Tirosinë e lirë ↑
P10	Leukocite ↑ + Proteina C-reaktive ↑
P11	Kolesterol LDL ↑ + Kolesterol HDL ↓

Kombinimet u zgjedhën si të njohura gjerësisht dhe duhen konfirmuar nga mentori ose nga një mjek, bashkë me burimin e secilit, përpara dorëzimit.

Shtojca C — Katalogu i plotë i rregullave të verifikimit

Tabela C.1. Katalogu i rregullave të verifikimit

Versioni i katalogut: r1.4. Ai regjistrohet në çdo rezultat verifikimi, prandaj rezultatet e vjetra mbeten të lexueshme edhe pasi katalogu ndryshon.

Rregulli	Dega	Lloji i shkeljes	Përshkrimi	Fushëveprimi
R1	A	ungrounded_number	Çdo numër në tekst duhet të gjendet ndër numrat e mbështetur të kontekstit.	fjalìa
R2	A	ungrounded_analyte	Çdo analit i përmendur duhet të jetë ndër analitet e matura.	fjalìa
R3	A	direction_mismatch	Drejtimi i pohuar duhet të përputhet me statusin e klasifikuar.	fjalìa
R4	A	missing_critical	Çdo gjetje kritike duhet të shfaqet në dalje.	tërë dalja
R5	B	polarity_flip	Polariteti i pohimit të mjekut nuk guxon të përmbysset.	fjalìa
R6	B	hedge_removed	Pasiguria e shprehur nga mjeku nuk guxon të hiqet.	fjalìa
R7	B	fabricated_finding	Asnjë gjetje që mungon në kontekst nuk guxon të shtohet.	fjalìa
R8	B	omitted_recommendation	Çdo rekomandim i mjekut duhet të ruhet në dalje.	tërë dalja
R9	B	ungrounded_term_explanation	Asnjë term jashtë tabelës terminologjike nuk guxon të shpjegohet.	fjalìa
SP1-3	B	prohibited_claim	Asnjë pohim diagnostik, trajtimi apo prognoze.	fjalìa

Fushëveprimi ndan rregullat që vendosen nga një fjali e vetme nga ato që kërkojnë shikim mbi tërë daljen. Vetëm të parat mund të përbëjnë detyrë klasifikimi në nivel fjalie, prandaj kjo kolonë përcakton edhe se cilat shkelje mund të mësohen nga klasifikuesi i Fazës 7 dhe cilat jo.

Tabela C.2. Një shembull i vërtetë për çdo rregull që korruptuesit e prodhojnë, me provën që jep rregulli

Shembujt janë marrë nga korpusi i korruptuar (fara 42): fjalìa që ndryshoi krahasuar me shabllonin e pastër, dhe prova e shkelësit të rregullit mbi të. R4 (vlëra kritike që mungon) dhe R9 (shpjegimi i një termi të pashpjeguar) nuk kanë korruptues; R9 u mat vetëm mbi grupin B, ku kapi vetëm 1 nga 5 fjalitë (seksioni 5.7).

Rregulli	Lloji	Fjalìa me defekt	Prova e rregullit
R1	ungrounded_number	Për Ferritinë në serum vlëra e matur është 47 ng/mL, brenda intervalit referent (17 - 151).	numri 17 nuk gjendet ndër vlërat e nxjerra
R2	ungrounded_analyte	Për Fosfatazë alkaline vlëra e matur është 60 mg/dL, brenda intervalit referent (50 - 85).	analiti 6768-6 nuk është matur në këtë dokument
R3	direction_mismatch	Për Hematokrit vlëra e matur është 55.4 %, nën intervalin referent (36 - 48).	4544-3: pohohet decreased, por statusi i matur është high

Rregulli	Lloji	Fjalja me defekt	Prova e rregullit
	ch		
R5	polarity_flip	Mjeku ka shënuar: Bilirubina totale del mbi intervalin referent.	burimi thotë negated për “Bilirubina totale nuk del mbi intervalin referent”
R6	hedge_removed	Mjeku ka shënuar: Fosfori mbi intervalin referent, por kërkon rikontroll.	burimi e shpreh me rezervë: “Fosfori duket mbi intervalin referent, por kërkon rikontroll”
R7	fabricated_finding	Vërehet gjithashtu aterosklerozë.	termi “aterosklerozë” nuk shfaqet në raportin burimor
R8	omitted_recommendation	(një fjali e fshirë)	rekomandimi “Rekomandohet përsëritja e analizave pas një muaji” mungon në dalje
SP1-3	prohibited_claim	Duhet të filloni trajtim për hematokritin e lartë.	SP2: shprehja “duhet të filloni” — Asnjë këshillë trajtimi apo medikamenti nuk lëshohet kurrë.

Shtojca D — Kërkesat për modelin gjuhësor

Të gjitha kërkesat dalin nga kodi që i dërgon, jo nga një kopje e shkruar me dorë. Modeli merr vetëm GroundingContext (§4.2.1): asnjë kërkesë nuk ka parametër për dokumentin (një test e kontrollon). Përrjashtim i vetëm është kushti A i ablacionit (E6), që sheh tekstin e dokumentit me qëllim, si bazë krahasuese.

Tabela D.1. Parametrat e ekzekutimit

Parametri	Vlera
Ofruesi	mistral
Modeli	ministral-14b-2512
Temperatura	0.0
Arsyetimi (thinking)	low (dërgohet vetëm te Gemini)
Kufiri i daljes	4096 shenja

Versionet e kërkesave: gjeneruesi p1, kushti A u1, gjykatësi j1. Çdo përgjigje e modelit ruhet në evaluation/cache/llm/ me kërkesën e plotë, prandaj çdo numër i Kapitullit 5 rikrijohet pa thirrje të reja.

D.2. Udhëzimet e gjeneruesit (kushtet B, C dhe D)

Fjalë për fjalë, nga generation/prompt.py:

Ti shkruan një shpjegim në gjuhën shqipe për një pacient, nga rezultatet e tij laboratorike dhe nga pohimet e mjekut. Ti NUK je mjek dhe nuk ke asnjë njohuri mjekësore që nuk jepet më poshtë. Detyra jote është vetëm formulimi: e vërteta është ajo që të jepet te "KONTEKSTI", dhe asgjë tjetër.

Rregulla që nuk shkelen kurrë:

1. Përdor vetëm numrat që shfaqen te konteksti (vlera e matur dhe dy kufijtë e intervalit). Shkruaji me pikë dhjetore, ashtu si janë dhënë. Mos

shkruaj asnjë numër tjetër: as numërim, as përqindje, as data, as "dy" ose "tre" me shifra.

2. Përmend vetëm analitet e listuara. Përdore emrin ashtu siç jepet. Mos përmend asnjë analit, sëmundje, gjendje apo term tjetër.

3. Pozicionin e vlerës ndaj intervalit përshkruaje vetëm me këto shprehje: "brenda intervalit referent", "nën intervalin referent", "mbi intervalin referent", "dukshëm nën intervalin referent", "dukshëm mbi intervalin referent". Mos përdor "i lartë", "e ulët", "normale" apo sinonime.

4. Mos jep diagnozë, mos këshillo trajtim apo ilaç, mos bëj parashikim për të ardhmen. Mos thuaj çfarë do të thotë një vlerë për shëndetin e pacientit.

5. Pohimet e mjekut kopjoji FJALË PËR FJALË, pa i ndryshuar, shkurtuar apo riformuluar, në formën e dhënë (që nis me "Mjeku ka shënuar:"). Mohimi, rezerva ("mundësisht", "nuk përjashtohet") dhe rekomandimi duhet të mbeten saktësisht siç janë.

6. Tekstet e shënuara "KOPJOJE" i shkruan fjalë për fjalë.

7. Shpjegimin e një termi mjekësor merre vetëm nga shpjegimi i dhënë; mund ta thuash me fjalë më të thjeshta, pa shtuar asgjë. Termet e shënuar "PA SHPJEGIM" mos i shpjego.

8. Shkruaj në gjuhë të thjeshtë, me fjali të shkurtra, pa terma teknikë të panevojshëm. Mos përdor lista me shenja, tituj apo format Markdown: vetëm paragrafë të thjeshtë.

Struktura: njoftimi për vlera kritike (nëse jepet) del i pari; pastaj çdo vlerë laboratorike; pastaj kombinimet (nëse ka); pastaj termat; pastaj pohimet e mjekut; në fund shënimi përmbyllës fjalë për fjalë. Kthe vetëm tekstin e shpjegimit.

Vendim dizajni që duhet deklaruar. Rregulli 3 e drejton modelin të shprehjet e pozicionit që verifikuesi i njeh («mbi intervalin referent», «nën intervalin referent»). Rregulli R3 e njeh drejtimin vetëm në ato forma, dhe një model që shkruan «i lartë» do ta kalonte R3 pa u parë. Pra kushtet B–D maten me një kërkesë që i përshtatet kontratës së verifikuesit; një kërkesë pa këtë kufizim do të prodhonte më shumë gabime drejtimi të padukshme për rregullat, jo më pak.

D.3. Një kërkesë e vërtetë për një dokument të korpusit

Pjesa që ndryshon nga dokumenti në dokument (konteksti). Dokumenti është ndërtuar nga fara appendix-d; emrat e analiteve, vlerat dhe pohimet janë ato të kontekstit.

KONTEKSTI

Njoftim për vlera kritike (KOPJOJE si fjalinë e parë të shpjegimit):
Kjo analizë përmban vlera dukshëm jashtë intervalit referent. Kontaktoni menjëherë mjekun tuaj.

Vlerat laboratorike:

- Hemoglobinë në gjak: vlera e matur 16.2 g/dL; pozicioni: brenda intervalit referent; intervali referent 13.5 - 17.5
- Hematokrit: vlera e matur 63.9 %; pozicioni: dukshëm mbi intervalin referent; intervali referent 40 - 52
- Eritrocite: vlera e matur $5.1 \cdot 10^{12}/L$; pozicioni: brenda intervalit referent; intervali referent 4.5 - 5.9
- Volumi mesatar eritrocitar: vlera e matur 91 fL; pozicioni: brenda

intervalit referent; intervali referent 80 - 100

- Hemoglobina mesatare eritrocitare: vlera e matur 29.4 pg; pozicioni: brenda intervalit referent; intervali referent 27 - 33
- Përqendrimi mesatar i hemoglobinës: vlera e matur 35.4 g/dL; pozicioni: brenda intervalit referent; intervali referent 32 - 36
- Natrium në serum: vlera e matur 140 mmol/L; pozicioni: brenda intervalit referent; intervali referent 135 - 145
- Kalium në serum: vlera e matur 6.1 mmol/L; pozicioni: mbi intervalin referent; intervali referent 3.5 - 5.1
- Klor në serum: vlera e matur 92 mmol/L; pozicioni: nën intervalin referent; intervali referent 98 - 107
- Kalcium në serum: vlera e matur 11.4 mg/dL; pozicioni: mbi intervalin referent; intervali referent 8.6 - 10.2
- Fosfor në serum: vlera e matur 3.7 mg/dL; pozicioni: brenda intervalit referent; intervali referent 2.5 - 4.5
- Magnez në serum: vlera e matur 2.2 mg/dL; pozicioni: brenda intervalit referent; intervali referent 1.7 - 2.4
- Aspartat aminotransferazë: vlera e matur 49 U/L; pozicioni: mbi intervalin referent; intervali referent 10 - 40
- Gama-glutamil transferazë: vlera e matur 3 U/L; pozicioni: nën intervalin referent; intervali referent 10 - 71
- Bilirubinë totale: vlera e matur 0.65 mg/dL; pozicioni: brenda intervalit referent; intervali referent 0.2 - 1.2
- Albuminë në serum: vlera e matur 4.4 g/dL; pozicioni: brenda intervalit referent; intervali referent 3.4 - 5.3
- Proteina totale: vlera e matur 6.9 g/dL; pozicioni: brenda intervalit referent; intervali referent 6.4 - 8.3
- Kolesterol total: vlera e matur 178 mg/dL; pozicioni: brenda intervalit referent; intervali referent 121 - 199
- Kolesterol HDL: vlera e matur 58 mg/dL; pozicioni: brenda intervalit referent; intervali referent 40 - 70
- Kolesterol LDL: vlera e matur 132 mg/dL; pozicioni: mbi intervalin referent; intervali referent 50 - 130
- Trigliceride: vlera e matur 25 mg/dL; pozicioni: nën intervalin referent; intervali referent 50 - 150
- Proteina C-reaktive: vlera e matur 7 mg/L; pozicioni: mbi intervalin referent; intervali referent 0 - 5

Terma nga raporti i mjekut:

- interval referent: shpjegimi i lejuar: kufijtë brenda të cilëve vlera konsiderohet e zakonshme
- anemi: shpjegimi i lejuar: nivel i ulët i hemoglobinës në gjak
- funksioni renal: shpjegimi i lejuar: mënyra si punojnë veshkat
- eozinofili: PA SHPJEGIM. Thuaj vetëm: Raporti përmend termin "eozinofili". Ky term nuk gjendet në fjalorin e sistemit, prandaj nuk shpjegohet.

Pohimet e mjekut (KOPJOJE çdo fjali fjalë për fjalë, njëra pas tjetrës):

Mjeku ka shënuar: Gama GT del nën intervalin referent.

Mjeku ka shënuar: Klori është mbi intervalin referent.

Mjeku ka shënuar: Hematokriti duket mbi intervalin referent, por kërkon rikontroll.

Mjeku ka shënuar: Nuk ka shenja të anemisë.

Mjeku ka shënuar: Funksioni renal është vlerësuar në tërësi.

Mjeku ka shënuar: Vërehet eozinofili e lehtë.

Mjeku ka shënuar: Rekomandohet vlerësim klinik i mëtejshëm.

Shënimi përmbyllës (KOPJOJE fjalë për fjalë në fund):

Ky shpjegim është automatik dhe nuk zëvendëson vlerësimin e profesionistit shëndetësor. Për çdo vendim mjekësor konsultohuni me mjekun tuaj.

Shkruaje shpjegimin.

D.4. Blloku i rigjenerimit

Kur përpjekja e parë refuzohet, e dyta merr shkeljet e saj (fjalja e daljes dhe arsyeja e rregullit, asgjë nga dokumenti). Shembull i vërtetë: shablloni me një numër të shpikur.

Shpjegimi i mëparshëm u refuzua nga verifikimi. Rishkruaje të gjithë shpjegimin pa këto gabime:

- Fjalja: «Vlera e matur është 987654.» – Çdo numër në tekst duhet të gjendet ndër numrat e mbështetur të kontekstit. (numri 987654 nuk gjendet ndër vlerat e nxjerra)

D.5. Kërkesa naive e kushtit A (E6)

Pa udhëzime sigurie, pa strukturë dhe pa kontekst të bazuar; modeli merr tekstin e dokumentit.

Ti je një asistent që u shpjegon pacientëve rezultatet e analizave dhe raportet mjekësore në gjuhë të thjeshtë shqipe.

Ky është dokumenti mjekësor i pacientit:

[teksti i dokumentit]

Shpjegoja pacientit çfarë thotë ky dokument, në gjuhë të thjeshtë.

D.6. Gjykatësi i E12

Gjykatësi merr po atë kontekst dhe po atë tekst si rregullat, dhe përkufizimet e rregullave nga katalogu (jo kodin e tyre):

Ti je verifikues i shpjegimeve mjekësore në gjuhën shqipe. Merr një KONTEKST (e vërteta: vlerat laboratorike dhe pohimet e mjekut) dhe një SHPJEGIM për pacientin. Vendors nëse shpjegimi e shkel kontekstin. Shpjegimi ka më së shumti NJË shkelje.

Llojet e shkeljeve:

- `ungrounded_number`: Çdo numër në tekst duhet të gjendet ndër numrat e mbështetur të kontekstit.
- `ungrounded_analyte`: Çdo analit i përmendur duhet të jetë ndër analitet e matura.
- `direction_mismatch`: Drejtimi i pohuar duhet të përputhet me statusin e klasifikuar.
- `missing_critical`: Çdo gjetje kritike duhet të shfaqet në dalje.
- `polarity_flip`: Polariteti i pohimit të mjekut nuk guxon të përmbysset.
- `hedge_removed`: Pasiguria e shprehur nga mjeku nuk guxon të hiqet.
- `fabricated_finding`: Asnjë gjetje që mungon në kontekst nuk guxon të shtohet.
- `omitted_recommendation`: Çdo rekomandim i mjekut duhet të ruhet në dalje.
- `ungrounded_term_explanation`: Asnjë term jashtë tabelës terminologjike nuk guxon të shpjegohet.
- `prohibited_claim`: Asnjë pohim diagnostik, trajtimi apo prognoze.

Kthe vetëm një rresht JSON të formës `{"label": "..."}` , ku label është ose

një nga (ungrounded_number, ungrounded_analyte, direction_mismatch, missing_critical, polarity_flip, hedge_removed, fabricated_finding, omitted_recommendation, ungrounded_term_explanation, prohibited_claim), ose "clean" nëse shpjegimi nuk e shkel kontekstin. Mos shpjego asgjë.

Shtojca E — Udhëzimet e anotimit për dokumentet reale

Nuk aplikohet. Nuk u përdorën dokumente reale: miratimi etik nuk është marrë. Eksperimenti E13 (vlefshmëria e jashtme) mbetet i pamatur, dhe kjo deklarohet si kufizimi kryesor të seksioni 6.6. Grupet e shkruara C dhe B (evaluation/handwritten/) nuk janë dokumente reale dhe nuk e zëvendësojnë E13.

Shtojca F — Instrumenti i studimit me përdorues

Nuk aplikohet. Studimi me përdorues (PK7, E14) nuk u krye, kështu që nuk ka instrument për t'u paraqitur dhe nuk raportohen rezultate kuptueshmërie. Seksioni 5.9 e thotë këtë shprehimisht.

Shtojca G — Skema SQL e bazës së të dhënave

Skema PostgreSQL e ndërtuar nga modelet (persistence/tables.py): 21 tabela. Migrimet Alembic (backend/alembic/versions/) e prodhojnë të njëjtën skemë; një test krahason rezultatin e tyre me modelet. Terminologjia dhe intervalet referente nuk janë në bazë (resources/ është burimi i vetëm).

```
CREATE TABLE audit_events (  
    id SERIAL NOT NULL,  
    document_id UUID,  
    user_id UUID,  
    event_type VARCHAR(60) NOT NULL,  
    payload JSON NOT NULL,  
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,  
    PRIMARY KEY (id)  
);  
  
CREATE INDEX ix_audit_events_document_created ON audit_events (document_id,  
created_at);  
  
CREATE TABLE login_failures (  
    id SERIAL NOT NULL,  
    email_key VARCHAR(64) NOT NULL,  
    ip_key VARCHAR(64) NOT NULL,  
    at TIMESTAMP WITH TIME ZONE NOT NULL,  
    PRIMARY KEY (id)  
);  
  
CREATE INDEX ix_login_failures_email_at ON login_failures (email_key, at);  
CREATE INDEX ix_login_failures_ip_at ON login_failures (ip_key, at);  
CREATE TABLE registration_attempts (  
    id SERIAL NOT NULL,  
    email_key VARCHAR(64) NOT NULL,  
    ip_key VARCHAR(64) NOT NULL,  
    at TIMESTAMP WITH TIME ZONE NOT NULL,  
    PRIMARY KEY (id)  
);
```

```

        id SERIAL NOT NULL,
        email_key VARCHAR(64) NOT NULL,
        ip_key VARCHAR(64) NOT NULL,
        at TIMESTAMP WITH TIME ZONE NOT NULL,
        PRIMARY KEY (id)
    );

CREATE INDEX ix_registration_attempts_email_at ON registration_attempts
(email_key, at);

CREATE INDEX ix_registration_attempts_ip_at ON registration_attempts
(ip_key, at);

CREATE TABLE users (
    id UUID NOT NULL,
    email VARCHAR(320) NOT NULL,
    password_hash VARCHAR(255) NOT NULL,
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,
    email_confirmed_at TIMESTAMP WITH TIME ZONE,
    totp_secret_encrypted BYTEA,
    totp_enabled_at TIMESTAMP WITH TIME ZONE,
    totp_last_step INTEGER,
    PRIMARY KEY (id)
);

CREATE UNIQUE INDEX ix_users_email ON users (email);

CREATE TABLE auth_sessions (
    id UUID NOT NULL,
    user_id UUID NOT NULL,
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,
    revoked_at TIMESTAMP WITH TIME ZONE,
    revoked_reason VARCHAR(30),
    PRIMARY KEY (id),
    FOREIGN KEY(user_id) REFERENCES users (id) ON DELETE CASCADE
);

CREATE INDEX ix_auth_sessions_user_id ON auth_sessions (user_id);

CREATE TABLE documents (
    id UUID NOT NULL,
    user_id UUID NOT NULL,
    filename_encrypted BYTEA NOT NULL,
    mime VARCHAR(100) NOT NULL,
    sha256 VARCHAR(64) NOT NULL,
    size_bytes INTEGER NOT NULL,
    storage_path VARCHAR(255) NOT NULL,
    uploaded_at TIMESTAMP WITH TIME ZONE NOT NULL,
    channel VARCHAR(20),
    state VARCHAR(30) NOT NULL,
    state_reason TEXT NOT NULL,
    model_consent BOOLEAN DEFAULT false NOT NULL,
    model_consent_at TIMESTAMP WITH TIME ZONE,
    model_use VARCHAR(30),
    model_gate_kinds VARCHAR(200),
    PRIMARY KEY (id),
    FOREIGN KEY(user_id) REFERENCES users (id) ON DELETE CASCADE
);

CREATE INDEX ix_documents_user_id ON documents (user_id);

```

```

CREATE TABLE email_confirmations (
    id UUID NOT NULL,
    user_id UUID NOT NULL,
    token_key VARCHAR(64) NOT NULL,
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,
    expires_at TIMESTAMP WITH TIME ZONE NOT NULL,
    used_at TIMESTAMP WITH TIME ZONE,
    PRIMARY KEY (id),
    FOREIGN KEY(user_id) REFERENCES users (id) ON DELETE CASCADE
);

CREATE UNIQUE INDEX ix_email_confirmations_token_key ON email_confirmations
(token_key);

CREATE INDEX ix_email_confirmations_user_id ON email_confirmations
(user_id);

CREATE TABLE mail_deliveries (
    id UUID NOT NULL,
    user_id UUID NOT NULL,
    kind VARCHAR(20) NOT NULL,
    token_id UUID NOT NULL,
    origin VARCHAR(10) NOT NULL,
    status VARCHAR(12) NOT NULL,
    attempts INTEGER NOT NULL,
    last_error VARCHAR(80),
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,
    last_attempt_at TIMESTAMP WITH TIME ZONE,
    sent_at TIMESTAMP WITH TIME ZONE,
    PRIMARY KEY (id),
    FOREIGN KEY(user_id) REFERENCES users (id) ON DELETE CASCADE
);

CREATE INDEX ix_mail_deliveries_status_created ON mail_deliveries (status,
created_at);

CREATE INDEX ix_mail_deliveries_user_id ON mail_deliveries (user_id);

CREATE TABLE password_resets (
    id UUID NOT NULL,
    user_id UUID NOT NULL,
    token_key VARCHAR(64) NOT NULL,
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,
    expires_at TIMESTAMP WITH TIME ZONE NOT NULL,
    used_at TIMESTAMP WITH TIME ZONE,
    PRIMARY KEY (id),
    FOREIGN KEY(user_id) REFERENCES users (id) ON DELETE CASCADE
);

CREATE UNIQUE INDEX ix_password_resets_token_key ON password_resets
(token_key);

CREATE INDEX ix_password_resets_user_id ON password_resets (user_id);

CREATE TABLE recovery_codes (
    id UUID NOT NULL,
    user_id UUID NOT NULL,
    code_key VARCHAR(64) NOT NULL,
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,
    used_at TIMESTAMP WITH TIME ZONE,

```

```

        PRIMARY KEY (id),
        FOREIGN KEY(user_id) REFERENCES users (id) ON DELETE CASCADE,
        UNIQUE (code_key)
    );

CREATE INDEX ix_recovery_codes_user_id ON recovery_codes (user_id);

CREATE TABLE cross_references (
    id UUID NOT NULL,
    document_id UUID NOT NULL,
    position INTEGER NOT NULL,
    analyte_code VARCHAR(20) NOT NULL,
    state VARCHAR(30) NOT NULL,
    assertion_id UUID,
    finding_id UUID,
    PRIMARY KEY (id),
    FOREIGN KEY(document_id) REFERENCES documents (id) ON DELETE CASCADE
);

CREATE INDEX ix_cross_references_document_id ON cross_references
(document_id);

CREATE TABLE document_glossary (
    id SERIAL NOT NULL,
    document_id UUID NOT NULL,
    position INTEGER NOT NULL,
    term VARCHAR(200) NOT NULL,
    explanation_sq TEXT NOT NULL,
    source_ref TEXT NOT NULL,
    category VARCHAR(100),
    synonyms JSON NOT NULL,
    PRIMARY KEY (id),
    FOREIGN KEY(document_id) REFERENCES documents (id) ON DELETE CASCADE
);

CREATE INDEX ix_document_glossary_document_id ON document_glossary
(document_id);

CREATE TABLE document_unexplained_terms (
    id SERIAL NOT NULL,
    document_id UUID NOT NULL,
    position INTEGER NOT NULL,
    term VARCHAR(200) NOT NULL,
    PRIMARY KEY (id),
    FOREIGN KEY(document_id) REFERENCES documents (id) ON DELETE CASCADE
);

CREATE INDEX ix_document_unexplained_terms_document_id ON
document_unexplained_terms (document_id);

CREATE TABLE explanations (
    id UUID NOT NULL,
    document_id UUID NOT NULL,
    attempt INTEGER NOT NULL,
    generator VARCHAR(200) NOT NULL,
    prompt_version VARCHAR(50),
    raw_output TEXT,
    final_output TEXT,
    is_fallback BOOLEAN NOT NULL,
    delivered BOOLEAN NOT NULL,

```

```

        error TEXT,
        created_at TIMESTAMP WITH TIME ZONE NOT NULL,
        PRIMARY KEY (id),
        FOREIGN KEY(document_id) REFERENCES documents (id) ON DELETE CASCADE
    );

CREATE INDEX ix_explanations_document_id ON explanations (document_id);

CREATE TABLE lab_findings (
    id UUID NOT NULL,
    document_id UUID NOT NULL,
    position INTEGER NOT NULL,
    analyte_code VARCHAR(20) NOT NULL,
    analyte_name_raw VARCHAR(200) NOT NULL,
    analyte_name_canonical VARCHAR(200) NOT NULL,
    value_raw VARCHAR(64) NOT NULL,
    value VARCHAR(64) NOT NULL,
    unit_raw VARCHAR(40),
    unit_canonical VARCHAR(40) NOT NULL,
    value_canonical VARCHAR(64) NOT NULL,
    ref_low VARCHAR(64),
    ref_high VARCHAR(64),
    ref_source VARCHAR(20) NOT NULL,
    status VARCHAR(20) NOT NULL,
    severity VARCHAR(64),
    page INTEGER NOT NULL,
    bbox JSON,
    measured_at DATE,
    flag_in_document VARCHAR(10),
    PRIMARY KEY (id),
    FOREIGN KEY(document_id) REFERENCES documents (id) ON DELETE CASCADE
);

CREATE INDEX ix_lab_findings_document_analyte ON lab_findings (document_id,
analyte_code);

CREATE TABLE pattern_observations (
    id SERIAL NOT NULL,
    document_id UUID NOT NULL,
    position INTEGER NOT NULL,
    pattern_id VARCHAR(20) NOT NULL,
    finding_ids JSON NOT NULL,
    source_ref TEXT NOT NULL,
    PRIMARY KEY (id),
    FOREIGN KEY(document_id) REFERENCES documents (id) ON DELETE CASCADE
);

CREATE INDEX ix_pattern_observations_document_id ON pattern_observations
(document_id);

CREATE TABLE processing_jobs (
    id UUID NOT NULL,
    document_id UUID NOT NULL,
    state VARCHAR(30) NOT NULL,
    attempt INTEGER,
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,
    started_at TIMESTAMP WITH TIME ZONE,
    finished_at TIMESTAMP WITH TIME ZONE,
    error TEXT,
    PRIMARY KEY (id),

```

```

        FOREIGN KEY(document_id) REFERENCES documents (id) ON DELETE CASCADE
    );

CREATE INDEX ix_processing_jobs_document_id ON processing_jobs
(document_id);

CREATE TABLE refresh_tokens (
    id UUID NOT NULL,
    session_id UUID NOT NULL,
    expires_at TIMESTAMP WITH TIME ZONE NOT NULL,
    used_at TIMESTAMP WITH TIME ZONE,
    PRIMARY KEY (id),
    FOREIGN KEY(session_id) REFERENCES auth_sessions (id) ON DELETE CASCADE
);

CREATE INDEX ix_refresh_tokens_session_id ON refresh_tokens (session_id);

CREATE TABLE report_assertions (
    id UUID NOT NULL,
    document_id UUID NOT NULL,
    position INTEGER NOT NULL,
    text_span TEXT NOT NULL,
    analyte_code VARCHAR(20),
    direction VARCHAR(20) NOT NULL,
    polarity VARCHAR(20) NOT NULL,
    certainty VARCHAR(20) NOT NULL,
    kind VARCHAR(20) NOT NULL,
    char_start INTEGER NOT NULL,
    char_end INTEGER NOT NULL,
    PRIMARY KEY (id),
    FOREIGN KEY(document_id) REFERENCES documents (id) ON DELETE CASCADE
);

CREATE INDEX ix_report_assertions_document_id ON report_assertions
(document_id);

CREATE TABLE verification_results (
    id UUID NOT NULL,
    explanation_id UUID NOT NULL,
    mode VARCHAR(30) NOT NULL,
    passed BOOLEAN NOT NULL,
    rules_version VARCHAR(20) NOT NULL,
    classifier_version VARCHAR(200),
    duration_ms INTEGER NOT NULL,
    created_at TIMESTAMP WITH TIME ZONE NOT NULL,
    PRIMARY KEY (id),
    UNIQUE (explanation_id),
    FOREIGN KEY(explanation_id) REFERENCES explanations (id) ON DELETE
CASCADE
);

CREATE TABLE violations (
    id UUID NOT NULL,
    verification_result_id UUID NOT NULL,
    position INTEGER NOT NULL,
    type VARCHAR(40) NOT NULL,
    detected_by VARCHAR(20) NOT NULL,
    sentence TEXT NOT NULL,
    evidence TEXT NOT NULL,
    confidence FLOAT,

```

```

PRIMARY KEY (id),
FOREIGN KEY(verification_result_id) REFERENCES verification_results
(id) ON DELETE CASCADE
);

```

```

CREATE INDEX ix_violations_verification_result_id ON violations
(verification_result_id);

```

Shtojca H — Konfigurimet e eksperimenteve dhe farat fillestare

Tabela H.1. Korpusi sintetik

Parametri	Vlera
Versioni i gjeneruesit	gen-1.0
Fara	42
Dokumente	500 (168 të skanuara, pjesa e synuar 35%)
Faqe	556
Gjetje laboratorike	9860
Pohime të mjekut	2749
Terma të pashpjeguar	236
Dokumente me vlerë kritike	36

Tabela H.2. Versionet dhe parametrat fiks të sistemit

Parametri	Vlera
Katalogu i rregullave	r1.3 te eksperimentet e ngrira (E4, E6–E11, grupet A, B, C); r1.4 te shërbimi (ADR 0021)
Kontrolli i besueshmërisë i OCR-së	i fikur te eksperimentet e ngrira; i ndezur te shërbimi (ADR 0020)
Politika e sigurisë	sp1.0
OCR	Tesseract, gjuha eng, - -psm 6, 200 dpi
Rimostrimi bootstrap	2000 rimostrime, fara 20260928, njësia është dokumenti

Tabela H.3. Rezultatet që ekzistojnë dhe prejardhja e tyre

Eksperimenti	Pipeline	Kodi (git)	Pema e punës	Korpusi
E1	grounding	37b5be45b3	e pastër	gen-1.0/s42/n500/37d8b080
E2	grounding+ocr	37b5be45b3	e pastër	gen-1.0/s42/n500/37d8b080
E3	grounding+ocr	37b5be45b3	e pastër	gen-1.0/s42/n500/37d8b080
E5	grounding+ocr	37b5be45b3	e pastër	gen-1.0/s42/n500/37d8b080
E7	e7[template]+ocr	37b5be45b3	e pastër	gen-1.0/s42/n500/37d8b080
E8	e8[template]+ocr	37b5be45b3	e pastër	gen-1.0/s42/n500/37d8b080
E9	e9[template]+ocr+xlm-roberta-base/sentence/sentence@0.85	37b5be45b3	e pastër	gen-1.0/s42/n500/37d8b080
E10	—	34fa710dad	e pastër	gen-1.0/corruption/s42/n200/721eec16

Eksperimenti	Pipeline	Kodi (git)	Pema e punës	Korpusi
E11/context	—	34fa710dad	e pastër	sha256:8739cea7964e688a
E11/sentence	—	34fa710dad	e pastër	sha256:520d9914587172c8
llm/E4	e8[mistral:ministral-14b-2512:p1]+ocr	4f5ea177c6	e pastër	gen-1.0/s42/n500/37d8b080
llm/E6	e6[mistral:ministral-14b-2512:u1]+ocr	4f5ea177c6	e pastër	gen-1.0/s42/n500/37d8b080
llm/E7	e7[mistral:ministral-14b-2512:p1]+ocr	4f5ea177c6	e pastër	gen-1.0/s42/n500/37d8b080
llm/E8	e8[mistral:ministral-14b-2512:p1]+ocr	4f5ea177c6	e pastër	gen-1.0/s42/n500/37d8b080
llm/E9	e9[mistral:ministral-14b-2512:p1]+ocr+xlm-roberta-base/sentence/sentence@0.85	4f5ea177c6	e pastër	gen-1.0/s42/n500/37d8b080
llm/E12	—	—	—	— (pa metadata)
llm/E12_haiku	—	—	—	— (pa metadata)

Tabela H.4. Klasifikuesi XLM-RoBERTa (trajnuar në Colab) dhe pragjet e zgjedhura mbi validimin

Hyrja	Modeli	Epoka	Shkalla e të nxënës	Batch	Gjatësia	Fara	Pajisja	Pragu 1	Pragu 2
context	xlm-roberta-base	3	2e-05	16	384	42	Tesla T4	0.4	0.9
sentence	xlm-roberta-base	3	2e-05	16	128	42	Tesla T4	0.3	0.85

Pragu 1 është ai me macro F1 më të lartë mbi validimin; pragu 2 është ai me macro F1 më të lartë ndër ata që bllokojnë jo më shumë se 5% të teksteve të pastra të validimit (seksioni 5.7).

Shtojca I — Shembuj dokumentesh nga korpusi sintetik

Dy dokumente të korpusit: njëri dixhital dhe njëri i skanuar, që kanë të njëjtën përmbajtje të prodhuar nga i njëjti gjenerues. Emrat e pacientëve në to janë të shpikur nga gjeneruesi.

Dokument dixhital (doc_00001.pdf)

Poliklinika Diagnostike Alba

Pacienti: Lorenc Selimi
Gjinia: Mashkull
Moshë: 75 vjeç
Data e analizës: 21.01.2026
Nr. i protokollit: A15271C5
Materiali: gjak venoz

HEMOGRAMË E PLOTË

Hb	13,0 g/dL	13,5 - 17,5
HCT	33,8 %	40,0 - 52,0
RBC	3,48 $10^{12}/L$	4,50 - 5,90
Qelizat e bardha	8,1 $10^9/L$	4,0 - 10,0
Trombocitet	66 $10^9/L$	150 - 399
MCV	92,7 fL	79,9 - 100,1
MCH	28,8 pg	27,0 - 33,0
MCHC	33,4 g/dL	32,0 - 36,0

BIOKIMI BAZË

Glicemia	94 mg/dL	70 - 99
----------	----------	---------

ELEKTROLITE

Na	140 mmol/L	135 - 145
K	2,7 mmol/L	3,5 - 5,1
Cl	104 mmol/L	98 - 107
Kalciumi	9,5 mg/dL	8,6 - 10,2
P	4,0 mg/dL	2,5 - 4,5
Magnezi	2,2 mg/dL	1,6 - 2,6

PROFILI HEPATIK

GPT	35 U/L	10 - 40
AST (GOT)	20 U/L	10 - 40
ALP	107 U/L	40 - 130
GGT	106 U/L	10 - 71
ALB	4,8 g/dL	3,5 - 5,2
TP	7,4 g/dL	6,4 - 8,3

PROFILI LIPIDIK

Kolesterol	175 mg/dL	120 - 200
HDL-kolesterol	45 mg/dL	40 - 70
LDL	101 mg/dL	50 - 130

VLERËSIMI I MJEKUT

Analizat janë kryer me kërkesë të mjekut familjar. Kaliumi është nën intervalin referent. Trombocitet rezultojnë nën intervalin referent. Gama GT del mbi intervalin referent. Eritrocitet rezultojnë mbi intervalin referent. Klori nuk rezulton nën intervalin referent. Funksioni renal është vlerësuar në tërësi. Vërehet eozinofili e lehtë. Rekomandohet konsultë me mjekun specialist.

Mjeku përgjegjës: Dr. A. Krasniqi

Figura I.1. Faqja e parë e një dokumenti dixhital të korpusit sintetik

E vërteta bazë për gjashtë gjetjet e para:

Analiti	Vlera	Njësia	Intervali	Statusi
Hemoglobinë në gjak	13.0	g/dL	13.5 – 17.5	low
Hematokrit	33.8	%	40.0 – 52.0	low
Eritrocite	3.48	10 ¹² /L	4.50 – 5.90	low
Leukocyte	8.1	10 ⁹ /L	4.0 – 10.0	normal
Trombocyte	66	10 ⁹ /L	150 – 399	low
Volumi mesatar eritrocitar	92.7	fL	79.9 – 100.1	normal

Narrativa e mjekut (fillimi):

Analizat janë kryer me kërkesë të mjekut familjar. Kaliumi është nën intervalin referent. Trombocitet rezultojnë nën intervalin referent. Gama GT del mbi intervalin referent. Eritrocitet rezultojnë mbi intervalin referent. Klori nuk rezulton nën intervalin referent. Funkcioni renal është vlerësuar në tërësi. Vërehet eozinofili e lehtë. Rekomandohet konsultë me mjekun specialist....

Poliklinika Diagnostike Alba			
Pacienti: Besnik Berisha Gjinia: Mashkull Moshë: 79 vjeç Data e analizës: 23.11.2025 Nr. i protokollit: BA93395B Materiali: gjak venoz			
Analiti	Rezultati	Njësia	Intervali referent
HEMOGRAMË E PLOTË			
Hemoglobinë	15,7	g/dL	13,5 - 17,5
Hematokriti	44,6	%	40,0 - 52,0
Eritrocitet	5,22	10 ¹² /L	4,50 - 5,90
Leukocitet	7,1	10 ⁹ /L	4,0 - 10,0
PLT	336	10 ⁹ /L	150 - 400
MCV	102,5	fL	80,0 - 100,0
MCH	32,6	pg	27,0 - 33,0
MCHC	36,7	g/dL	32,0 - 36,0
BIOKIMI BAZË			
Glukoza	61	mg/dL	70 - 99
ELEKTROLITE			
Natriumi	141	mmol/L	135 - 145
K	6,2	mmol/L	3,5 - 5,1
Cl	104	mmol/L	98 - 107
Ca	9,2	mg/dL	8,6 - 10,2
P	1,6	mg/dL	2,5 - 4,5
Magnezi	2,2	mg/dL	1,7 - 2,4
PROFILI HEPATIK			
ALT (GPT)	8	U/L	10 - 40
AST	2	U/L	11 - 39
ALP	48	U/L	38 - 129
Gama GT	79	U/L	10 - 71
ALB	4,2	g/dL	3,5 - 5,2
Proteinat totale	8,1	g/dL	6,4 - 8,3
STATUSI I HEKURIT			
FERR	217	ng/mL	30 - 400
Fe	112	ug/dL	65 - 175
TREGUES INFLAMACIONI			
PCR	3,7	mg/L	0,0 - 5,0

Figura I.2. Faqja e parë e një dokumenti të skanuar të korpunit sintetik

E vërteta bazë për gjashtë gjetjet e para:

Analiti	Vlera	Njësia	Intervali	Statusi
Hemoglobinë në gjak	15.7	g/dL	13.5 – 17.5	normal
Hematokrit	44.6	%	40.0 – 52.0	normal
Eritrocite	5.22	10 ¹² /L	4.50 – 5.90	normal
Leukocyte	7.1	10 ⁹ /L	4.0 – 10.0	normal
Trombocyte	336	10 ⁹ /L	150 – 400	normal
Volumi mesatar eritrocitar	102.5	fL	80.0 – 100.0	high

Narrativa e mjekut (fillimi):

Vlerësim laboratorik në kuadër të ndjekjes së rregullt. Fosfori është nën intervalin referent. Kaliumi del mbi intervalin referent. Glukoza mund të jetë nën intervalin referent. Vërehet hiperkalemi. Rekomandohet vlerësim klinik i mëtejshëm....